



ET SCIENCES DU NUMERIQUE

UNIVERSITE VIRTUELLE DE CÔTE D'IVOIRE

N° d'ordre :

Mémoire Pour l'obtention du :

Diplôme de Master

Domaine : Sciences et Technologies

Mention : Informatique et Applications Numériques

Spécialité : Big Data Analytics (BDA)

Présenté par

Amani Yao Jean Marc

Sujet :

Système d'aide au diagnostic du cancer
du sein basé sur la classification
échographique des lésions mammaires
par apprentissage profond.

Soutenu le .../.../...devant le jury composé de :

M.	Professeur Titulaire	Université Virtuelle de Côte d'Ivoire	Président
M.	Maître Assistant	...	Superviseur
Mme.	Maître de Conférences	...	Examineur
Mme.	Maître de Conférences	...	Examineur

REMERCIEMENTS

Je remercie en premier lieu DIEU de m'avoir donné la force, la persévérance et la capacité de mener à bien ce mémoire de **Master Big Data Analytics**.

Je tiens à exprimer ma profonde gratitude à Monsieur Edja Béranger, Directeur de mémoire, pour son encadrement rigoureux, sa disponibilité constante et ses conseils avisés qui ont structuré ce travail.

Je souhaite adresser ma reconnaissance à l'ensemble des enseignants du Master Big Data Analytics de l'université virtuelle de côte d'ivoire pour la qualité exceptionnelle de leur formation et l'excellence académique dispensée.

Un remerciement particulier à mes collègues de promotion pour nos échanges enrichissants, notre soutien mutuel et les moments de partage qui ont marqué cette année universitaire.

Je remercie l'administration universitaire pour son appui dans les démarches administratives et la mise à disposition des ressources nécessaires à ce travail.

Je remercie du fond du cœur ma famille pour son soutien indéfectible, sa patience et sa confiance durant ces mois de recherche intensive.

Je remercie chaleureusement mes amis proches pour leur présence constante, leurs encouragements sincères et leur compréhension face aux exigences de ce mémoire.

Abidjan, le 27 février 2026

Amani Yao Jean Marc

DÉDICACE

À ma famille bien-aimée,
À toutes les femmes ivoiriennes touchées par le cancer du sein,
À celles qui luttent aujourd'hui,
À celles qui s'en sont sorties,
À la mémoire de celles qui nous ont quittées.

Ce travail vous est dédié.

RÉSUMÉ

Contexte et Problématique : Le cancer du sein constitue en Côte d'Ivoire un défi majeur de santé publique, avec plusieurs milliers de nouveaux cas annuels et un taux de létalité supérieur à 50% [1]. Cette forte mortalité est principalement liée à un diagnostic tardif (stades III–IV dans plus de 70% des cas) et à un déficit d'infrastructures de dépistage organisé [2]. Dans ce contexte, l'échographie mammaire s'impose comme un outil de première ligne. Cependant, la fatigue cognitive des praticiens et la difficulté de caractériser certaines lésions, en particulier sur des tissus mammaires denses fréquents chez les patientes ouest-africaines, peuvent limiter l'efficacité du diagnostic.

Solution Proposée : Ce mémoire développe un système de diagnostic assisté par ordinateur (CADx) adapté au contexte ivoirien, visant à proposer un outil de triage clinique pour la classification automatisée de lésions mammaires suspectes en échographie. La méthodologie repose sur l'architecture EfficientNet-B0 (avec DenseNet-121 comme modèle de référence), affinée pour une classification en trois classes cliniques : normal, bénin et malin.

Sur un jeu de test indépendant rigoureusement assaini de toute fuite de données (data leakage), le modèle EfficientNet-B0 atteint une exactitude globale de 82,7%, avec un rappel natif de 90,3% sur la classe maligne. Surtout, par l'application d'un protocole de calibration clinique (Fail-Safe), la sensibilité (rappel) atteint 96,7% pour les lésions malignes, garantissant un niveau de sécurité renforcé pour un usage en dépistage de première ligne. En parallèle, une architecture en cascade avec U-Net a été explorée de manière préliminaire pour isoler la lésion du tissu environnant, ouvrant la voie à une explicabilité visuelle accrue et à une meilleure prise en compte des seins denses.

Contributions:

- 1) Mise en place d'un pipeline d'IA complet pour la classification mammaire en trois classes, respectant la nomenclature clinique stricte.
- 2) Réduction des problèmes d'oubli catastrophique (catastrophic forgetting) grâce à une gestion fine du gel de la BatchNormalization sur un petit volume de données médicales.

3) Implémentation d'un seuillage asymétrique (Fail-Safe) optimisant le modèle pour un contexte de triage, avec un rappel malin de 96,7%.

Perspectives : Un déploiement pilote prospectif au sein d'un environnement hospitalier ivoirien (tel que les CHU d'Abidjan), la création d'une bio-banque de données locales annotées, ainsi que le ré-entraînement conjoint de modèles de segmentation (U-Net) en cascade, afin d'isoler et de caractériser les lésions en tenant compte de la densité mammaire spécifique des patientes.

Mots-clés : Cancer du sein ; échographie mammaire ; EfficientNet-B0 ; classification automatisée ; U-Net ; triage clinique ; Côte d'Ivoire.

ABSTRACT

Background and Problem Statement : Breast cancer constitutes a major public health challenge in Côte d'Ivoire, with thousands of new cases annually and a mortality rate exceeding 50% [1]. This high mortality is primarily linked to late-stage diagnosis (stages III–IV in over 70% of cases) and a lack of organized screening infrastructure [2]. In this context, breast ultrasound stands out as a first-line tool. However, practitioner cognitive fatigue and the difficulty of characterizing certain lesions, particularly in the dense breast tissues common among West African patients, can limit diagnostic efficacy.

Proposed Solution : This thesis develops a Computer-Aided Diagnosis (CADx) system adapted to the Ivorian context, aiming to provide a clinical triage tool for the automated classification of suspicious breast lesions on ultrasound. The methodology relies on the EfficientNet-B0 architecture (with DenseNet-121 as a baseline model), fine-tuned for a strict three-class clinical classification: normal, benign, and malignant.

On an independent test set rigorously sanitized against any data leakage, the EfficientNet-B0 model achieves an overall accuracy of 82.7%, with a native recall of 90.3% for the malignant class. Crucially, through the application of a clinical calibration protocol (Fail-Safe), the sensitivity (recall) reaches 96.7% for malignant lesions, ensuring an enhanced level of safety for use in first-line screening. Concurrently, a cascaded architecture with U-Net was preliminarily explored to isolate the lesion from surrounding tissue, paving the way for increased visual explainability and better management of dense breasts.

Contributions :

- Implementation of a complete AI pipeline for three-class breast classification, strictly adhering to clinical nomenclature.
- Reduction of catastrophic forgetting issues through fine-grained management of BatchNormalization freezing on a small volume of medical data.
- Implementation of an asymmetric thresholding strategy (Fail-Safe) optimizing the model for a triage context, with a malignant recall of 96.7%.

Perspectives : A prospective pilot deployment within the CHUs of Abidjan, the creation of a locally annotated data bio-bank, and the joint re-training of cascaded segmentation models (U-Net) to isolate and characterize lesions while accounting for patient-specific breast density.

Keywords : Breast cancer; breast ultrasound; EfficientNet-B0; automated classification; U-Net; clinical triage; Côte d'Ivoire.

Table des matières

RÉSUMÉ.....	3
ABSTRACT	4
INTRODUCTION GÉNÉRALE	7
CHAPITRE 1 : CONTEXTE CLINIQUE ET ÉPIDÉMIOLOGIQUE	9
CHAPITRE 2 : ÉTAT DE L'ART ET POSITIONNEMENT DE L'ÉTUDE.....	14
CHAPITRE 3 : MÉTHODOLOGIE-PIPELINE D'IA POUR LA CLASSIFICATION DES LÉSIONS MAMMAIRES ÉCHOGRAPHIQUES.....	24
CHAPITRE 4 : RÉSULTATS EXPÉRIMENTAUX ET DISCUSSION	32

CHAPITRE 5 : DISCUSSION SCIENTIFIQUE.....	39
CONCLUSION GÉNÉRALE ET PERSPECTIVES	49
RÉFÉRENCES	51
ANNEXES	53
LISTE DES FIGURES	55
LISTE DES TABLEAUX.....	57
LISTE DES ABRÉVIATIONS.....	58

INTRODUCTION GÉNÉRALE

En Côte d'Ivoire, le cancer du sein constitue aujourd'hui une véritable urgence de santé publique. Il représente la première cause de cancer chez la femme dans le pays, avec 4 845 cas et 2 284 décès, selon la fiche technique spécifique au pays [1] tirée des dernières estimations mondiales de l'Agence Internationale de Recherche sur le Cancer (publiées par Sung, Bray et al. dans « Global cancer statistics 2024 ») [15]. Le taux de létalité dépasse 50 %, l'un des plus élevés d'Afrique de l'Ouest, comme le souligne le Programme National de Lutte contre le Cancer (PNLC) [2].

Cette mortalité élevée est en grande partie liée à un diagnostic tardif : plus de 70 % des cas ivoiriens sont détectés aux stades cliniques avancés III et IV [2], contre environ 30 % dans les pays européens. À ce stade, les options thérapeutiques sont limitées et le pronostic de survie se dégrade significativement. Ce retard diagnostique s'explique principalement par le déficit d'infrastructures de dépistage. La mammographie, examen radiologique de référence en oncologie mammaire, reste très peu accessible à l'échelle nationale : la Côte d'Ivoire présente un ratio mammographes/population parmi les plus faibles d'Afrique de l'Ouest [2]. Outre son coût élevé d'acquisition et de maintenance, cet examen expose les patientes à des rayonnements ionisants et peut être douloureux lors de la compression du sein, ce qui en limite l'acceptabilité dans certains contextes. Face à cette contrainte matérielle, l'échographie mammaire technique d'imagerie par ultrasons, exempte de rayonnements ionisants, portable et économique s'est imposée comme l'examen de première ligne le plus accessible dans les centres de santé ivoiriens. Elle présente en outre un avantage majeur dans le contexte africain : les femmes d'Afrique subsaharienne présentent fréquemment une densité mammaire élevée (riches en tissu glandulaire), comme l'expliquent Amadou et al. dans « Breast cancer in Africa: a review » [28]. Dans un sein dense, la mammographie est moins efficace car le tissu masque les tumeurs sur l'image. L'échographie contourne ce problème car les ultrasons traversent bien ces tissus et permettent de distinguer clairement les masses. Il est cependant essentiel de rappeler que toute masse détectée à l'échographie n'est pas nécessairement un cancer. Les lésions mammaires comprennent de nombreuses lésions bénignes (comme les kystes ou les fibroadénomes) qui ne sont pas dangereuses mais nécessitent un suivi. Le système international BI-RADS aide les médecins à classer ces masses : les catégories 1 et 2 sont rassurantes, la catégorie 3 nécessite un contrôle après six mois, et les catégories 4 et 5 sont suspectes et nécessitent une biopsie (un prélèvement). C'est précisément sur les lésions ambiguës (catégories 3 et 4) que la décision du médecin est la plus difficile et que le risque d'erreur diagnostique s'accroît.

La principale limite de l'échographie mammaire est que sa fiabilité dépend fortement de l'expérience du médecin qui la réalise. L'interprétation d'une masse ambiguë repose sur l'analyse visuelle de plusieurs détails:

la forme de la lésion (ovale pour le bénin, irrégulière pour le malin), son orientation par rapport à la peau, la nature de ses contours (nets et réguliers pour le bénin ; spiculés, anguleux ou indistincts pour le malin), et son échogénicité interne (homogène ou hétérogène). Ces critères sont complexes à évaluer. Très souvent, deux radiologues différents peuvent donner un avis contraire sur la même image. De plus, la fatigue liée au nombre important de patientes reçues chaque jour augmente le risque de rater un cancer (un faux négatif) sur les images les plus difficiles.

Plusieurs équipes de recherche ont exploré l'apport de l'intelligence artificielle, et plus précisément des réseaux de neurones convolutifs (CNN), pour automatiser cette analyse. Raza et al. [12], dans « Breast cancer classification from ultrasound images using deep learning », ont obtenu des résultats supérieurs à 90 % d'accuracy sur le jeu de données BUSI pour distinguer le bénin du malin. McKinney et al. [14], dans une étude publiée dans Nature en 2020, ont démontré que des systèmes d'IA pouvaient même dépasser les performances de radiologues expérimentés sur la mammographie. Ces travaux s'appuient sur des modèles reconnus, comme DenseNet (proposé par Huang et al. dans « Densely Connected Convolutional Networks » [4]) et EfficientNet (introduit par Tan et Le dans « EfficientNet » [8]).

Cependant, ces travaux présentent trois limites qui motivent notre recherche. Premièrement, presque tous se limitent à un choix binaire (bénin ou malin), en excluant les images de sein normal. Cela ne reflète pas la réalité du médecin qui doit classer trois situations : tissu sain, masse bénigne, ou masse maligne. Deuxièmement, aucun de ces systèmes n'a été pensé pour un contexte africain, avec ses particularités (seins très denses et qualité d'image variable). Troisièmement, la plupart des algorithmes fonctionnent comme des "boîtes noires" : ils donnent un résultat sans expliquer pourquoi, ce qui fait que les médecins hésitent à leur faire confiance.

C'est pour corriger ces lacunes que s'inscrit notre travail. Notre problématique est la suivante : Comment concevoir et optimiser un système d'aide au diagnostic (basé sur les CNN DenseNet-121 et EfficientNet-B0) pour classer automatiquement les échographies mammaires en trois catégories (normal, bénin, malin), afin de fournir un second avis fiable et explicable aux radiologues ivoiriens ?

Notre contribution scientifique s'articule autour de trois axes :

1. **Un système complet en 3 classes** : Nous proposons un classifieur strict (normal/bénin/malin) entraîné sur la base de données BUSI d'Al-Dhabyani et al.

[3]. Nous avons préalablement assaini ces données pour prévenir toute fuite de données (data leakage), en retirant notamment les masques de segmentation du jeu de test.

2. **Une adaptation fine des modèles** : Nous comparons rigoureusement les architectures EfficientNet-B0 et DenseNet-121, en utilisant une technique d'entraînement spécifique (le gel progressif des couches) pour éviter que le modèle n'oublie les connaissances acquises lors du pré-entraînement (Catastrophic Forgetting).
3. **L'explicabilité des décisions** : Nous utilisons la technique Grad-CAM [6] pour rendre l'IA compréhensible. Le système génère une carte de chaleur superposée à l'image indiquant les zones précises (contours, formes, texture) qui l'ont aidé à prendre sa décision, permettant au médecin de vérifier la pertinence médicale du résultat.

Le présent mémoire s'organise en cinq chapitres :

Le Chapitre 1 présente la situation épidémiologique du cancer du sein en Côte d'Ivoire, les limites de la mammographie et le rôle de l'échographie mammaire.

Le Chapitre 2 dresse l'état de l'art des architectures CNN appliquées à l'imagerie mammaire, des bases de données de référence et des méthodes d'explicabilité.

Le Chapitre 3 décrit la méthodologie mise en œuvre : préparation des données, choix d'architectures, protocole d'entraînement et calibration des seuils.

Le Chapitre 4 analyse et compare les résultats expérimentaux entre EfficientNet-B0 et DenseNet-121, avec visualisation Grad-CAM.

Le Chapitre 5 discute la portée clinique des résultats et les perspectives de déploiement dans les Centres Hospitaliers Universitaires (CHU) d'Abidjan.

CHAPITRE 1 : CONTEXTE CLINIQUE ET ÉPIDÉMIOLOGIQUE

Ce premier chapitre a pour objectif de dresser le panorama clinique et épidémiologique du cancer du sein en Côte d'Ivoire. Avant d'aborder les solutions technologiques basées sur l'intelligence artificielle, il est indispensable de comprendre la réalité du terrain : la prévalence de la


maladie, les infrastructures de santé disponibles, le système de classification radiologique en vigueur (BI-RADS), ainsi que les particularités physiologiques des patientes ouest-africaines qui justifient le choix de l'échographie mammaire comme modalité de dépistage privilégiée.

I-CONTEXTE CLINIQUE EN CÔTE D'IVOIRE

1.1 Épidémiologie et limites des infrastructures de dépistage

En Côte d'Ivoire, le cancer du sein est le cancer féminin le plus fréquemment diagnostiqué et représente l'une des principales causes de mortalité par cancer chez la femme [2]. L'étude de l'Observatoire Mondial du Cancer (GLOBOCAN), publiée par Sung, Bray et al. dans « Global cancer statistics 2024 » [15], ainsi que la fiche technique spécifique à la Côte d'Ivoire [1], font état d'une incidence de 4 845 cas et de 2 284 décès à l'échelle nationale. La Figure 1.1 et le Tableau 1.1 illustrent l'ampleur de ce problème de santé publique, le cancer du sein représentant à lui seul plus du tiers (40,7 %) des cancers féminins diagnostiqués.

Figure 1.1 : Répartition des cancers féminins en Côte d'Ivoire
(Données GLOBOCAN 2024)






Tableau 1.1 : Charge du cancer du sein chez la femme en Côte d'Ivoire (GLOBOCAN 2024 [1] , [15])

Indicateur	Valeur 2022
Incidence (cas diagnostiqués)	4 845
Mortalité (décès)	2 284
Part du sein dans les cancers féminins	40,7%
Rang du cancer du sein parmi les cancers féminins	1er
Principale source de données	Registre du cancer d'Abidjan

Au-delà des statistiques brutes, la réalité clinique en Afrique subsaharienne se caractérise par des tumeurs qui surviennent souvent chez des patientes plus jeunes et sous des formes biologiques agressives (telles que les cancers dits "triple-négatifs"). Cette agressivité tumorale rend la rapidité de la prise en charge d'autant plus cruciale. Pourtant, cette mortalité élevée reste majoritairement liée à un diagnostic tardif. Contrairement aux pays occidentaux où le dépistage précoce permet de sauver de nombreuses vies, la Côte d'Ivoire voit la majorité de ses patientes arriver à l'hôpital à un stade clinique très avancé (stades III et IV). Ce décalage dramatique s'explique non seulement par un manque d'équipements médicaux adaptés, mais également par la complexité du parcours de soins. Souvent, la découverte d'une anomalie se fait de manière fortuite par la patiente elle-même. Son premier contact s'effectue

généralement dans un centre de santé primaire de proximité, sous-équipé en imagerie lourde, ce qui initie un long processus de transfert vers une structure tertiaire. Habituellement, la mammographie (examen par rayons X) est la méthode de référence mondiale pour le dépistage. Cependant, le réseau national ivoirien repose sur quelques dizaines de mammographes fixes, principalement concentrés à Abidjan dans les grandes structures de référence (CHU de Treichville et de Cocody, INSP, CNRAO). En dehors de ces centres urbains, l'accès à cet équipement lourd et coûteux reste extrêmement limité. Face à cette centralisation, l'échographie mammaire joue un rôle de première ligne décisif. Beaucoup plus accessible dans les centres de santé de proximité, plus économique, indolore et exempte de rayonnements ionisants, elle constitue souvent le premier, voire l'unique examen d'imagerie qu'une patiente pourra réaliser.

1.2 L'échographie mammaire : avantages anatomiques et défis diagnostiques (BI-RADS)

Au-delà de son aspect purement économique et logistique, l'échographie répond à un impératif physiologique spécifique au contexte africain : la densité mammaire. À la mammographie, la graisse apparaît en noir et le tissu mammaire dense en blanc (tout comme les tumeurs), ce qui crée un effet de masquage rendant les lésions indétectables. En revanche, l'échographie utilise des ondes sonores (ultrasons) capables de bien traverser ce tissu dense pour distinguer clairement les masses. Or, les femmes d'Afrique subsaharienne présentent une proportion significativement plus élevée de seins denses (catégories BI-RADS C et D) que les populations européennes, selon les études d'Amadou et al. [28] et de Loeffler & Kabba [18]. Pour ces patientes, la mammographie classique perd drastiquement de son efficacité. L'échographie devient alors non plus une simple alternative, mais une nécessité médicale absolue. Toutefois, identifier l'existence d'une masse à l'échographie n'est que la première étape ; il faut ensuite en évaluer la nature exacte. L'échographie est une modalité d'imagerie intrinsèquement complexe à lire. Contrairement à la radiographie qui offre un rendu net, l'image échographique est naturellement sujette à des artefacts acoustiques, notamment le "bruit de chatoiement" (speckle noise). Ce phénomène physique donne un aspect granuleux à l'image et réduit considérablement le contraste entre la lésion et les tissus sains environnants. Pour standardiser

les diagnostics malgré ces difficultés visuelles, l'American College of Radiology a mis en place le système BI-RADS, résumé dans le Tableau 1.2.

Tableau 1.2 : Les catégories BI-RADS en échographie

Catégorie	Risque de cancer	Conduite clinique à tenir
1	0%	Examen normal. Aucune action requise.
2	0%	Anomalie bénigne certaine. Suivi de routine.
3	Moins de 2 %	Probablement bénin. Une surveillance à six mois est recommandée.
5	2 à 10 %	Anomalie faiblement suspecte. Une biopsie est souvent requise.
4B / 4C	10 à 95 %	Anomalie modérément à hautement suspecte. Biopsie obligatoire.
5	Plus de 95 %	Forte probabilité de malignité.

Le grand défi quotidien des radiologues est de différencier les masses bénignes (catégorie 3) des petits cancers naissants (catégorie 4A), afin d'éviter à la fois les faux négatifs (qui laisseraient un cancer proliférer) et les biopsies chirurgicales inutiles. Ce classement exige une acuité visuelle extrême, car il repose sur l'analyse de critères morphologiques très fins : la forme de la lésion, son orientation par rapport à la peau (une orientation non-parallèle étant très suspecte), la nature de ses contours et son échogénicité interne. Par exemple, faire la distinction visuelle entre un contour "net" (caractéristique d'un kyste bénin) et un contour "spiculé" ou "micro-lobulé" (signe que la tumeur s'infiltré comme des racines dans le tissu) est souvent rendu périlleux par le bruit granuleux de l'échographie. Ces critères structurels, qui guident difficilement l'œil humain, sont précisément les paramètres mathématiques que le modèle d'apprentissage profond (CNN) devra apprendre à extraire et reconnaître automatiquement, comme nous le verrons au Chapitre 3.

1.3 L'intelligence artificielle comme outil d'aide au diagnostic (CADx)

L'interprétation de ces subtils critères morphologiques reste fortement soumise à l'expérience visuelle du praticien, ce qui entraîne une variabilité de diagnostic d'un médecin à l'autre. Or, la Côte d'Ivoire, à l'instar de nombreux pays de la sous-région, fait face à une pénurie de radiologues spécialisés en sénologie, créant des déserts médicaux diagnostiques en dehors des grands pôles hospitaliers. Aujourd'hui, avec la numérisation croissante des hôpitaux ivoiriens (déploiement du Dossier Patient Informatisé), de nouvelles perspectives techniques s'ouvrent pour pallier ce manque de spécialistes. L'implémentation de logiciels d'Aide au Diagnostic (CADx) basés sur l'intelligence artificielle apparaît comme une solution technologique particulièrement pertinente. Installé sur la station de travail de l'échographe, ce système ne remplace pas le médecin, mais agit comme un second lecteur infatigable et objectif. Il fournit une analyse instantanée (probabilité de malignité) pour conforter le praticien dans sa décision finale, s'avérant particulièrement utile face aux images ambiguës classées BI-RADS 3 ou 4. Cependant, l'intégration de ces technologies importées soulève un défi scientifique majeur : le biais de représentation des données d'entraînement. La très grande majorité des modèles d'intelligence artificielle commerciaux actuels ont été conçus et entraînés sur des bases de données occidentales ou asiatiques, issues de populations présentant des densités mammaires différentes et capturées avec des équipements haut de gamme. Comme le soulignent Loeffler et Kabba dans leur revue systématique sur l'imagerie mammaire en Afrique subsaharienne [30], le déploiement et l'évaluation de ces outils d'intelligence artificielle dans les pays à ressources limitées restent très peu documentés. C'est très exactement cette lacune scientifique que notre étude cherche à combler, en explorant l'adaptabilité et les performances des réseaux de neurones appliqués spécifiquement à ce type d'imagerie. Le chapitre suivant dresse justement l'état de l'art du fonctionnement de ces modèles d'apprentissage profond et de leur application en imagerie médicale.

CHAPITRE 2 : ÉTAT DE L'ART ET POSITIONNEMENT DE L'ÉTUDE

Ce deuxième chapitre dresse une revue critique des travaux scientifiques existants sur l'application de l'apprentissage profond à l'imagerie mammaire. Il analyse successivement les bases de données disponibles, les architectures neuronales éprouvées par la communauté scientifique, les biais méthodologiques persistants et

les approches d'explicabilité. Cette analyse aboutit à une synthèse comparative qui définit précisément le positionnement scientifique et la valeur ajoutée de notre étude.

II - REVUE DE LA LITTÉRATURE ET POSITIONNEMENT SCIENTIFIQUE

2.1 L'imagerie mammaire et la nécessité d'une base de données adaptée : Le choix de BUSI

L'entraînement d'un modèle d'intelligence artificielle requiert des corpus d'images médicales rigoureusement annotées par des experts cliniques. Les premières bases publiques de référence ont été constituées autour de la mammographie. Selon l'étude fondatrice de R. Sawyer-Lee et al. intitulée « Curated breast imaging subset of digital database for screening mammography (CBIS-DDSM) » [26], la base CBIS-DDSM regroupe environ 3 000 mammographies argentiques numérisées annotées pour des masses et des calcifications. De même, la publication de I. C. Moreira et al. intitulée « INbreast: Toward a full-field digital mammographic database » [27] rapporte que la base INbreast, développée au Portugal, contient 410 mammographies numériques plein champ avec des annotations au niveau des lésions. Ces bases ont permis des avancées majeures, mais elles présentent deux limites fondamentales pour notre contexte. D'une part, elles sont constituées en majorité à partir de patientes de populations occidentales, dont les profils de densité mammaire et donc les caractéristiques visuelles des images diffèrent significativement de ceux des femmes d'Afrique subsaharienne, comme démontré par Amadou et al. dans leur article « Breast cancer in Africa: a review » [28] et par Loeffler & Kabba dans leur étude « Breast imaging and cancer in sub-Saharan Africa » [18]. D'autre part, comme établi au Chapitre 1, la mammographie n'est pas l'outil de première ligne en Côte d'Ivoire. Ces bases ne sont donc pas directement transposables à notre problème. En réponse à ces limites, la communauté scientifique a constitué des bases de données en échographie mammaire. Parmi celles-ci, le Breast Ultrasound Images Dataset (BUSI), introduit par Al-Dhabyani et al. en 2020 dans leur article « Dataset of breast ultrasound images » [3], est devenu la référence internationale pour l'évaluation des systèmes de CADx sur échographies. Il contient 780 images réparties en trois classes. La Figure

2.1 illustre visuellement la diversité et la complexité des lésions présentes dans la base BUSI pour ces trois catégories :




Figure 2.1 : Exemples d'images échographiques extraites du dataset BUSI pour les trois classes : Normal, Bénin, Malin (Source : Al-Dhabyani et al. [3]).

Afin de situer BUSI dans le paysage scientifique, le Tableau 2.1 ci-dessous compare les principales bases de données publiques disponibles en sénologie.

Tableau 2.1 - Comparaison des principales bases de données publiques en sénologie

Dataset	Modalité	Nombres d'images (ordre de grandeur)	Types de classes / lésions	Limites principales
CBIS-DDSM	Mammographie film	≈ 3 000	Bénin / Malin	Population occidentale, modalité non disponible en CI
INbreast	Mammographie FFDM	410	Bénin / Malin	Très faible volume, un seul centre clinique
BUSI	Échographie	780	Normal / Bénin / Malin	Volume modéré, population moyen-orientale

La base BUSI s'impose pour notre étude pour deux raisons. Premièrement, elle correspond exactement à notre modalité cible l'échographie mammaire.

Deuxièmement, elle est l'une des rares bases à inclure trois classes cliniques distinctes (Normal, Bénin, Malin), ce qui reflète la réalité du radiologue en salle d'examen. Il est important de souligner une précision méthodologique : les classes de BUSI utilisent les termes Benign et Malignant dans leur sens histologique strict. Les lésions Benign désignent les tumeurs sans potentiel malin avéré (fibroadénomes, kystes complexes), qui nécessitent néanmoins un suivi en raison de leur morphologie ambiguë à l'échographie. Les lésions Malignant désignent les carcinomes confirmés par biopsie. Ces deux catégories ne doivent pas être confondues dans l'interprétation clinique des résultats. Cependant, l'exploitation d'une telle base de données nécessite des architectures algorithmiques capables d'extraire les critères radiologiques pertinents malgré le bruit échographique.

2.2 Évolution des architectures CNN et l'apport des modèles multi-branches

Avant l'avènement des réseaux de neurones convolutifs (CNN), le diagnostic assisté par ordinateur reposait sur l'extraction manuelle de caractéristiques les chercheurs programmaient des algorithmes pour mesurer la circularité, le contraste ou la rugosité d'une masse. Cette approche, bien que novatrice, se montrait rigide et difficile à généraliser sur des images dégradées par le bruit de chatoiement (speckle noise) caractéristique de l'échographie. Les CNN s'affranchissent de cette contrainte en extrayant automatiquement les caractéristiques de manière hiérarchique. Ce processus reproduit d'ailleurs de manière computationnelle l'analyse visuelle BI-RADS du radiologue :

- **Les premières couches convolutives** détectent les gradients de bords et les variations d'intensité locales ce qui correspond aux contours réguliers ou irréguliers de la masse.
- **Les couches intermédiaires** agrègent ces informations pour reconnaître des structures plus complexes telles que les micro-lobulations ou les contours spiculés (critères suspects forts).
- **Les couches profondes** intègrent enfin le contexte spatial global, permettant d'évaluer l'orientation de la masse par rapport au plan cutané (verticalité) ou la présence d'ombres acoustiques postérieures.

Parmi les architectures historiques de référence, DenseNet-121, introduite par Huang et al. en 2017 [4], repose sur un principe d'interconnexion totale. Les Figures 2.2 et 2.3 détaillent le fonctionnement de ces connexions denses (Dense Blocks). Cette architecture préserve les gradients de bas niveau (les bords fins et micro-lobulations

qui signent les lésions BI-RADS 4) jusqu'aux couches de décision, tout en limitant le risque de surapprentissage.






Figure 2.2 : Architecture globale du réseau DenseNet (Source : Huang et al. [4]).

Standard Connectivity



Resnet Connectivity



DenseNet Connectivity




Figure 2.3 : Détail d'un "Dense Block" illustrant le principe de réutilisation des caractéristiques (feature reuse) (Source : Huang et al. [4]).

Plus récemment, l'architecture EfficientNet, théorisée par Tan et Le dans leur publication intitulée « EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks » [8], a introduit le Compound Scaling pour optimiser la résolution et la profondeur du réseau. Cette légèreté algorithmique constitue un avantage opérationnel décisif pour un déploiement hospitalier aux ressources limitées. Aujourd'hui, les recherches les plus récentes (2025-2026) abandonnent les réseaux simples pour se tourner vers des architectures hybrides (qui combinent plusieurs modèles) et multi-branches (qui analysent l'image sous plusieurs angles). Par exemple, dans leur article intitulé « Tri-ResNet: A Parallel Multi-Branch and Transfer Learning Triple-Input Model » [31], Kacher et al. proposent le modèle Tri-ResNet et démontrent qu'en fusionnant les prédictions issues de différentes entrées (images globales et régions d'intérêt) via un apprentissage d'ensemble, il est possible d'augmenter drastiquement la précision discriminante du réseau. (À noter que dans le domaine connexe de l'analyse histologique au microscope, des approches similaires d'ensemble ont été proposées, comme le modèle CAE-StackedNet d'Ogundokun et al. [32]). La Figure 2.5 schématise ce principe de transfert de connaissances, crucial pour pallier le manque de données médicales :




Figure 2.5 : Schéma du processus d'Apprentissage par Transfert (Transfer Learning) de données générales vers des données médicales.

Ces architectures modernes reposent toutes sur l'Apprentissage par Transfert (Transfer Learning). Initialisées avec des poids pré-entraînés sur ImageNet (plus d'un million d'images génériques), elles sont ensuite adaptées aux échographies par un ajustement fin (Fine-Tuning). Cette stratégie pallie le volume insuffisant de données médicales annotées disponibles. Si ces avancées architecturales sont remarquables, il convient de les évaluer à l'aune des performances réelles publiées sur notre dataset cible.

2.3 Résultats des travaux récents sur BUSI : performances et limites

Pour positionner notre contribution, il est indispensable de quantifier les résultats des travaux les plus récents (2024) appliqués à la base BUSI. Le Tableau 2.2 propose une synthèse comparative des métriques cliniques rapportées dans la littérature récente.

Tableau 2.2 - Synthèse des travaux existants récents (2020-2024) sur le dataset BUSI

Auteurs	Année	Architecture / Méthode	Classes	Accuracy	Rappel Malin	Limites identifiées
Al-Dhabyani et al. [3]	2020	Baseline CNN	Normal/Bénin /Malin	≈ 73 %	Non rappel	Modèle de référence (non optimisé)
Raza et al. [12]	2023	DeepBreastCancerNet	Bénin/Malin	94,8 %	Non rapp.	Classification binaire, exclut Normal
G.Madhu et al. [29]	2024	UCapsNet (U-Net + Capsule)	Normal/Bénin /Malin	99,2 %	99,5 %	Complexité extrême (deux réseaux en série), difficile à déployer
A. Fiaz et al. [30]	2024	Deep Fusion Vision Transformer	Bénin/Malin	97,7 %	Non rapp.	Classification binaire uniquement, exclut le tissu Normal
Notre étude	2025-2026	EfficientNet-B0 (Transfer)	Normal/Bénin /Malin	82,7 %	90,3 %	Voir Chapitre 4

L'analyse de ce tableau soulève trois constats critiques :

- La simplification du problème** : De nombreuses études très performantes (comme Fiaz et al. [30] ou Raza et al. [12]) atteignent des scores élevés en se limitant à une classification binaire (Bénin vs Malin). En excluant les images normales, elles éludent le cas clinique quotidien le plus difficile : distinguer un tissu mammaire sain d'une lésion bénigne ambiguë.
- La rareté du critère de Rappel (Sensibilité)** : La majorité des publications ne rapportent pas explicitement le Recall sur la classe maligne, préférant communiquer sur l'Exactitude globale (Accuracy).
- La complexité calculatoire** : Si les modèles comme UCapsNet [29] offrent des performances exceptionnelles sur le papier, leur architecture à deux étages

(Segmentation puis Classification) requiert une puissance de calcul massive (GPU haut de gamme), les rendant inadaptés à une installation directe dans les dispensaires locaux.

Ces limites méthodologiques nous conduisent à reconsidérer la manière dont les modèles doivent être évalués et entraînés.

2.4 Enjeux méthodologiques : déséquilibre des classes et explicabilité

2.4.1 Le déséquilibre des classes et la Focal Loss

La distribution des images dans BUSI est intrinsèquement déséquilibrée : 437 images bénignes contre 210 malignes et 133 normales. Entraîner un modèle avec une fonction de coût standard (Cross-Entropy) conduit à une optimisation trompeuse : le modèle apprend à prédire systématiquement la classe majoritaire pour maximiser son Accuracy globale, générant ainsi des faux négatifs cliniquement inacceptables. Pour corriger ce biais, la Focal Loss, introduite par Lin et al. [5], modifie dynamiquement la contribution de chaque image à l'erreur totale. Contrairement à la Cross-Entropy classique, la Focal Loss introduit un facteur de modulation $(1 - p_t)^\gamma$. La fonction de perte s'exprime ainsi :

$$L_{FL}(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t)$$

où p_t est la probabilité prédite pour la classe cible, α_t est un facteur de pondération pour équilibrer les classes, et γ (paramètre de focalisation) réduit le poids des exemples faciles à classer. Dans ce cadre, notre métrique principale d'évaluation n'est plus l'Accuracy, mais bien le Rappel (Sensibilité) sur la classe maligne. Sur le terrain, un faux négatif (un cancer non détecté) entraîne des conséquences létales, tandis qu'un faux positif aboutit, par précaution, à une biopsie.

2.4.2 L'explicabilité par Grad-CAM

L'adoption clinique des modèles se heurte à leur opacité. Pour qu'un radiologue accorde sa confiance au système, il doit vérifier que l'IA a détecté la lésion en utilisant des critères morphologiques réels (ex: spiculation) et non en "apprenant" un artefact en arrière-plan. La méthode Grad-CAM (Gradient-weighted Class Activation Mapping) [6] répond à cette exigence. La Figure 2.4 démontre ce fonctionnement. En calculant les gradients de la dernière couche convolutive, Grad-CAM génère une "carte de

chaleur" superposée à l'échographie, désignant précisément les zones ayant motivé le choix du réseau.




Figure 2.4 : Principe de fonctionnement de Grad-CAM illustrant la localisation spatiale des caractéristiques prédictives (Source : Selvaraju et al. [6]).

Ainsi équipé, le modèle cesse d'être une boîte noire pour devenir un second lecteur interactif.

2.5 Synthèse critique et positionnement de notre étude

L'analyse de la littérature existante révèle trois failles fondamentales que notre travail se propose de combler :

1. **Le contournement de la réalité clinique** : Les études binaires sur-optimisent leurs résultats. Nous imposerons à notre modèle une classification stricte en 3 classes (Normal, Bénin, Malin).
2. **L'erreur d'objectif statistique** : Rater un cancer est plus grave qu'une fausse alerte. Plutôt que de viser 99 % d'Accuracy artificielle, nous calibrerons le modèle avec la Focal Loss pour maximiser un Rappel clinique cible de 90 % sur les lésions malignes.
3. **La déconnexion matérielle** : UCapsNet [29] atteint des performances exceptionnelles de 99,2 % d'accuracy en combinant un réseau U-Net de segmentation et un réseau Capsule de classification. Cependant, cette

architecture à deux étages requiert une puissance de calcul massive plusieurs GPU haut de gamme et un temps d'inférence élevé, rendant son déploiement impossible sur les postes de travail standard des hôpitaux ivoiriens. De plus, ses résultats sont obtenus avec les masques de segmentation inclus dans l'entraînement, ce qui constitue une fuite de données (data leakage) que nous avons précisément éliminée dans notre protocole. Notre approche EfficientNetB0 atteint 82,7 % d'accuracy sur des données assainies, avec un temps d'inférence de moins d'une seconde sur CPU standard condition indispensable pour un déploiement réel en Côte d'Ivoire.

Le Chapitre 3 décrira en détail la méthodologie de prétraitement et le pipeline d'entraînement mis en œuvre pour atteindre ces objectifs.

CHAPITRE 3 : MÉTHODOLOGIE-PIPELINE D'IA POUR LA CLASSIFICATION DES LÉSIONS MAMMAIRES ÉCHOGRAPHIQUES

Ce chapitre décrit l'architecture logicielle, les transformations appliquées aux images et les stratégies d'apprentissage profond mises en œuvre. L'ensemble de la méthodologie est conçu pour répondre à deux contraintes majeures : le déséquilibre des classes et la priorité clinique donnée à la détection des lésions malignes.

III - CONCEPTION ET PROTOCOLE D'ENTRAÎNEMENT DU MODÈLE

3.1 Partitionnement des données (Train / Val / Test)


Avant toute opération d'entraînement, le dataset de 780 images a été rigoureusement divisé pour garantir une évaluation non biaisée. La répartition classique 70% / 15% / 15% a été retenue :

- **Ensemble d'entraînement (Train - 70%)** : 546 images utilisées pour l'optimisation des poids du modèle. C'est sur cet ensemble uniquement que l'augmentation de données (Mixup) est appliquée.
- **Ensemble de validation (Validation - 15%)** : 117 images utilisées pour surveiller l'apprentissage à chaque époque, ajuster les taux d'apprentissage

(Learning Rate) et décider de l'arrêt précoce (Early Stopping) pour éviter le surapprentissage.

- **Ensemble de test (Test - 15%)** : 117 images strictement isolées jusqu'à la toute fin du projet. Elles simulent les performances du modèle en conditions réelles sur des patientes jamais vues.

Cette division a été réalisée de manière stratifiée, s'assurant que la proportion de cas normaux, bénins et malins soit identique dans les trois sous-ensembles. De plus, pour contrer le déséquilibre initial strict sans polluer les données de validation et de test (prévention du data leakage), des augmentations hors-ligne ont été appliquées uniquement sur l'ensemble d'entraînement. Ce processus a permis d'équilibrer les classes et de générer un corpus d'entraînement étendu à 1 580 images, comme l'illustre la répartition stricte détaillée ci-dessous.



3.2 Pipeline de prétraitement : CLAHE et Mixup

L'analyse d'images échographiques est rendue difficile par le bruit speckle et le faible contraste des tissus. Le prétraitement vise donc à améliorer la qualité visuelle des images tout en préservant la morphologie des lésions.

3.2.1 Normalisation et amélioration de contraste (CLAHE)

Toutes les images sont redimensionnées à 320×320 pixels et normalisées dans l'intervalle [0, 1] (facteur rescale = 1/255). Pour améliorer le contraste local, un filtre CLAHE (Contrast Limited Adaptive Histogram Equalization) est appliqué :

- opération par tuiles locales
- paramètres : $clip_limit = 2.0, tile_grid_size = (8,8)$

Contrairement à une égalisation d'histogramme globale, CLAHE limite l'amplification artificielle du contraste et évite de renforcer excessivement le bruit, ce qui est crucial pour les contours subtils des masses mammaires.

3.2.2 Augmentation de données : choix de Mixup

Pour régulariser le modèle et réduire l'overfitting, une stratégie d'augmentation de données est mise en place. Deux approches ont été testées : CutMix [11] (découpage/collage de patches d'images) et Mixup [10] (combinaison linéaire d'images et de labels). Les essais préliminaires ont montré que CutMix a été jugé moins adapté au maintien des structures échographiques fines dans notre protocole (spiculations, bords, forme globale de la tumeur). Le pipeline final conserve donc uniquement Mixup [10]. Cette technique génère de nouveaux exemples d'entraînement en combinant linéairement deux images (x_i, x_j) et leurs labels correspondants (y_i, y_j) :

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j \quad \tilde{y} = \lambda y_i + (1 - \lambda)y_j$$

où le coefficient d'interpolation λ est tiré d'une distribution Bêta(α, α). Pour notre étude, nous avons fixé le paramètre $\alpha = 0.1$ avec une probabilité d'application $p = 0.5$. Un α faible garantit que les images générées restent proches de la réalité anatomique, tout en lissant les frontières de décision du modèle.

3.2.3 Limites et risques du prétraitement

Bien que le prétraitement améliore la lisibilité des images, il comporte des limites. Un contraste trop renforcé peut accentuer des artefacts. De même, l'augmentation par

Mixup ne doit pas s'éloigner de la réalité clinique au risque de perturber la différenciation entre lésions malignes et anomalies bénignes. Le choix d'un alpha très faible vise à respecter l'équilibre entre diversité des données et préservation des signatures tumorales.

3.3 Architectures d'extraction de caractéristiques

Notre méthodologie compare deux backbones pré-entraînés sur ImageNet pour l'extraction des caractéristiques visuelles.

3.3.1 Intérêt des blocs denses en échographie (DenseNet-121)

Dans DenseNet-121 [4], l'architecture est composée de 4 Dense Blocks interconnectés, totalisant 121 couches paramétrées (dont 117 couches convolutives et 4 couches denses). Sa particularité fondamentale est que chaque couche d'un bloc reçoit en entrée les cartes de caractéristiques (feature maps) concaténées de toutes les couches précédentes. Cette réutilisation systématique (Feature Reuse) est particulièrement pertinente pour l'échographie. Contrairement aux architectures résiduelles classiques qui procèdent par addition, DenseNet préserve explicitement les caractéristiques de bas niveau grâce à la concaténation. Les gradients texturaux (les textures fines, les hétérogénéités subtiles) sont ainsi maintenus jusqu'aux dernières couches de décision, permettant au modèle de baser sa prédiction simultanément sur la morphologie globale (haut niveau) et l'échogénicité locale (bas niveau).

3.3.2 Architecture EfficientNet-B0 et stratégie d'adaptation

EfficientNet-B0, introduit par Tan et Le [8], repose sur un principe de mise à l'échelle coordonnée (Compound Scaling) de la profondeur, de la largeur et de la résolution du réseau. Par rapport à DenseNet-121, EfficientNet-B0 offre un rapport performance/coût computationnel supérieur, avec environ 5,3 millions de paramètres contre 8 millions pour DenseNet. Sa légèreté le rend particulièrement adapté à un déploiement sur des postes hospitaliers aux ressources limitées.

3.3.3 Tête de classification

Au-dessus du backbone (DenseNet ou EfficientNet, chargé sans sa tête de classification d'origine), une tête spécifique à la tâche est ajoutée :

- **Couche de Global Average Pooling (GAP)** : dimensions spatiales tout en limitant les paramètres.
- **Couche Dense(512, activation='relu')** : Le choix de 512 neurones s'est avéré optimal après essais empiriques. Une taille de 256 compressait excessivement les caractéristiques complexes des trois classes, tandis que 1024 neurones induisaient un surapprentissage massif (overfitting) sur notre petit jeu de 780 images, le modèle tendant à mémoriser les exemples d'entraînement.
- **Couche Dropout(0.3)** : Fixée à 0.3 pour désactiver aléatoirement 30% des neurones, forçant le réseau à apprendre des représentations redondantes et robustes sans trop ralentir la convergence.
- **Couche de sortie Dense(3, activation='softmax')** : pour fournir une probabilité sur les trois classes (bénin, malin, normal).

(Des modules d'attention CBAM [20] ont été explorés mais l'architecture finale repose sur la régularisation intrinsèque du réseau).

3.4 Protocole d'entraînement avancé

L'entraînement est réalisé en deux phases successives afin de stabiliser d'abord la tête de classification, puis d'ajuster finement le backbone.

3.4.1 Stratégie de fine-tuning progressif

- Phase 1 – Apprentissage de la tête
 - Backbone DenseNet totalement gelé
 - Seules les couches supérieures (GAP + Dense(512) + Dropout + Dense(3)) sont entraînées
 - Taux d'apprentissage initial : $\text{lr} = 1\text{e-}4$
 - Ordonnancement du lr par Cosine Annealing avec warmup de 5 époques
- Phase 2 – Fine-tuning conservateur
 - Dégel des $\approx 15\%$ couches supérieures du backbone (≈ 65 couches entraînables sur 427)
 - Taux d'apprentissage très faible : $\text{lr} = 5\text{e-}6$
 - Particularité cruciale: Les couches de BatchNormalization ont été explicitement maintenues gelées pendant cette phase. Lors des premiers essais d'EfficientNet-B0 sans gel de ces couches, l'accuracy de validation

chutait de 74 % à 38 % dès la première époque de la Phase 2. Ce comportement suggérait une forte sensibilité des statistiques de normalisation au faible batch size (batch_size=16), entraînant une instabilité d'adaptation susceptible de dégrader les poids pré-entraînés sur ImageNet.

3.4.2 Focal Loss pondérée et priorités cliniques

La fonction de coût Cross-Entropy standard traite de manière identique les exemples faciles et les exemples difficiles, ce qui la rend inadaptée au déséquilibre de classes. La Focal Loss [5] modifie ce comportement en ajoutant un facteur de modulation dynamique :

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t)$$

Où $\gamma = 2.0$ (paramètre de focalisation) maintient une forte pression d'apprentissage sur les cas ambigus. Les coefficients de poids de classe α_t ont été ajustés pour refléter la réalité clinique de l'oncologie :

- $\alpha_{\text{benin}} = 1.2$: léger renforcement pour garantir un haut taux de détection des cancers avérés (priorité absolue).
- $\alpha_{\text{malin}} = 1.0$: poids de référence
- $\alpha_{\text{normal}} = 1.5$: compensation de la faible représentation de cette classe dans la base de données.

3.4.3 Exploration et choix des hyperparamètres

Les valeurs des hyperparamètres n'ont pas été fixées arbitrairement, mais sont le résultat d'une recherche systématique (Grid Search). Les taux d'apprentissage finaux (1e-4 puis 5e-6) représentent un compromis entre l'adaptation du modèle aux textures échographiques et la préservation de ses capacités d'extraction générales. Les poids de la Focal Loss garantissent que le modèle est fortement pénalisé s'il omet des lésions malignes, alignant ainsi l'objectif d'optimisation mathématique avec l'exigence clinique de minimisation des faux négatifs. La pondération asymétrique finale (1.2, 1.0, 1.5) a été retenue empiriquement car elle permet de maximiser le rappel sur la classe maligne sans effondrer la précision globale (les résultats détaillés seront exposés au Chapitre 4).

3.5 Métriques d'évaluation et Calibration clinique

Dans un contexte de dépistage, toutes les erreurs n'ont pas le même impact. Un faux négatif sur une lésion maligne (rater un cancer) retarde une prise en charge vitale. Un faux positif entraîne des biopsies inutiles, générant de l'anxiété mais assurant la sécurité de la patiente.

3.5.1 Les métriques de référence

Pour évaluer formellement les performances du modèle, nous nous basons sur la matrice de confusion qui dénombre les Vrais Positifs (TP), Vrais Négatifs (TN), Faux Positifs (FP) et Faux Négatifs (FN).

- **Recall / Sensibilité de la classe "malin" (Métrique Principale)** : Capacité du modèle à détecter tous les cancers avérés. C'est l'indicateur de sécurité clinique.

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **Précision** : Proportion de tumeurs réellement malignes parmi toutes celles prédites comme telles par le modèle.

$$\text{Précision} = \frac{TP}{TP + FP}$$

- **F1-score macro et AUPRC** : Le F1-score est la moyenne harmonique de la précision et du rappel. Calculé en "macro" (moyenne des F1-scores de chaque classe), il évalue le compromis exactitude/exhaustivité indépendamment des déséquilibres de classes.

$$F1 = 2 \times \frac{\text{Précision} \times \text{Recall}}{\text{Précision} + \text{Recall}}$$

- **Accuracy (Exactitude globale)** : Taux de bonnes prédictions sur l'ensemble du dataset. Bien qu'utile, cette métrique est trompeuse si elle masque un mauvais recall sur la classe maligne minoritaire.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

1.5.2 Calibration hiérarchique asymétrique (Fail-safe)

Après l'entraînement, des seuils de décision cliniques optimisés (T_{malin} , T_{benin}) sont calculés. Lors de l'inférence, la décision suit une règle hiérarchique de triage :

1. Si $p(malin) \geq T_{malin}$ la prédiction est malin (biopsie d'urgence).
2. Sinon, si $p(benin) \geq T_{benin}$ la prédiction est bénin (suivi ou biopsie optionnelle).

3. Ce n'est que si aucun de ces seuils n'est atteint que le réseau classe l'image comme normal.

Pour le modèle EfficientNet-B0 final, les valeurs de seuil retenues sur la courbe ROC de validation ont été fixées à $T_{malin} = 0.35$ (très sensible pour ne rater aucun cancer) et $T_{bénin} = 0.45$. Toute image n'atteignant pas ces scores stricts sur les classes pathologiques est alors considérée normale. Cette approche fail-safe doit être comprise comme une stratégie de triage clinique visant à optimiser le flux de travail, et non comme une règle de vérité médicale absolue. Elle garantit qu'en cas d'ambiguïté algorithmique, le modèle orientera la patiente vers le niveau de vigilance supérieur, réduisant ainsi le risque d'omission au stade du premier examen.

1.6 Reproductibilité : organisation du code et suivi des expériences

Afin de garantir la totale reproductibilité des expériences, plusieurs mesures strictes ont été prises dans l'architecture du projet :

- L'ensemble des tirages aléatoires (initialisation des poids, séparation 70/15/15 des données, augmentation Mixup) a été verrouillé par une "graine" globale (seed = 42) définie au début de tous les scripts Python (`os.environ['PYTHONHASHSEED']`, `np.random.seed`, `tf.random.set_seed`).
- Le code source a été organisé de manière modulaire en respectant les standards de l'ingénierie logicielle : `dataset_preparation.py` (gestion de la séparation stricte), `augmentation.py` (fonctions Mixup/CLAHE testables unitairement), et `train_advanced.py` (pipeline d'entraînement avec Focal Loss).
- Toutes les exécutions ont généré des artefacts automatisés via des callbacks Keras (ModelCheckpoint pour sauvegarder les meilleurs poids, CSVLogger pour l'historique complet de la fonction de perte à chaque époque, et sauvegarde automatique des matrices de confusion). L'intégralité du code et de ces artefacts est versionnée.

1.7 Résumé et logique clinique de la méthodologie

L'ensemble des choix méthodologiques présentés dans ce chapitre s'inscrit dans une logique de conception orientée par le besoin clinique. Chaque composant du pipeline (prétraitement, architecture de caractéristiques, schéma d'entraînement en deux phases, Focal Loss pondérée, calibration hiérarchique des seuils) vise à réduire au maximum le risque de faux négatifs sur les lésions malignes, tout en conservant une performance globale compatible avec un usage de triage. Concrètement, la

méthodologie développée dans ce mémoire repose sur un pipeline strict pour prévenir toute fuite d'informations (data leakage). Le jeu de données original a d'abord été divisé en trois sous-ensembles disjoints au niveau patient (70% entraînement, 15% validation, 15% test). Ensuite, uniquement sur l'ensemble d'entraînement, des augmentations hors-ligne ont été appliquées pour balancer les classes, générant un corpus théorique étendu à 1 580 images. Les images sont prétraitées par redimensionnement, normalisation et CLAHE pour améliorer le contraste local tout en limitant le bruit. Cette rigueur contribue à garantir que les résultats expérimentaux présentés dans le chapitre suivant tendent à estimer de manière réaliste les capacités de généralisation clinique du modèle sur de nouvelles patientes.

CHAPITRE 4 : RÉSULTATS EXPÉRIMENTAUX ET DISCUSSION

Ce chapitre expose les performances obtenues sur l'ensemble de test isolé (117 images brutes, rigoureusement séparées du jeu d'entraînement). Les résultats de la classification multiclasse (Normal, Bénin, Malin) sont analysés, d'abord sous l'angle des métriques standards, puis à travers le prisme de la matrice de confusion. L'impact concret de la calibration clinique (triage) introduite au chapitre précédent est ensuite chiffré. Enfin, l'interprétabilité du modèle via Grad-CAM et les limites de généralisation au contexte clinique ivoirien sont discutées.

IV - ANALYSE DES RÉSULTATS ET INTERPRÉTABILITÉ

4.1 Performances globales et benchmark des architectures

Sur l'ensemble de test de 117 images (correspondant à 15% de la base nettoyée de 780 images), trois architectures ont été évaluées de manière comparative. Les performances diagnostiques de ces modèles, détaillées

dans le Tableau 4.1 ci-dessous, attestent de l'efficacité de la stratégie de fine-tuning (notamment le gel des couches de BatchNormalization) et de l'augmentation de données hors-ligne.

4.1.1 Comparaison des métriques finales

Tableau 4.1 : Comparaison des performances finales sur le jeu de test (117 images)

Modèle	Exactitude (Accuracy)	F1-Score Macro	Rappel Malin (Recall)	Précision Maligne (Precision)
EfficientNet-B0	82.74%	81.27%	90.3%	71.3%
DenseNet-121 (Baseline)	81.33%	79.75%	77.4%	73.0%

(Note : 31 images malignes dans le jeu de test).

4.1.2 Choix de l'architecture optimale

L'architecture EfficientNet-B0 s'impose comme le modèle optimal. Bien que son exactitude globale (82,74 %) soit proche de celle de la baseline DenseNet, elle présente un avantage décisif : un rappel natif exceptionnel sur la classe maligne (90,3 %). En oncologie radiologique, cette capacité à minimiser naturellement les faux négatifs est le critère prépondérant. C'est donc le modèle EfficientNet-B0, calibré selon le protocole Fail-Safe du Chapitre 3, qui sera analysé en détail dans les sections suivantes.

4.2 Analyse des erreurs et matrice de confusion (Seuils standards)

Pour évaluer la solidité du modèle EfficientNet-B0, il est essentiel d'observer en premier lieu sa dynamique d'apprentissage. L'historique d'entraînement, illustré par la Figure 4.1, confirme la pertinence de la stratégie en deux phases : la ligne verticale délimite le passage au fine-tuning, où l'on constate une stabilisation saine des courbes de perte (Loss) et d'exactitude (Accuracy) sans signe de surapprentissage, notamment grâce à l'augmentation des données. Une fois cette convergence validée, il convient de comprendre finement le comportement diagnostique du modèle en analysant sa matrice de confusion avec le seuil de décision standard (Argmax), illustrée par la Figure 4.2. L'ensemble de test, strictement isolé de l'entraînement, comprend 117

images réparties de manière stratifiée comme suit : 20 Normales, 66 Bénignes, et 31 Malignes.




Figure 4.1 – Historique d’entraînement de l’EfficientNet-B0 (Courbes d'Accuracy et de Loss)




Figure 4.2 : Matrice de Confusion (Seuil Standard - Argmax)

4.2 Analyse des erreurs et matrice de confusion (Seuils standards)

L'analyse de cette distribution révèle plusieurs éléments cliniquement cohérents :

- **Les vrais positifs malins (28/31)** : Le modèle identifie correctement la vaste majorité des cancers avérés.
- **Les faux négatifs (Risque majeur)** : 3 lésions malignes ont été classées à tort (généralement confondues avec la classe "Bénin"). Une analyse visuelle a posteriori montre que ces lésions présentaient des contours étonnamment réguliers ou étaient de très petite taille, rendant leur discrimination plus difficile pour le modèle.
- **Les faux positifs malins (Sur-diagnostic)** : 11 images non cancéreuses (9 lésions bénignes et 2 cas normaux) ont été classées comme malignes. Ce phénomène s'explique par l'hétérogénéité de certains fibroadénomes complexes qui partagent des caractéristiques échographiques (ombre acoustique postérieure, irrégularité) avec les carcinomes. Dans un contexte de dépistage primaire, cette prudence algorithmique est acceptable.

4.3 Impact de la calibration clinique (Triage)

Comme théorisé au Chapitre 3, le seuillage standard de l'Argmax n'est pas optimal pour la sécurité de la patiente. L'application du protocole de Fail-Safe (seuils asymétriques fixés à $T_{\text{malin}} = 0.35$ et $T_{\text{bénin}} = 0.45$) vise spécifiquement à rattraper les 3 faux négatifs critiques identifiés précédemment.

4.3.1 Évolution des métriques de détection

En appliquant cette calibration de triage sur les probabilités brutes (Softmax) de l'ensemble de test, la répartition des prédictions est modifiée :

- **Rattrapage diagnostique (Rappel malin)** : Le rappel passe de 90,3 % (28/31) à 96,7 % (30/31). Grâce à la calibration, le modèle rattrape deux cas supplémentaires dont le cancer aurait été manqué avec un seuillage informatique classique. Un seul faux négatif subsiste (un carcinome de très petite taille, noyé dans un tissu fibroglandulaire dense sans spiculation évidente).
- **Conséquence sur la précision** : En contrepartie, le nombre de faux positifs malins passe de 11 à 18. Le taux de biopsies potentiellement inutiles augmenterait, mais ce compromis est totalement assumé dans notre cahier des charges clinique où le "coût médical" d'un cancer non détecté surpasse largement celui d'un examen complémentaire de contrôle.

Le bilan chiffré de cet arbitrage clinique est détaillé dans le Tableau 4.2

Tableau 4.2 Synthèse de l'impact de la calibration clinique sur EfficientNet-B0

Métrique	Seuil standard (Argmax)	Après calibration Fail-Safe
Vrais positifs malins	28 / 31	30 / 31
Faux négatifs (cancers ratés)	3	1
Recall malin	90,3 %	96,7 %
Faux positifs malins	11	18
Accuracy globale	82,74 %	78,47 %

Cette évolution diagnostique en conditions de triage est également synthétisée par la




Figure 4.2.



Figure 4.2 : Évolution de la matrice de confusion après calibration clinique

Cette démonstration valide mathématiquement l'hypothèse centrale de ce mémoire : un modèle d'IA en médecine ne doit pas chercher à maximiser aveuglément

l'exactitude globale (Accuracy), mais doit être calibré post-entraînement pour s'aligner sur la réalité du terrain médical.

4.4 Interprétabilité visuelle par Grad-CAM

Pour que ce système d'aide au diagnostic (CADx) soit accepté et utilisé par les praticiens, il doit être explicable (paradigme de la eXplainable AI). Les cartes d'activation de classe (Grad-CAM [6]) extraites de la dernière couche de convolution d'EfficientNet-B0 démontrent que le réseau prend ses décisions sur la base de critères anatomiquement pertinents, comme le mettent en évidence les Figures 4.3, 4.4 et 4.5.



4.4.1 Examen des cartes de chaleur

L'analyse des cartes de chaleur confirme l'apprentissage de biomarqueurs rigoureux :

- **Lésions malignes** : Les fortes activations recouvrent avec précision la masse hypoéchogène et se concentrent particulièrement sur les spicules (extensions étoilées) et les ruptures de l'architecture tissulaire. Les cartes Grad-CAM suggèrent une attention portée aux marges tumorales, ce qui correspond fidèlement à la méthode d'évaluation radiologique BI-RADS.
- **Lésions bénignes** : Le focus algorithmique est fermement maintenu sur le foyer lésionnel (souvent un ovale bien circonscrit et parallèle à la peau), ignorant le parenchyme glandulaire sain environnant.
- **Cas normaux** : L'activation est uniformément diffuse sur l'ensemble du tissu fibroglandulaire. Le modèle ne s'accroche à aucun artefact trompeur (zones d'ombre physiologiques, repères anatomiques non pathologiques ou texte incrusté en bordure), prouvant la robustesse du recadrage initial et de l'augmentation des données.

4.4.2 Analyse des erreurs par Grad-CAM (Faux positifs)

Il est tout aussi crucial de comprendre le comportement du modèle lorsqu'il se trompe. L'analyse Grad-CAM des faux positifs (images bénignes classées malignes) montre que le modèle ne prend pas de décisions aléatoires. Dans la majorité de ces cas, le réseau focalise son attention sur des micro-calcifications bénignes denses ou des ombres acoustiques profondes générées par des kystes complexes. Visuellement, ces zones miment la signature ultrasonore d'une tumeur infiltrante. Cette erreur algorithmique est cliniquement compréhensible : face à une telle ambiguïté visuelle, un clinicien humain aurait lui aussi très probablement classé la lésion en BI-RADS 4 (biopsie recommandée).

4.5 Limites de généralisation au contexte ivoirien

Bien que le modèle obtienne d'excellents résultats théoriques et génère des cartes visuelles cohérentes (Grad-CAM), la rigueur scientifique exige de reconnaître ses limites avant d'envisager son utilisation réelle dans les hôpitaux d'Abidjan. Actuellement, le déploiement de ce système sur le terrain se heurte à trois obstacles cliniques majeurs.

4.5.1 Le biais de densité mammaire afro-descendante

La base de données d'entraînement (BUSI) a été collectée auprès d'une population moyen-orientale dont les caractéristiques d'imagerie peuvent différer de la population ivoirienne. En effet, certaines études radiologiques [18], [28] suggèrent une prévalence variable de la densité mammaire selon les groupes démographiques. Si une proportion

importante de patientes locales présente des seins de forte densité (de type BI-RADS C ou D), l'analyse échographique s'en trouve complexifiée car ces parenchymes denses ont tendance à masquer les petites lésions. Une baisse algorithmique du rappel (Recall) est donc un risque à considérer si le modèle est appliqué sans fine-tuning local préalable.

4.5.2 L'espace latent face à la diversité lésionnelle

Bien que l'augmentation hors-ligne ait permis d'entraîner le modèle sur 1 580 images issues de la base BUSI [3], cette volumétrie reste modeste pour saturer un réseau convolutif profond. Les pathologies rares, les présentations atypiques (comme les carcinomes lobulaires infiltrants) ou les kystes complexes inflammatoires ne sont probablement pas suffisamment cartographiés dans l'espace latent du modèle.

4.5.3 Le paradigme statique 2D contre l'examen dynamique

Sur le terrain, le radiologue réalise un examen échographique résolument dynamique : il modifie la pression de la sonde pour évaluer la compressibilité (élastographie basique) et change les angles d'incidence. Le système CADx développé ici juge sur une coupe 2D unique, statique et pré-gelée. L'utilisation du modèle développé dans ce mémoire doit donc impérativement rester cantonnée à un rôle d'aide au "second regard" et de priorisation de flux (triage), sans jamais se substituer à la synthèse médicale globale du praticien.

Au-delà de ces considérations techniques et cliniques explorées tout au long de ce chapitre, l'architecture EfficientNet-B0 a démontré sa capacité à sécuriser le diagnostic grâce au protocole de Fail-Safe (96,7 % de rappel malin). Néanmoins, pour pallier les limites inhérentes à une approche purement classificatrice et enrichir l'explicabilité, l'intégration d'un module de segmentation spatiale s'avère pertinente. C'est l'objet du Chapitre 5, qui discutera de l'approche en cascade (U-Net), du bilan critique de ces travaux, ainsi que des perspectives de déploiement réel (MLOps) au sein des infrastructures hospitalières ivoiriennes.

CHAPITRE 5 : DISCUSSION SCIENTIFIQUE

Ce chapitre conclut notre étude en mettant en perspective les résultats obtenus. Il évalue notre contribution par rapport à l'état de l'art, discute des limites de notre approche et propose des axes d'amélioration concrets, notamment l'utilisation de

modèles de segmentation en cascade, en vue d'un futur déploiement dans le système de santé ivoirien.

V - DISCUSSION ET PERSPECTIVES CLINIQUES

5.1 Comparaison aux travaux de l'état de l'art

Les performances obtenues dans ce mémoire (rappel malin de 96,7 %, accuracy globale post-calibration de 78,47 % contre 82,74 % avant calibration la légère baisse d'exactitude étant le prix assumé de la hausse du recall malin de 90,3 % à 96,7 %) se situent dans une approche pragmatique et inédite par rapport à l'état de l'art. En effet, le problème traité ici est plus complexe qu'une simple classification binaire : il s'agit d'une classification à trois classes (normal, bénin, malin) sur un jeu de données strictement expurgé de toute fuite d'information (masques retirés). Là où la plupart des travaux cherchent uniquement à gonfler l'accuracy globale, notre approche maximise la sécurité clinique en minimisant les faux négatifs (seuillage asymétrique Fail-Safe), ce que peu d'études ciblent avec autant de rigueur. Des modèles comme UCapsNet [29] et Vision Transformer de Fiaz et al. [30] affichent des accuracy dépassant 97-99 % sur BUSI, mais en classification binaire uniquement et en exploitant les masques de segmentation dans le jeu de test ce qui constitue précisément la fuite de données que notre protocole a éliminée. Les études comparatives récentes [29] , [30] citent souvent DenseNet ou ResNet. Cependant, notre évaluation rigoureuse (Tableau 4.1) a démontré la supériorité d'EfficientNet-B0 face au déséquilibre des classes et aux petits jeux de données. La particularité et la force de ce travail résident dans la combinaison d'un assainissement strict des données, d'une régularisation structurelle (gel de la BatchNormalization), et d'une calibration asymétrique. Cette méthodologie permet d'atteindre une très haute sensibilité de détection (96,7 % sur les lésions malignes), répondant ainsi directement à l'exigence absolue de sécurité pour un système de triage en première ligne, particulièrement adapté aux contraintes du dépistage en Côte d'Ivoire.

5.2 Limites : taille d'échantillon et biais de population

Les limites identifiées au Chapitre 4 rejoignent des difficultés bien documentées dans la littérature sur le deep learning en imagerie médicale. Plusieurs revues systématiques [18] , [20] soulignent que la plupart des modèles existants sont entraînés sur des datasets de taille limitée et peu diversifiés, souvent centrés sur des populations caucasiennes ou asiatiques, ce qui réduit la capacité de généralisation vers d'autres groupes démographiques. Dans ce travail, le corpus de 1 580 images

enrichies à partir de BUSI reste modeste pour un réseau de 5 à 8 millions de paramètres, malgré le recours au transfert d'apprentissage et à l'augmentation. Ceci expose le modèle au risque de sur-spécialisation sur les caractéristiques propres à BUSI. Un autre point critique est le biais de population. Des travaux récents [18] , [28] insistent sur le fait que la plupart des modèles de dépistage du cancer du sein sont entraînés sur des données provenant majoritairement de patientes européennes, nord-américaines ou asiatiques, avec des profils de densité mammaire et des contextes cliniques différents de ceux observés en Afrique subsaharienne. Dans ce mémoire, l'utilisation d'un dataset issu d'un autre contexte géographique signifie que les performances mesurées ne peuvent pas être transposées telles quelles à la population ivoirienne, où la prévalence élevée de seins denses pourrait réduire la sensibilité du modèle. Enfin, le modèle développé est unimodal (échographie 2D seule) et ne tient pas compte du contexte clinique (âge, antécédents, facteurs de risque) ni d'autres modalités (mammographie, IRM). La littérature montre pourtant que les systèmes d'aide au diagnostic les plus performants tendent vers des approches multimodales et multi-centriques, combinant plusieurs sources d'information et validées sur des données externes hétérogènes.

5.3 Perspectives : Segmentation U-Net, Cascade et Déploiement Clinique

Plusieurs pistes de travail se dégagent pour prolonger ce mémoire et aller vers un déploiement progressif dans un environnement clinique comme les CHU d'Abidjan. L'une des perspectives les plus prometteuses, testée de manière préliminaire à l'issue de ce travail, est l'intégration d'un modèle de segmentation U-Net [23] en cascade avec notre classifieur EfficientNet-B0.

5.3.1 Architecture en cascade (U-Net + EfficientNet) : Expérimentation Pratique

Actuellement, le modèle EfficientNet-B0 traite l'échographie entière. Cependant, en contexte clinique, les radiologues fondent leur diagnostic sur des critères BI-RADS précis liés à la forme de la lésion (contours spiculés, orientation, etc.). Afin d'isoler la lésion du bruit de fond (tissus sains, ombres acoustiques), nous avons développé et testé un pipeline en deux étapes :

1. **Étape de Segmentation (U-Net) [23]** : Un réseau U-Net génère un masque binaire détournant la tumeur au pixel près.


2. **Étape de Classification (EfficientNet-B0)** : Le masque est utilisé pour extraire la zone d'intérêt (masquage du fond en noir) avant de la transmettre au réseau de classification finale (normal, bénin, malin).

Résultats de l'expérimentation : Un test pratique rapide a été implémenté en masquant le fond de l'image. Les résultats immédiats sur EfficientNet-B0 (entraîné originellement sur des images entières) ont montré une chute vertigineuse de l'accuracy (tombant à environ 14%). Ce comportement est scientifiquement cohérent et riche en enseignements :

- **Biais de contexte global** : Il démontre que l'EfficientNet actuel s'appuie fortement sur la texture globale du parenchyme mammaire (le fond) pour prédire la classe, et pas uniquement sur la lésion elle-même.
- **Nécessité d'un ré-entraînement conjoint** : Pour qu'une architecture en cascade soit performante, il est impératif de ré-entraîner entièrement le modèle EfficientNet-B0 sur les images détournées (masquées par U-Net). Ainsi, le classifieur apprendra à n'extraire que les caractéristiques intrinsèques de la tumeur (bordures, spiculation interne) sans dépendre du contexte global.

L'extrait de code suivant illustre l'architecture U-Net utilisée pour la segmentation et le pipeline de cascade

Extrait simplifié du script train_unet.py — Architecture U-Net



```
def build_unet(input_shape=(256, 256, 3)):
    inputs = layers.Input(shape=input_shape)

    # Encoder
    c1 = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(inputs)
    c1 = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(c1)
    p1 = layers.MaxPooling2D((2, 2))(c1)

    c2 = layers.Conv2D(64, (3, 3), activation='relu', padding='same')(p1)
    c2 = layers.Conv2D(64, (3, 3), activation='relu', padding='same')(c2)
    p2 = layers.MaxPooling2D((2, 2))(c2)

    c3 = layers.Conv2D(128, (3, 3), activation='relu', padding='same')(p2)
    c3 = layers.Conv2D(128, (3, 3), activation='relu', padding='same')(c3)
    p3 = layers.MaxPooling2D((2, 2))(c3)

    c4 = layers.Conv2D(256, (3, 3), activation='relu', padding='same')(p3)
    c4 = layers.Conv2D(256, (3, 3), activation='relu', padding='same')(c4)
    p4 = layers.MaxPooling2D((2, 2))(c4)

    # Bottleneck
    c5 = layers.Conv2D(512, (3, 3), activation='relu', padding='same')(p4)
    c5 = layers.Conv2D(512, (3, 3), activation='relu', padding='same')(c5)

    # Decoder
    u6 = layers.Conv2DTranspose(256, (2, 2), strides=(2, 2), padding='same')(c5)
    u6 = layers.concatenate([u6, c4])
    c6 = layers.Conv2D(256, (3, 3), activation='relu', padding='same')(u6)
    c6 = layers.Conv2D(256, (3, 3), activation='relu', padding='same')(c6)

    u7 = layers.Conv2DTranspose(128, (2, 2), strides=(2, 2), padding='same')(c6)
    u7 = layers.concatenate([u7, c3])
    c7 = layers.Conv2D(128, (3, 3), activation='relu', padding='same')(u7)
    c7 = layers.Conv2D(128, (3, 3), activation='relu', padding='same')(c7)

    u8 = layers.Conv2DTranspose(64, (2, 2), strides=(2, 2), padding='same')(c7)
    u8 = layers.concatenate([u8, c2])
    c8 = layers.Conv2D(64, (3, 3), activation='relu', padding='same')(u8)
    c8 = layers.Conv2D(64, (3, 3), activation='relu', padding='same')(c8)

    u9 = layers.Conv2DTranspose(32, (2, 2), strides=(2, 2), padding='same')(c8)
    u9 = layers.concatenate([u9, c1])
    c9 = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(u9)
    c9 = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(c9)

    outputs = layers.Conv2D(1, (1, 1), activation='sigmoid')(c9)
```

```
def build_unet(input_shape=(256, 256, 3)):
    inputs = tf.keras.Input(shape=input_shape)
```

Encodeur (contraction)

```
c1 = Conv2D(64, 3, activation='relu', padding='same')(inputs)
p1 = MaxPooling2D()(c1)
c2 = Conv2D(128, 3, activation='relu', padding='same')(p1)
p2 = MaxPooling2D()(c2)
```

Pont (bottleneck)

```
b = Conv2D(256, 3, activation='relu', padding='same')(p2)
```

Décodeur (expansion) avec skip connections

```
u1 = UpSampling2D()(b)
u1 = Concatenate()([u1, c2]) # Skip connection
d1 = Conv2D(128, 3, activation='relu', padding='same')(u1)
```



```

u2 = UpSampling2D()(d1)
u2 = Concatenate()([u2, c1]) # Skip connection
d2 = Conv2D(64, 3, activation='relu', padding='same')(u2)

```

Masque binaire de sortie

```

outputs = Conv2D(1, 1, activation='sigmoid')(d2)
return tf.keras.Model(inputs, outputs)

```

Extrait simplifié du script test_unet_efficientnet_cascade.py
Pipeline de cascade : U-Net → Masquage → DenseNet

```

32 def test_cascade(original_img_path):
33     print("Chargement de l'image : {original_img_path}")
34     original_img = cv2.imread(original_img_path)
35     if original_img is None:
36         raise FileNotFoundError(f"Impossible de lire l'image : {original_img_path}")
37
38     original_img = cv2.cvtColor(original_img, cv2.COLOR_BGR2RGB)
39
40     print("Initialisation des adaptateurs de modèles...")
41     # 1. Adaptateur U-Net (Respect de la Clean Architecture)
42     unet = UNetAdapter()
43
44     # 2. Adaptateur EfficientNet-B0
45     effnet_adapter = EfficientNetAdapter()
46     effnet_model, _ = effnet_adapter.build_model((224, 224), 0.3, 0.001)
47
48     #
49     # ETAPE 1 : Segmentation par U-Net
50     #
51     print("Segmentation par U-Net...")
52     unet_input = cv2.resize(original_img, (256, 256)) / 255.0
53     unet_input_tensor = np.expand_dims(unet_input, 0)
54
55     try:
56         mask_binary = unet.predict_mask(unet_input_tensor)[0]
57     except Exception as e:
58         print(f"Attention: (e). Utilisation d'un masque simulé pour le test.")
59         mask_binary = np.ones((256, 256, 1), dtype=np.float32)
60
61     #
62     # ETAPE 2 : Application du masque sur l'image d'origine
63     #
64     print("Application du masque et prétraitement (CLAHE)...")
65     mask_resized = cv2.resize(mask_binary, (224, 224))
66     img_224 = cv2.resize(original_img, (224, 224)) / 255.0
67
68     # CLAHE
69     try:
70         from src.domain.preprocessing import apply_clahe
71         img_clahe = apply_clahe(img_224)
72     except ImportError:
73         img_clahe = apply_clahe_fallback(img_224)
74
75     # Multiplication par le masque
76     masked_img = img_clahe * np.expand_dims(mask_resized, -1)
77
78     #

```

1. Segmentation par U-Net (256x256)

```

unet_input = cv2.resize(original_img, (256, 256)) / 255.0
mask_pred = unet_model.predict(np.expand_dims(unet_input, 0))[0]
mask_binary = (mask_pred > 0.5).astype(np.float32)

```

2. Application du masque sur l'image originale

```

mask_resized = cv2.resize(mask_binary, (224, 224))

```



```
img_224 = cv2.resize(original_img, (224, 224)) / 255.0
masked_img = apply_clahe(img_224) * np.expand_dims(mask_resized, -1)
```

3. Classification par DenseNet-121

```
pred_probs = densenet_model.predict(np.expand_dims(masked_img, 0))[0]
predicted_class = np.argmax(pred_probs)
```

L'impact de ce masquage direct sans ré-entraînement conjoint est synthétisé dans le Tableau 5.1 ci-dessous :

Tableau 5.1 – Comparaison des performances en cascade

Métrique	EfficientNet-B0 seul (pré-calibration)	Cascade U-Net + EfficientNet-B0
Accuracy globale	82,7 %	14,7 %
F1-score macro	0,81	0,12
Recall « malin »	90,3 %	0,0 %
Recall « bénin »	77,3 %	12,5 %
Recall « normal »	85,0 %	43,5 %

Pour mieux appréhender la chute spectaculaire de ces métriques, l'impact visuel du masquage sur une échographie est détaillé dans les Figures 5.1, 5.2 et 5.3 :




Figure 5.1 : Échographie mammaire originale (contexte textural complet)




Figure 5.2 : Masque de segmentation binaire généré par le modèle U-Net




Figure 5.3 : Image masquée (lésion isolée sur fond noir) soumise au classifieur EfficientNet-B

Ces visuels illustrent clairement le phénomène de perte d'information contextuelle : lorsque le fond est entièrement mis en noir par le masque U-Net, le classifieur (entraîné sur des images complètes) perd les repères texturaux du parenchyme mammaire sur lesquels il avait appris à se baser. Ce résultat confirme que le ré-entraînement conjoint du classifieur sur les images segmentées est un prérequis indispensable pour exploiter pleinement cette architecture en cascade.

5.3.2 L'apport de U-Net face aux spécificités ivoiriennes (Âge et Densité)

L'utilisation d'un U-Net ouvre également une voie majeure pour adresser le défi des tissus mammaires denses, très fréquents chez les patientes ivoiriennes jeunes. Un modèle de segmentation permet de :

Calculer automatiquement les caractéristiques morphologiques : Taille exacte en cm^2 , orientation (parallèle ou non-parallèle), et régularité des marges. Ces paramètres extraits mathématiquement offrent une explicabilité totale au médecin.

Isoler l'effet de l'âge : En séparant la lésion du tissu fibro-glandulaire dense environnant, le système réduit considérablement les faux positifs chez les patientes jeunes.

Suivi longitudinal : U-Net permettrait de mesurer objectivement l'évolution du volume tumoral d'une patiente sous chimiothérapie néo-adjuvante mois après mois.

5.3.3 Plan de déploiement progressif dans les CHU d'Abidjan

La translation du modèle vers la pratique clinique nécessite une démarche progressive, structurée en plusieurs phases, afin de garantir à la fois la sécurité des patientes et l'adaptation aux contraintes du système de santé ivoirien. Des expériences internationales montrent que les déploiements réussis d'IA en dépistage mammaire reposent souvent sur un cheminement en plusieurs étapes. Dans le contexte des CHU d'Abidjan, un plan de déploiement réaliste pourrait s'organiser en quatre phases successives, étalées sur plusieurs années.

- 1. Phase 1 : Validation rétrospective locale.** En appliquant le modèle aux archives d'échographies mammaires des CHU (examens déjà interprétés et dont l'issue clinique est connue). L'objectif serait de comparer, de manière anonyme et sans impact sur la prise en charge, les prédictions de l'IA aux comptes rendus existants, afin d'estimer le recall réel sur les lésions malignes et le taux de faux positifs dans la population ivoirienne. En parallèle, un protocole de recherche et un cadre éthique devraient être validés par les instances compétentes.
- 2. Phase 2 : Pilote prospectif en double lecture.** Au sein d'un seul service d'imagerie de ces CHU, les radiologues continueraient à réaliser leur lecture habituelle, tandis que le système CADx produirait en arrière-plan un score de risque et une suggestion de classe, accompagnés de cartes Grad-CAM. Les décisions cliniques resteraient basées sur la lecture humaine, mesurant l'impact potentiel de l'IA sans exposer les patientes à un risque.
- 3. Phase 3 : Intégration partielle dans le flux de travail (triage ou "safety net").** Le modèle prioriserait la relecture des cas les plus suspects, réduisant les délais pour les patientes à haut risque, ou agirait comme filet de sécurité en déclenchant une alerte sur des examens jugés normaux par le clinicien en cas de discordance forte.
- 4. Phase 4 : Extension multi-sites.** Intégration dans les stratégies nationales de lutte contre le cancer du sein, nécessitant une infrastructure numérique minimale (archivage, réseau) et un cadre de gouvernance.

5.4 Enjeux éthiques et organisationnels de l'IA en dépistage

L'intégration d'un système d'IA dans le dépistage du cancer du sein soulève des questions éthiques et organisationnelles qui dépassent les seules performances chiffrées :

- **Responsabilité clinique** : En cas de faux négatif, il faut clarifier le rôle du radiologue et de l'outil. Le modèle est conçu comme une aide à la décision en double lecture, le médecin restant l'autorité finale.
- **Équité d'accès** : Le déploiement ne doit pas renforcer les inégalités. La validation clinique prospective locale est indispensable pour garantir que le modèle performe de manière équitable sur toutes les patientes ivoiriennes.
- **Gouvernance des données de santé** : La confidentialité, l'anonymisation et le contrôle des métadonnées sont des prérequis impératifs.

En définitive, si les performances de notre modèle EfficientNet-B0 calibré prouvent la faisabilité technique d'un outil de dépistage automatisé performant (96,7 % de sensibilité), sa viabilité clinique repose sur un équilibre délicat entre puissance diagnostique, explicabilité (Grad-CAM) et intégration ergonomique. Les expérimentations préliminaires menées avec U-Net démontrent que l'intelligence artificielle en imagerie médicale ne se résume pas à une course aux métriques, mais exige une compréhension profonde du contexte anatomique et radiologique. Le passage du cadre expérimental in silico vers la salle d'échographie ivoirienne ne sera pas qu'un défi technologique, mais avant tout un projet médical et organisationnel. Il nécessitera d'associer étroitement les radiologues et les décideurs de santé publique, afin que cette innovation se traduise in fine par ce qui compte le plus : une détection plus précoce et une réelle réduction de la mortalité par cancer du sein chez les femmes en Côte d'Ivoire.

CONCLUSION GÉNÉRALE ET PERSPECTIVES

Le cancer du sein reste une cause majeure de mortalité chez la femme, particulièrement dans les pays à ressources limitées manquant d'infrastructures de dépistage organisé. Face à cet enjeu, cette étude s'est attachée à concevoir un modèle de deep learning dédié à la classification automatisée des lésions mammaires échographiques. En s'appuyant sur l'architecture EfficientNet-B0, l'objectif était d'intégrer d'emblée les contraintes et les exigences d'un futur déploiement hospitalier ivoirien. L'analyse de l'état de l'art a révélé que si de nombreux travaux atteignent des performances élevées en classification binaire (bénin/malin), rares sont ceux qui abordent un scénario à trois classes cliniques tout en priorisant explicitement la sensibilité diagnostique. Pour y répondre, une méthodologie stricte a été déployée sur un jeu de données rigoureusement nettoyé pour limiter les biais (notamment la fuite d'information liée aux masques). L'entraînement a combiné une augmentation de

données dynamique (Mixup), une fonction de perte pondérée (Focal Loss) et le gel ciblé de la BatchNormalization pour prévenir l'oubli catastrophique (Catastrophic Forgetting). Ces choix structurants ont naturellement orienté l'algorithme vers un comportement de triage. Les résultats expérimentaux ont confirmé la supériorité d'EfficientNet-B0 face au déséquilibre des classes. Par l'application d'une calibration clinique (Fail-Safe), le système a atteint une sensibilité (rappel) exceptionnelle de 96,7 % sur la détection des lésions malignes. Si ce filet de sécurité s'obtient au prix d'une légère baisse de l'exactitude globale (78,47 % contre 82,74 % pré-calibration), ce compromis assumé correspond exactement au cahier des charges d'un outil de dépistage de première ligne. Par ailleurs, les cartes d'activation Grad-CAM [6] suggèrent que l'algorithme se focalise majoritairement sur des zones anatomiquement pertinentes. Enfin, le test préliminaire d'une architecture en cascade (U-Net) a rappelé l'importance de préserver le contexte échographique global. Cette recherche présente toutefois des limites objectives. L'échantillon modeste (780 images) et son origine géographique (hors Afrique subsaharienne) restreignent la généralisation du modèle, notamment face à la densité mammaire spécifique des patientes ouest-africaines. De plus, l'approche reste unimodale (échographie 2D seule), ignorant les données cliniques (âge, antécédents) qui demeurent pourtant essentielles à la pratique radiologique quotidienne. Ces contraintes dessinent des perspectives claires pour la recherche future. La priorité est la constitution d'une bio-banque locale annotée au sein des CHU d'Abidjan, indispensable pour ré-entraîner l'algorithme sur les spécificités régionales. Sur le plan méthodologique, l'évolution vers un système multimodal et l'évaluation d'architectures plus légères (MobileNet, EfficientNet-Lite) ou hybrides (architectures hybrides de type CNN-Transformer) mieux adaptées aux contraintes matérielles des hôpitaux ivoiriens faciliteront son adoption. À terme, un projet pilote en double lecture permettrait de mesurer l'impact réel du système tout en garantissant la sécurité médicale des patientes. Sur le plan scientifique, cette étude contribue à la littérature par une adaptation d'une classification mammaire tri-classe explicitement orientée vers le contexte ivoirien. Elle démontre également l'intérêt du gel de la BatchNormalization sur de petits volumes de données médicales, une approche facilement transférable. Enfin, l'ouverture du code source offre une base reproductible pour d'autres chercheurs. À plus long terme, la trajectoire de ce projet s'inscrit dans les ambitions du Plan National de Lutte contre le Cancer [2] en Côte d'Ivoire. Chaque cancer détecté à un stade précoce représente un pronostic radicalement amélioré. À l'échelle d'un pays où plus de 70 % des diagnostics interviennent à un stade avancé, un système de triage automatisé et éthiquement responsable peut avoir un impact populationnel majeur. C'est avec cette volonté d'allier rigueur algorithmique, humilité clinique et conscience des réalités du terrain que ce travail a été conduit. Il ne s'agit pas de remplacer le radiologue, mais d'offrir un premier jalon vers une imagerie médicale plus accessible et équitable.

RÉFÉRENCES

- [1] OMS/IARC. (2024). Côte d'Ivoire Fact Sheet, GLOBOCAN 2024.
- [2] Programme National de Lutte contre le Cancer — Côte d'Ivoire. (2022). Plan Stratégique National de Lutte contre le Cancer 2022–2025. Abidjan : Ministère de la Santé, de l'Hygiène Publique et de la Couverture Maladie Universelle.
- [3] Al-Dhabyani, W., Gomaa, M., Khaled, H., & Fahmy, A. (2020). Dataset of breast ultrasound images. *Data in Brief*, 28, 104863.
- [4] Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 4700–4708.
- [5] Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2980–2988.
- [6] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 618–626.
- [7] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778.
- [8] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, PMLR 97, 6105–6114.
- [9] Dosovitskiy, A., et al. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR)*.
- [10] Zhang, H., Cissé, M., Dauphin, Y. N., & Lopez-Paz, D. (2018). Mixup: Beyond empirical risk minimization. *International Conference on Learning Representations (ICLR)*.
- [11] Yun, S., Han, D., Oh, S. J., Chun, S., Choe, J., & Yoo, Y. (2019). CutMix: Training strategy to train stronger classifiers with localizable features. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 6023–6032.

- [12] Raza, A., et al. (2023). DeepBreastCancerNet: A Novel Deep Learning Model for Breast Cancer Detection Using Ultrasound Images. *Applied Sciences*, 13(4), 2082. DOI: 10.3390/app13042082.
- [13] Shen, L., Margolies, L. R., Rothstein, J. H., Fluder, E., McBride, R., & Sieh, W. (2019). Deep learning to improve breast cancer detection on screening mammography. *Scientific Reports*, 9, 12495.
- [14] McKinney, S. M., Sieniek, M., Godbole, V., Godwin, J., Antropova, N., Ashrafian, H., ... Shetty, S. (2020). International evaluation of an AI system for breast cancer screening. *Nature*, 577, 89–94.
- [15] Ferlay, J., Ervik, M., Lam, F., Laversanne, M., Colombet, M., Mery, L., ... Bray, F. (2024). *Global Cancer Observatory: Cancer Today*. Lyon: International Agency for Research on Cancer.
- [16] Tice, J. A., Cummings, S. R., Smith-Bindman, R., Ichikawa, L., Barlow, W. E., & Kerlikowske, K. (2008). Using clinical factors and mammographic breast density to estimate breast cancer risk: development and validation of a new predictive model. *Annals of Internal Medicine*, 148(5), 337–347.
- [17] Wanders, J. O., Holland, K., Veldhuis, W. B., Mann, R. M., Pijnappel, R. M., Peeters, P. H., ... Karssemeijer, N. (2017). Volumetric breast density affects performance of digital screening mammography. *Breast Cancer Research and Treatment*, 162(1), 95–103.
- [18] Loeffler, M. D., & Kabba, M. (2022). Breast imaging and cancer in sub-Saharan Africa: a systematic review. *The Breast*, 61, 30–38.
- [19] Woo, S., Park, J., Lee, J.-Y., & Kweon, I. S. (2018). CBAM: Convolutional block attention module. *Proceedings of the European Conference on Computer Vision (ECCV)*, 3–19.
- [20] Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., ... Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60–88.
- [21] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1), 1929–1958.
- [22] Loshchilov, I., & Hutter, F. (2017). SGDR: Stochastic gradient descent with warm restarts. *International Conference on Learning Representations (ICLR)*.

- [23] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 234–241.
- [24] Mammographic density and breast cancer risk among Black American women. PubMed. <https://pubmed.ncbi.nlm.nih.gov/39425554/>
- [25] Racial differences in mammographic breast density. PubMed. <https://pubmed.ncbi.nlm.nih.gov/12879477/>
- [26] Sawyer-Lee, R. et al. (2016). Curated breast imaging subset of digital database for screening mammography (CBIS-DDSM). *The Cancer Imaging Archive*.
- [27] Moreira, I. C. et al. (2012). INbreast: Toward a full-field digital mammographic database. *Academic Radiology*, 19(2), 236-248.
- [28] Amadou, A. et al. (2021). Breast cancer in Africa: a review. *The Lancet Global Health*.
- [29] Madhu, G. et al. (2024). UCapsNet: A Two-Stage Deep Learning Model Using U-Net and Capsule Network for Breast Cancer Segmentation and Classification in Ultrasound Imaging. *Cancers*, 16.
- [30] Fiaz, A. et al. (2024). A deep fusion-based vision transformer for breast cancer classification. *Healthcare Technology Letters*, 11, 471-484.
- [31] Kacher, A. et al. (2026). Tri-ResNet: A Parallel Multi-Branch and Transfer Learning Triple-Input Model for Breast Cancer Detection and Classification. *Vietnam Journal of Computer Science*.
- [32] Ogundokun, R. O. et al. (2026). CAE-StackedNet: A Hybrid Convolutional Autoencoder and Stacked Ensemble Framework for Histopathological Breast Cancer Image Classification. *Annals of Data Science*.

ANNEXES

Annexe A : Code source (lien repository)

Cette annexe regroupe les éléments permettant de reproduire intégralement les expériences décrites dans le mémoire :

- lien vers le dépôt Git (GitHub, GitLab ou autre) contenant le code source du projet ;
- principaux scripts Python :

- train_advanced.py : script d'entraînement (phases 1 et 2, callbacks, sauvegardes)
- augmentation.py : gestion des prétraitements et de l'augmentation (CLAHE, Mixup)
- focal_loss.py : implémentation de la Focal Loss pondérée
- calibrate_exp4.py : calibration des seuils et évaluation post-entraînement
- instructions succinctes d'exécution (version de Python, dépendances, commande de lancement).

Le code source complet de ce travail, incluant les scripts d'entraînement, d'augmentation de données et de calibration, est disponible sous licence libre à l'adresse suivante : <https://github.com/yaman1444/master-research.git>

Annexe B : Métriques complètes et courbes ROC

Cette annexe fournit les détails chiffrés complémentaires qui ne tiennent pas dans le corps du texte :

- tableaux complets des métriques retraçant l'évolution depuis le modèle de base (DenseNet-121) jusqu'au modèle optimal (EfficientNet-B0) : accuracy, precision, recall, F1 par classe, F1 macro ;
- courbes ROC par classe (normal, bénin, malin) pour la baseline et le modèle optimal ;
- éventuellement les courbes Precision-Recall.

Par exemple :

Tableau B.1 – Détails de l'évolution des métriques par classe

Classe	Métrique	Baseline (DenseNet-121)	EfficientNet-B0 (Standard)	EfficientNet-B0 (Fail-Safe)
Bénin	Précision	74,0 %	92,9 %	93,9 %
	Recall	88,1 %	78,8 %	69,7 %
	F1-score	0,81	0,85	0,80
Malin	Précision	73,0 %	71,8 %	62,5 %

	Recall	77,4 %	90,3 %	96,8 %
	F1-score	0,75	0,80	0,76
Normal	Précision	89,0 %	77,3 %	80,0 %
	Recall	63,0 %	85,0 %	80,0 %
	F1-score	0,74	0,81	0,80
Macro avg	Accuracy	81,3 %	82,9 %	78,6 %
	F1 macro	0,79	0,82	0,79

(Note : les valeurs de la colonne Fail-Safe reflètent le compromis clinique assumé : baisse de précision globale au profit d'un rappel malin maximal pour la sécurité des patientes).

Annexe C : Heatmaps Grad-CAM

Cette annexe présente des exemples supplémentaires de visualisations Grad-CAM obtenues avec le modèle EfficientNet-B0 final. Ces cartes de chaleur permettent de confirmer que le réseau se focalise sur les zones d'intérêt clinique (masses, irrégularités de contours) pour établir son diagnostic.

Figure C.1 - Visualisation Grad-CAM sur une lésion maligne (Malin). La zone d'activation (rouge) correspond précisément à la masse tumorale infiltrante, validant la pertinence spatiale de la décision.

Figure C.2 - Visualisation Grad-CAM sur une lésion bénigne (Bénin). Le modèle identifie une zone suspecte plus restreinte, cohérente avec une anomalie architecturale précoce. Figure C.3 – Visualisation Grad-CAM sur un tissu normal

Figure C.3 - Visualisation Grad-CAM sur un tissu normal. On observe une absence de foyer d'activation intense, confirmant le caractère non suspect de l'image.

LISTE DES FIGURES

Figure 1.1 - Charge du cancer du sein en Côte d'Ivoire (GLOBOCAN 2024)

Figure 1.2 - Contraintes d'infrastructure de dépistage (nombre de mammographes par population)

Figure 1.3 -illustration schématique de la classification BI-RADS des microcalcifications

Figure 1.4 -Schéma des tissus mammaires denses (BI-RADS C et D) et impact sur la visibilité des lésions

Figure 2.1 - Exemples d'images issues des datasets CBIS-DDSM, INbreast et BUSI

Figure 2.2 - Schéma simplifié de l'architecture DenseNet-121

Figure 2.3 - illustration des connexions denses au sein d'un dense block

Figure 2.4 - Visualisation d'un exemple de carte Grad-CAM en imagerie mammaire

Figure 3.1 - Répartition du dataset en ensembles d'entraînement, validation et test (1 580 images)

Figure 3.2 - Déséquilibre des classes dans l'ensemble d'entraînement (normal / bénin / malin)

Figure 3.3 - Schéma du pipeline de prétraitement (redimensionnement, normalisation, CLAHE, Mixup)

Figure 3.4 - Vue d'ensemble de l'architecture avec tête de classification à 3 classes

Figure 3.5 - Historique d'entraînement : courbes de loss et d'AUC sur train / validation

Figure 4.1 - Historique d'entraînement de l'EfficientNet-B0 (Courbes d'Accuracy et de Loss)

Figure 4.2 - Matrice de Confusion (Seuil Standard - Argmax) du modèle EfficientNet-B0

Figure 4.3 - Évolution de la matrice de confusion après calibration clinique (Fail-Safe)

Figure 4.4 - Prédiction Grad-CAM sur une lésion de stade bénin

Figure 4.5 - Prédiction Grad-CAM sur une lésion de stade malin

Figure 4.6 - Prédiction Grad-CAM sur un sein normal

Figure 5.1 - Exemple de cascade U-Net + EfficientNet-B0 : Image originale

Figure 5.2 - Exemple de cascade U-Net + EfficientNet-B0 : Masque binaire généré par U-Net

Figure 5.3 - Exemple de cascade U-Net + EfficientNet-B0 : Image masquée soumise au classifieur

Figure B.1 - Courbes ROC par classe pour la baseline DenseNet-121

Figure B.2 - Courbes ROC par classe pour le modèle optimal EfficientNet-B0

Figure C.1 - Heatmaps Grad-CAM supplémentaires pour des cas correctement classés

Figure C.2 - Heatmaps Grad-CAM pour des cas mal classés (faux positifs / faux négatifs)

LISTE DES TABLEAUX

Tableau 1.1 - Charge du cancer du sein chez la femme en Côte d'Ivoire (GLOBOCAN 2024)

Tableau 1.2 - Contraintes infrastructurelles et organisationnelles du dépistage en Côte d'Ivoire

Tableau 1.3 - Classification BI-RADS des microcalcifications et probabilité de malignité

Tableau 1.4 - Tendances de densité mammaire (BI-RADS C/D) selon les populations

Tableau 2.1 - Principaux jeux de données en cancer du sein (CBIS-DDSM, INbreast, BUSI)

Tableau 2.2 - Caractéristiques détaillées du dataset BUSI

Tableau 2.3 - Principales familles d'architectures CNN utilisées en imagerie mammaire

Tableau 2.4 - Stratégies de gestion du déséquilibre des classes (Focal Loss, oversampling, seuils)

Tableau 2.5 - Méthodes XAI courantes pour les CNN (Grad-CAM, Grad-CAM++, SHAP)

Tableau 3.1 - Répartition globale du dataset (train / validation / test)

Tableau 3.2 - Distribution des classes dans l'ensemble d'entraînement

Tableau 3.3 - Résumé des hyperparamètres d'entraînement (LR, batch size, gamma, alpha)

Tableau 3.4 - Mécanismes de reproductibilité mis en place (scripts, seeds, checkpoints)

Tableau 4.1 - Comparaison des performances finales sur le jeu de test (117 images)

Tableau 4.2 - Synthèse de l'impact de la calibration clinique sur EfficientNet-B0

Tableau 5.1 - Comparaison des performances de l'architecture en cascade

Tableau B.1 - Détails de l'évolution des métriques par classe

LISTE DES ABRÉVIATIONS

AUC : Area Under the Curve (surface sous la courbe ROC)

AUROC : Area Under the Receiver Operating Characteristic Curve

BI-RADS : Breast Imaging Reporting and Data System

CAD : Computer-Aided

Detection CADx : Computer-Aided Diagnosis

CBAM : Convolutional Block Attention Module

CBIS-DDSM : Curated Breast Imaging Subset of the Digital Database for Screening Mammography

CHU : Centre Hospitalier Universitaire

CLAHE : Contrast Limited Adaptive Histogram Equalization

CNN : Convolutional Neural Network

CPU : Central Processing Unit

DCIS : Ductal Carcinoma In Situ

DL : Deep Learning

FFDM : Full-Field Digital Mammography

FN : False Negative (faux négatif)

FP : False Positive (faux positif)

FPR : False Positive Rate

F1 : F1-score (moyenne harmonique précision / recall)

GPU : Graphics Processing Unit

Grad-CAM : Gradient-weighted Class Activation Mapping

IA : Intelligence Artificielle

JSON : JavaScript Object Notation

LR : Learning Rate (taux d'apprentissage)

ML : Machine Learning

NPV : Negative Predictive Value

PPV : Positive Predictive Value

ReLU : Rectified Linear Unit

ROC : Receiver Operating Characteristic

SGD : Stochastic Gradient Descent

SOTA : State Of The Art

TN : True Negative (vrai négatif)

TP : True Positive (vrai positif)

TPR : True Positive Rate (recall / sensibilité)

TTA : Test-Time Augmentation

UVCI : Université Virtuelle de Côte d'Ivoire

ViT : Vision Transformer

XAI : eXplainable Artificial Intelligence