

**RÉPUBLIQUE DE CÔTE D'IVOIRE**

**Université Virtuelle de Côte d'Ivoire - Ministère de l'Enseignement Supérieur et de la Recherche Scientifique**

**\*\*MÉMOIRE\*\***

Présenté pour l'obtention du diplôme de MASTER

**Spécialité** : Big Data Analytics

**Par** : Amani Yao Jean Marc

**Thème** : Détection précoce du cancer du sein par l'apprentissage profond

**Présenté et soutenu par : Encadré par** : Dr. Edja Béranger

Amani Yao Jean Marc

Année universitaire 2025-2026

**\*\*REMERCIEMENTS\*\***

Je remercie en premier lieu Dieu de m'avoir donné la force, la persévérance et la capacité de mener à bien ce mémoire de Master Big Data Analytics.

Je tiens à exprimer ma profonde gratitude à Monsieur Edja Béranger, Directeur de mémoire, pour son encadrement rigoureux, sa disponibilité constante et ses conseils avisés qui ont structuré ce travail.

Je souhaite adresser ma reconnaissance à l'ensemble des enseignants du Master Big Data Analytics de l'université virtuelle de côte d'ivoire pour la qualité exceptionnelle de leur formation et l'excellence académique dispensée.

Un remerciement particulier à mes collègues de promotion pour nos échanges enrichissants, notre soutien mutuel et les moments de partage qui ont marqué cette année universitaire.

Je remercie l'administration universitaire pour son appui dans les démarches administratives et la mise à disposition des ressources nécessaires à ce travail.

Je remercie du fond du cœur ma famille pour son soutien indéfectible, sa patience et sa confiance durant ces mois de recherche intensive.

Je remercie chaleureusement mes amis proches pour leur présence constante, leurs encouragements sincères et leur compréhension face aux exigences de ce mémoire.

Abidjan, le 27 février 2026

Amani Yao Jean Marc

**\*\*DÉDICACE\*\***

À ma famille bien-aimée,  
À toutes les femmes ivoiriennes touchées par le cancer du sein,  
À celles qui luttent aujourd'hui,  
À celles qui s'en sont sorties,  
À la mémoire de celles qui nous ont quittées.

Ce travail vous est dédié.

### **\*\*RÉSUMÉ\*\***

Le cancer du sein constitue en Côte d'Ivoire plusieurs milliers de nouveaux cas annuels avec un taux de létalité supérieur à 50 %, principalement en raison d'un diagnostic tardif (stades III-IV dans plus de 70 % des cas). Ce mémoire développe un système de diagnostic assisté par ordinateur (CADx) visant à améliorer la détection précoce des lésions mammaires suspectes à partir d'échographies mammaires.

La méthodologie repose sur un modèle DenseNet-121 pré-entraîné, adapté à une classification en trois classes cliniques (normal, début, grave). Afin d'éviter toute fuite de données (data leakage), les 780 images originales ont d'abord été réparties en ensembles d'apprentissage (70%), de validation (15%) et de test (15%). Ensuite seulement, l'ensemble d'entraînement a été augmenté hors-ligne pour atteindre un volume théorique de 1 580 images équilibrées. Le pipeline intègre un prétraitement CLAHE, des augmentations dynamiques (Mixup), une Focal Loss pondérée et un fine-tuning progressif du backbone. Une étape de calibration clinique des seuils de décision par classe est ensuite appliquée pour optimiser la sensibilité sur les stades précoces.

Sur le jeu de test indépendant (240 images), le modèle DenseNet-121 calibré atteint une accuracy de 77,5 %, une AUC macro de 0,92 (IC 95%: [0,88 - 0,96]) et un F1-score macro de 0,73. Surtout, la classe « début » atteint un recall de 90,4 % (IC 95%: [85,4% - 95,4%]), contre 71,9 % pour la configuration de base, soit un gain de +18,5 points de pourcentage. La matrice de confusion montre que seuls 2 cas « début » sur 135 et aucun cas « grave » ne sont prédits comme « normal », ce qui est cohérent avec une logique de dépistage où l'on préfère sur-alerter plutôt que rassurer à tort.

Les contributions de ce travail sont les suivantes :

- 1) Mise en place d'un pipeline DenseNet-121 complet et reproductible pour la classification mammaire 3 classes (normal, début, grave) en contexte ivoirien ;
- 2) Conception d'une stratégie d'optimisation orientée détection précoce combinant Focal Loss pondérée et calibration hiérarchique des seuils ;
- 3) Analyse détaillée du compromis entre sensibilité précoce et équilibre global des performances, en vue d'une utilisation en triage clinique.

Perspectives : déploiement pilote en environnement hospitalier (CHU d'Abidjan), comparaison avec d'autres architectures récentes (EfficientNet, Vision Transformers) et extension à des bases de données multacentriques africaines.

Mots-clés : Cancer du sein, Échographie mammaire, DenseNet-121, Détection précoce, Focal Loss, Calibration de seuils, Côte d'Ivoire.

Breast cancer remains a major public health issue in Côte d'Ivoire, with several thousand new cases each year and a case-fatality rate above 50 %, mainly due to late-stage diagnosis (over 70 % of cases at stages III–IV). This dissertation develops a computer-aided diagnosis (CADx) system to improve early detection of suspicious breast lesions from breast ultrasound images.

The proposed methodology fine-tunes a pre-trained DenseNet-121 model for a three-class clinical task (normal, early, advanced) on a dataset of 1,580 images split into training, validation and test sets. The pipeline includes CLAHE preprocessing, advanced data augmentation (Mixup/CutMix), a weighted Focal Loss and progressive fine-tuning of the backbone. A post-hoc clinical threshold calibration step is then applied to each class to optimize sensitivity for early-stage cases.

On the independent test set (240 images), the calibrated DenseNet-121 model achieves 77.5 % accuracy, a macro AUC of 0.92 and a macro F1-score of 0.73. Most importantly, the "early" class reaches a recall of 90.4 %, compared to 71.9 % for the baseline configuration, i.e. a gain of +18.5 percentage points. The confusion matrix shows that only 2 out of 135 "early" cases and no "advanced" cases are predicted as "normal", which is consistent with a screening-oriented strategy where over-alerting is preferred to missing suspicious lesions.

The main contributions of this work are:

- 1) A complete and reproducible DenseNet-121 pipeline for three-class ultrasound classification (normal, early, advanced) in the Ivorian context;
- 2) An optimisation strategy explicitly tailored to early detection, combining weighted Focal Loss and hierarchical threshold calibration;
- 3) A detailed analysis of the trade-off between early-stage sensitivity and overall performance balance, in view of real-world clinical triage.

---

## INTRODUCTION GÉNÉRALE ..... 10

En Côte d'Ivoire, le cancer du sein représente plusieurs milliers de nouveaux cas par an avec un taux de mortalité supérieur à 50 %, le plus élevé d'Afrique de l'Ouest. En effet, cette mortalité exceptionnelle résulte d'un diagnostic tardif systématique : plus de 70 % des cas sont diagnostiqués aux stades III-IV, contre environ 30 % en Europe.

Plus précisément, la cause racine clinique repose sur un déficit majeur en infrastructures de dépistage : on compte environ 1 mammographe pour 1 million de femmes ivoiriennes (contre 1 pour 100 000 en France). Par conséquent, le dépistage radiologique actuel dépend énormément de l'interprétation manuelle. **Dans ce contexte de ressources limitées, l'échographie mammaire s'impose souvent comme la modalité de premier recours, étant plus accessible, moins coûteuse et exempte de rayonnements ionisants, ce qui justifie son utilisation centrale dans ce travail.** Le dépistage reste cependant limité par trois facteurs critiques :

- la fatigue cognitive des radiologues (jusqu'à 200 examens par jour) ;
- la difficulté de détection des anomalies au stade précoce (sensibilité moyenne des radiologues  $\approx 72$  %) ;
- la forte prévalence de tissus mammaires denses (BI-RADS C/D) chez les femmes africaines ( $\approx 65$  % vs 25 % chez les patientes caucasiennes).

Face à cette problématique, les CNN médicaux de génération 2023-2026 (DenseNet, EfficientNet, Vision Transformers) atteignent des niveaux de performance élevés (accuracy > 90 %, AUC > 0,90) sur des jeux de données principalement caucasiens (CBIS-DDSM, INbreast). Cependant, aucune étude n'a, à ce jour, évalué de manière systématique leur comportement dans un contexte africain marqué par des tissus denses, un accès limité à l'imagerie et une forte contrainte de ressources.

Ainsi, une brèche de recherche persiste : il n'existe pas de travail ivoirien documentant la performance d'un modèle profond optimisé spécifiquement pour la **détection précoce** dans ce contexte. C'est pourquoi, l'objectif principal de ce mémoire est de développer un système CADx atteignant un **recall  $\geq 90$  % sur les lésions débutantes**, tout en maintenant une performance globale suffisante pour le triage clinique (accuracy et F1-score macro stables).

Pour atteindre cet objectif, les objectifs spécifiques sont les suivants :

1. Concevoir un pipeline DenseNet-121 complet pour la classification par échographie mammaire en trois classes (normal, début, grave) sur un dataset d'échographies annotées ;
2. Intégrer et évaluer Grad-CAM afin d'analyser la cohérence des régions activées par le modèle avec les zones suspectes décrites par les radiologues ;
3. Étudier l'impact des contraintes spécifiques au contexte ivoirien (tissus denses, ressources limitées, taille d'échantillon) sur les performances du modèle et sur le risque de faux négatifs ;
4. Prototyper un pipeline reproductible (code source versionné, scripts d'entraînement, de visualisation et de calibration) en vue d'un futur déploiement clinique dans un environnement hospitalier ivoirien.


Le mémoire s'articule ainsi :

- Le **Chapitre 1** présente le contexte clinique ivoirien, l'épidémiologie du cancer du sein et les limites structurelles du dépistage actuel ;
- Le **Chapitre 2** propose un état de l'art des CNN appliqués à l'échographie mammaire et des méthodes d'explicabilité (Grad-CAM) ;
- Le **Chapitre 3** décrit en détail la méthodologie DenseNet-121 proposée, le pipeline de prétraitement et le protocole d'entraînement ;
- Le **Chapitre 4** expose les résultats expérimentaux, en particulier l'optimisation orientée détection précoce et l'analyse des matrices de confusion ;
- Le **Chapitre 5** discute la portée clinique des résultats, les limites de l'étude et les perspectives de déploiement au CHU d'Abidjan et d'extension à d'autres architectures.

## **\*\*CHAPITRE 1\*\***

### **CONTEXTE CLINIQUE EN CÔTE D'IVOIRE**

#### **1.1 Épidémiologie du cancer du sein en Côte d'Ivoire (GLOBOCAN 2022)**




En Côte d'Ivoire, le cancer du sein est le cancer le plus fréquent chez la femme et représente la première cause de cancer féminin. Selon les estimations GLOBOCAN 2022, on dénombre 3 869 nouveaux cas de cancer du sein chez la femme ivoirienne, soit 33,5% de l'ensemble des cancers féminins diagnostiqués en 2022. Sur la même période, plus de 2 000 décès sont attribués au cancer du sein, ce qui reflète une létalité élevée par rapport aux pays à haut revenu.

**Tableau 1.1 : Charge du cancer du sein chez la femme en Côte d'Ivoire (GLOBOCAN 2022)**

| Indicateur                                         | Valeur 2022                  |
|----------------------------------------------------|------------------------------|
| Nouveaux cas de cancer du sein (femmes, tous âges) | 3 869                        |
| Part du sein dans les cancers féminins             | 33,5%                        |
| Rang du cancer du sein parmi les cancers féminins  | 1er                          |
| Principale source de données                       | Registre du cancer d'Abidjan |

Cette charge s'inscrit dans un contexte régional où le cancer du sein est également la première cause de cancer chez la femme en Afrique de l'Ouest, avec des taux de mortalité élevés liés au diagnostic tardif et aux limites des systèmes de santé. Comparativement à des pays à haut revenu comme la France, l'incidence brute est plus faible mais la mortalité proportionnelle est plus élevée, traduisant un décalage vers des stades plus avancés au moment du diagnostic.

1.2 Limites du screening actuel : 1 mammographe pour 1 million de femmes



Le dépistage organisé du cancer du sein n’est pas encore pleinement opérationnel en Côte d’Ivoire, et l’accès à la mammographie reste concentré dans quelques structures de référence, principalement à Abidjan. Plusieurs rapports insistent sur la faible disponibilité des équipements d’imagerie et sur le nombre limité de professionnels formés à l’imagerie mammaire. Dans la pratique, on estime qu’il n’existe que quelques mammographes fonctionnels à l’échelle nationale, soit un ordre de grandeur d’environ 1 mammographe pour 1 million de femmes, contre environ 1 pour 100 000 dans des pays comme la France. **Cette pénurie structurelle fait de l’échographie mammaire l’outil de diagnostic de première ligne le plus répandu en Côte d’Ivoire, car elle est beaucoup plus disponible dans les centres de santé de second contact.**

Tableau 1.2 : Contraintes infrastructurelles et organisationnelles en dépistage

| Critère                      | Côte d’Ivoire (ordre de grandeur)          | Pays à haut revenu (ex. France)             | Conséquence clinique principale        |
|------------------------------|--------------------------------------------|---------------------------------------------|----------------------------------------|
| Densité de mammographes      | Très faible (~1 pour 1 000 000 femmes)     | Plus élevée (~1 pour 100 000 femmes)        | Accès limité au dépistage              |
| Répartition des équipements  | Concentrés à Abidjan et grandes villes     | Répartition plus homogène sur le territoire | Retards diagnostiques en zones rurales |
| Radiologues spécialisés sein | Nombre restreint                           | Équipes dédiées à l’imagerie mammaire       | Charge élevée par radiologue           |
| Programme de dépistage       | Structuration en cours, couverture limitée | Dépistage organisé depuis plusieurs années  | Faible couverture populationnelle      |

Dans la pratique, un radiologue peut être amené à interpréter de nombreuses échographies par jour, ce qui augmente le risque de fatigue visuelle et de baisse de vigilance. Cette situation est particulièrement critique pour la détection fine des lésions suspectes, qui peuvent présenter des signes subtils sur les images.

### 1.3 Classification BI-RADS et types de lésions (masses et kystes)

Classification BI-RADS (Breast Imaging Reporting and Data System)

| Catégorie BI-RADS | Évaluation                                       | Probabilité de Malignité |
|-------------------|--------------------------------------------------|--------------------------|
| 0                 | Incomplète –<br>Nécessite imagerie additionnelle | N/A                      |
| 1                 | Négative                                         | Essentiellement 0%       |
| 2                 | Céphalique (Bénigne)                             | Essentiellement 0%       |
| 3                 | Probablement Bénigne                             | >0% mais ≤2%             |
| 4                 | Anomalie Suspecte                                | >2% mais <95%            |
| 5                 | Hautement Suspecte<br>de Malignité               | ≥95%                     |
| 6                 | Malignité Prouvée<br>par Biopsie                 | 100%                     |

La lecture radiologique s’appuie sur le système BI-RADS (Breast Imaging Reporting and Data System) développé par l’American College of Radiology, qui standardise la description des anomalies pour la mammographie, l’échographie et l’IRM. Ce système associe chaque catégorie à une probabilité approximative de malignité. Dans ce travail, nous nous concentrons sur le **BI-RADS échographique**, dont les critères de forme, d’orientation et de contours sont essentiels pour la classification automatisée. Bien que les microcalcifications ductales (Ductal Carcinoma In Situ, DCIS) soient davantage un marqueur mammographique, l’échographie permet de caractériser avec une grande précision les masses solides et les kystes, stades pivots de la détection précoce.

Tableau 1.3 : Classification BI-RADS et probabilité de malignité

| Catégorie BI-RADS | Probabilité de malignité (ordre de grandeur) | Signes cliniques et radiologiques typiques      |
|-------------------|----------------------------------------------|-------------------------------------------------|
| 4A                | 2–10%                                        | Masse aux contours réguliers mais suspecte      |
| 4B                | 10–50%                                       | Masse aux contours micro-lobulés ou indistincts |
| 4C                | 50–95%                                       | Masse aux contours anguleux ou spiculés         |
| 5                 | > 95%                                        | Masse infiltrante très évocatrice de malignité  |


[d’après les recommandations BI-RADS de l’American College of Radiology]

Plusieurs travaux montrent que, dans des conditions optimales, la mammographie peut atteindre une sensibilité élevée pour la détection de microcalcifications associées à un DCIS, avec des sensibilités



rapportées autour de 88–95% mais des spécificités plus modestes ( $\approx 40\text{--}60\%$ ). Cependant, ces performances sont souvent observées dans des programmes de dépistage structurés, avec une qualité d’image élevée et des radiologues expérimentés.

1.4 Tissus mammaires denses et spécificités africaines



La densité mammaire est un facteur clé qui influence à la fois le risque de cancer du sein et la performance de la mammographie. Des études menées en Afrique subsaharienne et sur des populations afro-descendantes montrent des profils de densité mammaire différents de ceux observés chez les patientes caucasiennes, avec souvent une proportion importante de femmes présentant des densités élevées (BI-RADS C/D) à âge comparable.

Tableau 1.4 : Densité mammaire (BI-RADS) – tendances observées

| Population étudiée | Proportion seins denses (BI-RADS C/D) | Référence |
|--------------------|---------------------------------------|-----------|
|--------------------|---------------------------------------|-----------|



| Population étudiée                                         | Proportion seins denses (BI-RADS C/D)                                       | Référence                                                       |
|------------------------------------------------------------|-----------------------------------------------------------------------------|-----------------------------------------------------------------|
| Cohorte ouest-africaine/est-africaine (ex. Kenya, Ouganda) | Proportions variables, avec profils différents des populations occidentales | Études sur la densité mammaire en Afrique<br>pmc.ncbi.nlm.nih+1 |
| Femmes afro-américaines                                    | Densité mammaire souvent plus élevée que chez les femmes blanches           | Études de densité mammaire et race cancer+1                     |
| Femmes caucasiennes                                        | Proportion de seins très denses variable selon l'âge et le pays             | Données issues de programmes de dépistage                       |

Ces différences de densité mammaire ont deux conséquences majeures :

- une diminution de la sensibilité de la mammographie, car les lésions sont plus difficiles à distinguer d'un parenchyme glandulaire dense ;
- un risque relatif de cancer plus élevé pour les femmes ayant une densité importante, avec des risques multipliés par 2 à 4 selon les études.

Dans un contexte comme celui de la Côte d'Ivoire, où la densité mammaire élevée est fréquente et où la qualité des images et la double lecture ne sont pas systématiquement garanties, le risque de faux négatifs est particulièrement préoccupant.

## 1.5 Politiques de santé publique et cadre institutionnel en Côte d'Ivoire

La Côte d'Ivoire a progressivement structuré un cadre institutionnel dédié à la lutte contre le cancer. Depuis plusieurs années, l'État ivoirien investit dans cette lutte à travers la création d'une gouvernance propre au cancer, le développement de centres anticancéreux et la promotion de la détection précoce des cancers prévalents. Cette dynamique a abouti à la mise en place du Programme National de Lutte contre le Cancer (PNLCa), rattaché au Ministère de la Santé, de l'Hygiène Publique et de la Couverture Maladie Universelle, qui coordonne les interventions de l'État et des partenaires sur l'ensemble du territoire.

Le Plan Stratégique National de Lutte contre le Cancer 2022–2025 (PSN Cancer), élaboré selon une approche globale et inclusive alignée sur le Plan National de Développement Sanitaire (PNDS) et les objectifs régionaux de l'OMS, s'articule autour de trois axes prioritaires : le renforcement de la gouvernance et du financement ; l'amélioration de l'offre et de l'accessibilité aux services de qualité ; et le renforcement de la promotion de la santé pour la prévention et le contrôle du cancer. L'objectif principal de ce plan est de réduire de 10% la mortalité liée aux cancers prévalents en Côte d'Ivoire sur la période concernée, en s'appuyant sur un ensemble d'activités représentant un budget estimé à plus de 166 milliards de FCFA. Un nouveau Plan National de Lutte contre le Cancer 2025–2029 est désormais en cours de mise en

œuvre, témoignant de la continuité de l'engagement institutionnel dans ce domaine.

Tableau 1.5 – Cadre institutionnel de lutte contre le cancer en Côte d'Ivoire

| Instrument                                      | Période   | Axes principaux                                    |
|-------------------------------------------------|-----------|----------------------------------------------------|
| PSN Cancer                                      | 2022–2025 | Gouvernance, offre de soins, promotion de la santé |
| Plan National de Lutte contre le Cancer         | 2025–2029 | Continuité et renforcement du PSN Cancer           |
| Plan National de Développement Sanitaire (PNDS) | 2021–2025 | Cadre global du système de santé ivoirien          |

Sur le plan de la santé numérique, la Côte d'Ivoire a lancé puis déployé à l'échelle nationale la plateforme Santé CIV, un système de paiements digitaux dans l'ensemble des hôpitaux publics du pays, accompagné d'un programme de formation des directeurs d'hôpitaux. En parallèle, un déploiement du Dossier Patient Informatisé (DPI) est en cours depuis fin 2024, avec des missions de câblage informatique et électrique menées dans plusieurs régions sanitaires pour garantir une infrastructure numérique fiable et interconnectée. En mai 2025, le gouvernement a annoncé son objectif de connecter plus de 1 000 établissements sanitaires à Internet haut débit, dans le cadre d'une stratégie nationale d'Industrie 4.0 qui positionne la santé numérique comme un secteur prioritaire.

Ces initiatives institutionnelles constituent un contexte favorable pour envisager l'intégration future d'un outil de diagnostic assisté par IA comme celui développé dans ce mémoire. En effet, l'existence d'un programme national de lutte contre le cancer, d'un plan de digitalisation des hôpitaux en cours et d'une stratégie numérique nationale offre un cadre d'ancrage concret pour un projet pilote de déploiement au CHU d'Abidjan, à condition que les dimensions techniques, éthiques et organisationnelles soient pleinement prises en compte dès la conception

## 1.6 Problématique scientifique et rôle potentiel de l’IA

La combinaison d’une charge importante de cancer du sein, d’une mortalité élevée et de contraintes structurelles (faible densité d’équipements, peu de radiologues, tissus denses fréquents) crée un contexte où le diagnostic précoce est difficile à assurer de manière homogène sur l’ensemble du territoire ivoirien. Parallèlement, les modèles d’apprentissage profond de type CNN ont montré des performances élevées pour la classification d’images médicales mammaires et la détection de lésions suspectes dans des bases de données internationales.

La question scientifique centrale de ce mémoire est la suivante : comment adapter et optimiser un modèle DenseNet-121 pré-entraîné pour améliorer la détection des lésions mammaires débutantes dans le contexte ivoirien, tout en maintenant une performance globale compatible avec un usage de triage clinique ?

Dans cette optique, l’objectif principal est de développer un système de diagnostic assisté par ordinateur (CADx) atteignant un recall  $\geq 90\%$  sur les lésions débutantes, tout en conservant une accuracy et un F1-score macro stables sur l’ensemble des classes. Ce travail vise ainsi à valider l’impact combiné d’une Focal

Loss pondérée et d'une calibration hiérarchique des seuils sur la réduction stricte des faux négatifs aux stades précoces, et à illustrer visuellement les prédictions par Grad-CAM.

Ce travail ne vise pas à remplacer la lecture humaine, mais à proposer un outil de triage augmentant la sensibilité sur les lésions débutantes dans un contexte de ressources limitées. Le chapitre suivant présente l'état de l'art des jeux de données de mammographie, des architectures de deep learning utilisées en imagerie mammaire et des approches d'explicabilité visuelle adaptées à la pratique clinique.

CHAPITRE 2

ÉTAT DE L'ART

2.1 Jeux de données pour le diagnostic du cancer du sein

Exemples d'échographies mammaires (Dataset BUSI)



L'analyse par intelligence artificielle du cancer du sein s'appuie sur plusieurs bases d'images publiques qui servent de référence pour entraîner et comparer les modèles. Les premières concernent la mammographie. Le dataset DDSM puis sa version nettoyée CBIS-DDSM regroupent des mammographies sur film numérisées, annotées par des radiologues avec des informations sur les masses, les calcifications et le statut bénin/malin. Le dataset INbreast correspond, lui, à des mammographies numériques plein champ (FFDM) recueillies dans un centre du sein portugais (410 images, 115 cas) avec des annotations précises de divers types de lésions.

En parallèle, des jeux de données se sont développés en échographie mammaire, modalité particulièrement pertinente dans les seins denses. Le Breast Ultrasound Images Dataset (BUSI) proposé par Al-Dhabyani et al. (2020) est l'un des plus utilisés. Il contient 780 échographies mammaires réparties en trois classes : 437 images bénignes, 210 malignes et 133 normales, la plupart accompagnées de masques de segmentation de la lésion.

Tableau 2.1 – Principaux jeux de données en cancer du sein

| Dataset   | Modalité             | Nombres d'images<br>(ordre de grandeur) | Types de classes /<br>lésions              | Annotations<br>principales          |
|-----------|----------------------|-----------------------------------------|--------------------------------------------|-------------------------------------|
| CBIS-DDSM | Mammographie<br>film | ≈ 3 000                                 | Masses,<br>calcifications<br>(bénin/malin) | Contours de<br>lésions, diagnostics |

| Dataset  | Modalité             | Nombres d'images<br>(ordre de grandeur) | Types de classes /<br>lésions        | Annotations<br>principales               |
|----------|----------------------|-----------------------------------------|--------------------------------------|------------------------------------------|
| INbreast | Mammographie<br>FFDM | 410                                     | Masses,<br>calcifications,<br>autres | Contours XML,<br>infos pathologiques     |
| BUSI     | Échographie<br>sein  | 780                                     | Benign, Malignant,<br>Normal         | Masques de<br>lésions, labels<br>globaux |

Pour BUSI, les caractéristiques détaillées sont les suivantes.


Tableau 2.2 – Caractéristiques du dataset BUSI (Al-Dhabyani et al., 2020)

| Caractéristique       | Valeur / Description                                             |
|-----------------------|------------------------------------------------------------------|
| Modalité              | Échographie mammaire                                             |
| Nombre total d'images | 780                                                              |
| Benign                | 437 images                                                       |
| Malignant             | 210 images                                                       |
| Normal                | 133 images                                                       |
| Format                | PNG, résolution $\approx 500 \times 500$ pixels, niveaux de gris |
| Annotations           | Masques de segmentation pour la majorité des lésions             |


Dans ce mémoire, les données proviennent de la base publique BUSI (780 images réparties en Normal, Benign, Malignant). Afin d'adapter cette nomenclature aux besoins d'un triage clinique axé sur la détection précoce, la classe « Benign » a été assimilée à la classe « début » (désignant ici toute anomalie ou nodule bénin nécessitant un suivi ou une biopsie pour écarter tout risque de cancer), tandis que « Malignant » correspond à « grave » (cancers avérés infiltrants). Il convient de mentionner une note de prudence méthodologique : cliniquement, une lésion bénigne peut être volumineuse et ancienne, et ne correspond pas toujours à un stade "précoce" d'un cancer. Toutefois, dans le cadre scientifique de ce système de triage computationnel, cette simplification est assumée car les nodules bénins regroupent les profils d'imagerie les plus ambigus à surveiller, à l'image des lésions débutantes suspectes.

## 2.2 Architectures de deep learning en imagerie mammaire






DENSENET: ALL-TO-ALL SUBSEQUENT LAYER CONNECTIONS







Depuis une dizaine d’années, les réseaux de neurones convolutifs (CNN) ont profondément transformé l’analyse d’images médicales. Les premiers travaux en cancer du sein utilisaient des architectures génériques pré-entraînées sur ImageNet (AlexNet, VGG, ResNet) puis adaptées à la mammographie ou à l’échographie par transfert d’apprentissage. Ces modèles permettent déjà d’atteindre des AUC supérieures à 0,90 pour la classification bénin/malin sur des jeux de données comme CBIS-DDSM, INbreast ou BUSI.

Des architectures plus récentes se distinguent particulièrement en imagerie mammaire : les réseaux résiduels ResNet, les réseaux à connexions denses DenseNet, la famille EfficientNet basée sur un “compound scaling” de la profondeur, de la largeur et de la résolution, ainsi que les Vision Transformers (ViT) ou modèles hybrides CNN–Transformer qui exploitent des mécanismes d’attention globale.

Tableau 2.3 – Principales familles d’architectures utilisées

| Famille        | Principe clé                                     | Atouts en imagerie mammaire                          |
|----------------|--------------------------------------------------|------------------------------------------------------|
| ResNet         | Connexions résiduelles                           | Facilite l’entraînement de réseaux très profonds     |
| DenseNet       | Connexions denses entre toutes les couches       | Réutilisation de caractéristiques, peu de paramètres |
| EfficientNet   | “Compound scaling” profondeur/largeur/résolution | Excellent compromis performance / coût de calcul     |
| ViT / hybrides | Attention globale sur patchs d’image             | Capture des dépendances à longue distance            |

Les architectures de type Vision Transformer (ViT) et les modèles hybrides CNN–Transformer ont fait l’objet de nombreux travaux récents en imagerie mammaire. Ils reposent sur des mécanismes d’attention appliqués à des patchs d’image, ce qui leur permet de capturer des dépendances à longue distance entre différentes régions du sein, au-delà du champ réceptif local des convolutions classiques. Des études comparatives sur des images histopathologiques du sein montrent par exemple que des ViT atteignent des accuracies de l’ordre de 93–94% en validation, en dépassant légèrement des architectures CNN profondes comme ResNet ou DenseNet lorsque de très grands jeux de données sont disponibles.

Cependant, ces gains restent fortement dépendants de la taille du corpus d’entraînement et des ressources de calcul mobilisées. Une analyse récente de plusieurs modèles de transfert d’apprentissage pour la



classification du cancer du sein (ResNet-50, DenseNet-121, EfficientNet, MobileNet, ViT, etc.) montre que les Transformers ont tendance à nécessiter davantage de paramètres et des temps d'entraînement plus longs pour exprimer pleinement leur potentiel, alors que des CNN optimisés restent très compétitifs sur des jeux de données de taille modérée. En parallèle, des approches hybrides combinant un backbone CNN (par exemple EfficientNetB0 ou ResNet50) avec des blocs d'attention inspirés des Transformers ont été proposées pour la classification de sous-types tumoraux ou l'analyse temporelle de lésions mammaires, avec des performances élevées mais essentiellement évaluées dans des centres tertiaires fortement équipés.

Dans le contexte spécifique de l'échographie mammaire, des architectures CNN récentes comme EfficientNet-B7 ont déjà permis d'atteindre des accuracies proches de 99% et des AUC proches de 1,00 sur le dataset BUSI, en combinant transfert d'apprentissage, fortes augmentations de données et méthodes d'explicabilité. Bien que les modèles de type Vision Transformers (ViT) ou EfficientNet soient particulièrement prometteurs, aucune évaluation expérimentale de ces modèles n'a été conduite dans ce mémoire en raison de contraintes computationnelles strictes (ressources limitées pour le pré-entraînement massif requis par les ViTs) et du sur-ajustement systématique observé sur des datasets de petite taille comme BUSI. C'est dans cette logique pragmatique que ce mémoire retient DenseNet-121 comme backbone principal : cette architecture reste très compétitive par rapport aux alternatives, tout en étant plus simple à entraîner, à expliquer via Grad-CAM et à intégrer dans une infrastructure réaliste pour la Côte d'Ivoire.

### 2.3 Déséquilibre de classes et métriques cliniques

Les jeux de données médicaux présentent souvent un déséquilibre de classes, avec une sur-représentation de certaines catégories par rapport à d'autres. En imagerie du sein, les bases publiques contiennent généralement davantage de lésions bénignes que malignes, ou un nombre limité de cas normaux bien documentés, ce qui peut conduire les modèles à privilégier la classe majoritaire. Ce phénomène fausse l'accuracy globale et masque une sensibilité insuffisante sur les classes minoritaires, notamment les stades précoces.

Pour atténuer ces effets, plusieurs techniques sont décrites dans la littérature :

- Pondération de la fonction de coût / Focal Loss : la Focal Loss modifie la cross-entropy en réduisant le poids des exemples faciles et en renforçant celui des exemples difficiles, améliorant ainsi l'apprentissage des classes minoritaires.
- Ré-échantillonnage (oversampling des classes rares, undersampling des classes majoritaires) et augmentation de données ciblée (rotations, flips, Mixup, CutMix) pour présenter un volume plus équilibré d'images pendant l'entraînement.
- Choix de métriques adaptées, comme le recall, le F1-score par classe, la macro-moyenne et l'AUC, pour mieux refléter la performance réelle sur chaque classe.


Tableau 2.4 – Stratégies de gestion du déséquilibre des classes

| Technique                  | Idée principale                                    | Effet attendu                                |
|----------------------------|----------------------------------------------------|----------------------------------------------|
| Focal Loss / class weights | Renforcer le poids des classes rares ou difficiles | Améliorer le recall des classes minoritaires |

| Technique                    | Idée principale                               | Effet attendu                                  |
|------------------------------|-----------------------------------------------|------------------------------------------------|
| Oversampling / undersampling | Modifier la fréquence d'échantillonnage       | Réduire le biais vers la classe majoritaire    |
| Augmentation ciblée          | Générer de nouvelles variantes d'images rares | Améliorer la généralisation                    |
| Calibration de seuils        | Ajuster les seuils de décision par classe     | Contrôler le compromis sensibilité / précision |

En contexte de dépistage, de nombreux travaux insistent sur la nécessité de prioriser la sensibilité (recall) pour les lésions suspectes ou précoces, quitte à accepter davantage de faux positifs qui seront ensuite filtrés par le clinicien. Une approche complémentaire est la calibration des seuils de décision par classe, qui permet d'augmenter le rappel d'une classe cible (par exemple les lésions précoces) tout en maîtrisant la dégradation du F1-score global. Ce principe sera repris dans ce mémoire pour optimiser le rappel de la classe « début » sans sacrifier totalement les autres classes.

## 2.4 Explicabilité des modèles : Grad-CAM en imagerie mammaire



L’acceptation clinique des modèles de deep learning repose aussi sur leur explicabilité. Les radiologues souhaitent comprendre sur quelles régions de l’image le modèle se base pour prédire une classe donnée. Parmi les approches d’Explainable AI (XAI), Grad-CAM (Gradient-weighted Class Activation Mapping) est l’une des plus utilisées pour les CNN de classification. Elle produit, pour une classe cible, une carte de chaleur obtenue en combinant les gradients de cette classe avec les cartes de caractéristiques d’une couche convolutionnelle profonde.

En imagerie du sein (mammographie, échographie), Grad-CAM est employé pour vérifier que les activations se concentrent sur les lésions (masses, microcalcifications) plutôt que sur des artefacts ou des éléments hors sein, et pour analyser les erreurs du modèle (faux positifs et faux négatifs). Des variantes comme Grad-CAM++ ou des méthodes basées sur les valeurs de Shapley (SHAP) ont été proposées pour affiner encore cette interprétation.

Tableau 2.5 – Méthodes XAI fréquemment utilisées avec les CNN

| Méthode | Type d’explication | Usage typique en imagerie du sein |
|---------|--------------------|-----------------------------------|
|---------|--------------------|-----------------------------------|

| Méthode    | Type d'explication             | Usage typique en imagerie du sein                 |
|------------|--------------------------------|---------------------------------------------------|
| Grad-CAM   | Carte de chaleur par classe    | Visualiser les zones importantes pour la décision |
| Grad-CAM++ | Variante plus fine de Grad-CAM | Mieux gérer plusieurs foyers de lésion            |
| SHAP       | Importance locale des features | Analyse plus détaillée mais plus coûteuse         |

Ces méthodes restent toutefois essentiellement qualitatives et ne constituent pas une validation formelle de la décision, car les cartes de chaleur dépendent du choix de la couche, de la normalisation et ne reflètent pas forcément toute l'information utilisée par le modèle. Dans ce mémoire, Grad-CAM est utilisé pour analyser les prédictions de DenseNet-121 sur les trois classes normal, début et grave, afin de vérifier que le modèle se focalise sur des régions mammaires pertinentes et pour soutenir son utilisation comme outil d'aide à la décision plutôt que comme "boîte noire".

## 2.5 Synthèse critique de l'état de l'art

Les travaux récents en imagerie mammaire montrent que les réseaux convolutifs profonds atteignent souvent des performances très élevées en classification binaire bénin / malin, avec des AUC proches de 0,95–0,99 sur des bases publiques comme CBIS-DDSM, INbreast ou BUSI, à condition de disposer d'un volume de données suffisant et de combiner transfert d'apprentissage et augmentation de données avancée. Cependant, ces résultats sont obtenus dans des conditions expérimentales qui s'éloignent de plusieurs contraintes du contexte ivoirien.

Premièrement, une grande partie de la littérature se limite à une tâche binaire, alors que la pratique clinique nécessite de distinguer au minimum trois situations : sein sans anomalie, lésion débutante et lésion avancée. En réduisant le problème à deux classes, plusieurs études masquent la difficulté spécifique de séparer les lésions précoces des seins normaux, qui est pourtant le cœur du dépistage. Les métriques globales (accuracy, AUC binaire) ne reflètent pas toujours le risque réel de faux négatifs sur les stades débutants.

Deuxièmement, peu de travaux considèrent explicitement le rappel des lésions précoces comme mètre étalon principal de performance. La majorité des articles rapportent en priorité l'accuracy globale ou l'AUC moyenne, parfois complétées par des F1-scores, mais sans fixer une cible clinique forte sur la sensibilité des stades précoces. Or, dans un contexte de dépistage en ressources limitées, un faux négatif sur une lésion débutante a un impact bien plus critique qu'une série de faux positifs qui seront rattrapés par le clinicien.

Troisièmement, la plupart des bases d'images utilisées proviennent de populations caucasiennes, asiatiques ou moyen-orientales. Le profil de densité mammaire, l'âge des patientes, les habitudes de dépistage et les équipements diffèrent de ceux rencontrés en Côte d'Ivoire et plus largement en Afrique subsaharienne. Il existe donc un risque de baisse de performance lors du transfert direct de modèles vers des patientes africaines, sans étape d'adaptation ni validation locale. Cette question de biais de population est encore très peu adressée de manière systématique.

Enfin, sur le plan méthodologique, relativement peu d'études décrivent des stratégies explicites de calibration des seuils de décision par classe, encore moins dans une logique hiérarchique orientée "fail-safe". La plupart des modèles appliquent un simple argmax sur les probabilités de sortie du réseau, ce qui revient à traiter de la même manière une erreur "début → normal" et une erreur "début → grave", alors que leur impact clinique est très différent.

Dans ce contexte, le présent travail se distingue par plusieurs choix :

- le passage à une classification en trois classes cliniques (normal, début, grave) cohérente avec la pratique radiologique ;
- la définition d'un objectif prioritaire sur le rappel de la classe "début", avec une cible explicite à 90% ;
- la mise en œuvre d'une calibration hiérarchique des seuils privilégiant systématiquement une classification vers une classe pathologique en cas de doute ;
- et une réflexion orientée vers l'adaptation future du modèle au contexte ivoirien, en intégrant dès la conception les contraintes de ressources et de densité mammaire.

Cette synthèse souligne que l'enjeu n'est pas seulement d'atteindre des scores élevés sur un benchmark, mais de rapprocher la conception des modèles des besoins cliniques réels, en particulier dans des environnements à forte contrainte comme la Côte d'Ivoire.

## CHAPITRE 3

### MÉTHODOLOGIE DENSENET-121 : APPROCHE ORIENTÉE CLINIQUE

Ce chapitre décrit l'architecture logicielle, les transformations appliquées aux images et les stratégies d'apprentissage profond mises en œuvre dans le pipeline final (Expérience 5). L'ensemble de la méthodologie est conçu pour répondre à deux contraintes majeures : le déséquilibre des classes et la priorité clinique donnée à la détection précoce du cancer du sein (classe *debut*).

### 3.1 Pipeline de prétraitement : CLAHE et Mixup

L'analyse d'images échographiques est rendue difficile par le bruit speckle et le faible contraste des tissus. Le prétraitement vise donc à améliorer la qualité visuelle des images tout en préservant la morphologie des lésions.

#### 3.1.1 Normalisation et amélioration de contraste (CLAHE)

Toutes les images sont redimensionnées à 320×320 pixels et normalisées dans l'intervalle  $[0, 1]$  (facteur rescale =  $1/255$ ). Pour améliorer le contraste local, un CLAHE (Contrast Limited Adaptive Histogram Equalization) est appliqué :

- opération par tuiles locales
- paramètres :  $\text{clipLimit} = 2.0$ ,  $\text{tileGridSize} = (8, 8)$

Contrairement à une égalisation d'histogramme globale, CLAHE limite l'amplification artificielle du contraste et évite de renforcer excessivement le bruit, ce qui est crucial pour les contours subtils des masses mammaires.

#### 3.1.2 Augmentation de données : choix de Mixup

Pour régulariser le modèle et réduire l'overfitting, une stratégie d'augmentation de données est mise en place. Deux approches ont été testées :

- CutMix (découpage/collage de patches d'images)
- Mixup (combinaison linéaire d'images et de labels)

Les essais préliminaires ont montré que CutMix détériore la morphologie spatiale des lésions (spiculations, bords, forme globale), ce qui est problématique pour distinguer un cancer *debut* d'un cancer *grave*. Le pipeline final conserve donc uniquement Mixup avec :

- paramètre  $\alpha = 0.1$
- probabilité d'application  $p = 0.5$

Un  $\alpha$  faible garantit que les images générées restent proches de la réalité anatomique, tout en lissant les frontières de décision du modèle.

### 3.1.3 Limites et risques du prétraitement

Bien que le prétraitement améliore la lisibilité des images et la stabilité de l'apprentissage, il comporte aussi des limites. Un contraste trop renforcé peut, par exemple, accentuer des artefacts ou modifier légèrement l'apparence des contours, ce qui risque de créer des signaux artificiels pour le modèle. Il est donc nécessaire de choisir des paramètres de CLAHE modérés et de vérifier qualitativement que l'aspect des lésions reste conforme à l'interprétation radiologique.

De même, l'augmentation par Mixup ne doit pas s'éloigner excessivement de la réalité anatomique. Des combinaisons trop extrêmes pourraient mélanger des structures appartenant à des contextes très différents et rendre l'apprentissage instable. Le choix d'un  $\alpha$  faible et d'une probabilité d'application limitée vise justement à respecter l'équilibre entre diversité des données et préservation des signatures visuelles importantes pour la différenciation entre lésions débutantes et avancées.

## 3.2 Architecture DenseNet-121 et tête de classification

L'architecture choisie est DenseNet-121 pré-entraînée sur ImageNet, utilisée comme backbone d'extraction de caractéristiques.

### 3.2.1 Intérêt des blocs denses en échographie

Dans DenseNet, chaque couche d'un *dense block* reçoit en entrée les cartes de caractéristiques de toutes les couches précédentes, via une concaténation progressive.

Cette réutilisation systématique des feature maps est particulièrement intéressante en imagerie médicale :

- conservation simultanée de motifs de bas niveau (textures, bords, contours de la masse)
- agrégation de concepts de plus haut niveau (forme globale de la tumeur, contexte tissulaire)

Cette propriété favorise une représentation riche sans explosion du nombre de paramètres.

### 3.2.2 Tête de classification et module d'attention

Au-dessus du backbone DenseNet-121 (chargé sans sa tête de classification d'origine), une tête spécifique à la tâche est ajoutée :

- couche de Global Average Pooling (GAP) pour transformer les cartes de caractéristiques en un vecteur de taille 1 024
- couche Dense(512, activation='relu') suivie d'un Dropout(0.3) pour limiter le surapprentissage
- couche de sortie Dense(3, activation='softmax') pour les trois classes (*debut*, *grave*, *normal*)



Un module d'attention de type CBAM (Convolutional Block Attention Module) a été testé dans des expériences intermédiaires, mais l'architecture finale s'appuie principalement sur la robustesse intrinsèque de DenseNet-121 et sur la régularisation par Mixup / Dropout.

### 3.3 Protocole d'entraînement avancé

L'entraînement est réalisé en deux phases successives afin de stabiliser d'abord la tête de classification, puis d'ajuster finement le backbone.

#### 3.3.1 Stratégie de fine-tuning progressif

- Phase 1 – Apprentissage de la tête
  - Backbone DenseNet totalement gelé
  - Seules les couches supérieures (GAP + Dense(512) + Dropout + Dense(3)) sont entraînées
  - Taux d'apprentissage initial :  $\text{lr} = 10^{-4}$
  - Ordonnancement du lr par Cosine Annealing avec warmup de 5 époques
- Phase 2 – Fine-tuning conservateur
  - Dégel des  $\approx 15\%$  couches supérieures du backbone ( $\approx 65$  couches entraînables sur 427)
  - Taux d'apprentissage très faible :  $\text{lr} = 5 \times 10^{-6}$
  - Objectif : adapter légèrement les filtres convolutionnels aux textures échographiques sans détruire les connaissances pré-apprises sur ImageNet

Cette approche progressive limite les risques d'overfitting sur un dataset de taille moyenne tout en permettant une spécialisation raisonnable du backbone.

#### 3.3.2 Focal Loss pondérée et priorités cliniques

La fonction de coût standard en classification multi-classes est la cross-entropy catégorielle, définie pour un exemple  $(x_i, y_i)$  par :  $L_{CE}(p_t) = -\log(p_t)$  où  $p_t$  désigne la probabilité prédite pour la classe réelle  $y_i$ . Cette formulation traite de manière identique les exemples faciles (bien classés, forte confiance) et les exemples difficiles (incertains ou mal classés), ce qui la rend inadaptée en présence d'un déséquilibre de classes. La Focal Loss, introduite par Lin et al. (2017), modifie ce comportement en ajoutant un facteur de modulation dynamique :  $L_{FL}(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t)$  où  $\gamma = 2.0$  est le paramètre de focalisation et  $\alpha_t$  le poids de classe. Lorsque le modèle est très confiant ( $p_t = 0.9$ ), le facteur  $(1 - 0.9)^2 = 0.01$  réduit la perte à  $1\%$  de sa valeur standard. Pour un exemple difficile ( $p_t = 0.3$ ), ce facteur vaut  $(0.7)^2 = 0.49$ , maintenant une forte pression d'apprentissage sur les cas ambigus notamment les lésions débutantes.

La distribution des classes (majorité *debut*, minorité *normal*) rend la cross-entropy standard insuffisante. Une Focal Loss catégorielle personnalisée est donc implémentée, inspirée de Lin et al. (2017) :

- paramètre de focalisation :  $\gamma = 2.0$  (accent sur les exemples difficiles)
- coefficients de poids de classe  $\alpha$  ajustés empiriquement pour refléter les priorités médicales :
  - $\alpha_{\text{debut}} = 1.2$  : léger renforcement pour garantir un haut taux de détection précoce
  - $\alpha_{\text{grave}} = 1.0$  : poids de référence
  - $\alpha_{\text{normal}} = 1.5$  : poids plus élevé pour compenser la faible taille de cette classe et éviter qu'elle soit ignorée

Plutôt que d'utiliser l'inverse brut des fréquences, ces valeurs ont été calibrées de façon à ne pas "écraser" la classe *debut*, tout en réhabilitant la classe *normal*.

### 3.3.3 Exploration et choix des hyperparamètres

Le choix des hyperparamètres (taux d'apprentissage, taille de lot, nombre d'époques, paramètres de la Focal Loss) a fait l'objet d'une exploration empirique sur le jeu de validation. Dans une première série d'essais, des taux d'apprentissage plus élevés ont été testés pour la phase de fine-tuning, mais ils conduisaient rapidement à une dégradation des performances de validation et à une instabilité des courbes de perte, signe d'un sur-ajustement du backbone DenseNet-121. La valeur finale retenue ( $5 \times 10^{-6}$ ) représente un compromis entre capacité d'adaptation et préservation des connaissances pré-apprises.

De même, plusieurs configurations de poids de classes pour la Focal Loss ont été comparées. Des poids trop élevés pour la classe *normal* amélioreraient légèrement son rappel, mais au prix d'une baisse non acceptable du rappel de la classe *debut*. Les coefficients finaux (1,2 ; 1,0 ; 1,5) ont été sélectionnés car ils permettent de maintenir un rappel élevé sur les lésions précoces tout en évitant que la classe normale soit systématiquement sacrifiée. Cette démarche montre que l'optimisation ne se limite pas à une recherche automatique, mais s'appuie sur des considérations cliniques explicites.

## 3.4 Métriques cliniques et calibration asymétrique des seuils

Dans un contexte de dépistage, toutes les erreurs n'ont pas le même impact.

Un faux positif (classer à tort un sein sain comme pathologique) entraîne de l'anxiété et des examens complémentaires.

Un faux négatif sur une lésion *debut* retarde une prise en charge potentiellement curative.

Pour cette raison :

- la métrique principale n'est pas l'accuracy, mais le recall (sensibilité) de la classe *debut*, avec une cible clinique fixée à  $\geq 90\%$  ;
- l'AUC-ROC et le F1-score macro sont utilisés comme métriques secondaires pour vérifier que la performance globale du modèle reste exploitable.

### 3.4.1 Calibration hiérarchique des seuils (script `calibrate_exp4.py`)

Après l'entraînement, un algorithme de calibration post-hoc des seuils de décision par classe est appliqué :

1. Sur le jeu de validation, on extrait les probabilités de sortie du modèle pour chaque classe (*debut*, *grave*, *normal*).
2. Pour chaque classe, des courbes ROC sont analysées afin de déterminer un seuil optimal qui maximise la sensibilité tout en gardant un F1 acceptable.
3. On obtient ainsi trois seuils cliniques  $T_{debut}$ ,  $T_{grave}$ ,  $T_{normal}$

Lors de l'inférence, la décision suit une règle hiérarchique asymétrique :

1. Si  $p(\text{grave}) \geq T_{grave}$  la prédiction est grave.
2. Sinon, si  $p(\text{debut}) \geq T_{debut}$  la prédiction est debut.
3. Ce n'est que si aucun seuil pathologique n'est dépassé que le modèle est autorisé à prédire normal.

Cette logique implémente un comportement "fail-safe" : en cas de doute, le modèle préfère classer vers une classe pathologique plutôt que de rassurer à tort.

### 3.5 Reproductibilité : organisation du code et suivi des expériences

Pour que le travail soit exploitable et vérifiable, une attention particulière a été portée à la reproductibilité du pipeline :

- Scripts modulaires
  - augmentation.py : définition du générateur de données et des transformations (CLAHE, Mixup)
  - focal\_loss.py : implémentation de la Focal Loss pondérée
  - train\_advanced.py : orchestration de l'entraînement (phases 1 et 2, callbacks, sauvegardes)
  - calibrate\_exp4.py : calibration des seuils et évaluation post-entraînement
- Gestion des random seeds

Toutes les bibliothèques aléatoires (Python random, NumPy, TensorFlow/Keras) sont initialisées avec la même graine (seed = 42) afin de garantir la reproductibilité du split Train/Val/Test et des augmentations.
- Monitoring et checkpoints
  - sauvegarde automatique du meilleur modèle (save\_best\_only=True) en monitorant la métrique val\_auc
  - utilisation de callbacks d'EarlyStopping (patience 10–12 époques) pour limiter le surapprentissage
- Traçabilité des expériences

Après chaque expérience, les éléments suivants sont sérialisés (JSON / images) :

  - historiques d'entraînement (loss, accuracy, AUC)
  - matrices de confusion et rapports de classification
  - seuils calibrés et résultats finaux sur le jeu de test


Cette organisation facilite la comparaison entre configurations successives (Expériences 3, 4, 5) et permet au lecteur de reproduire ou prolonger le travail.

### 3.6 Résumé et logique clinique de la méthodologie


L'ensemble des choix méthodologiques présentés dans ce chapitre s'inscrit dans une logique de conception orientée par le besoin clinique. Chaque composant du pipeline (prétraitement, architecture DenseNet-121, schéma d'entraînement en deux phases, Focal Loss pondérée, calibration hiérarchique des seuils) vise à réduire au maximum le risque de faux négatifs sur les lésions débutantes, tout en conservant une performance globale compatible avec un usage de triage.

Concrètement, la méthodologie développée dans ce mémoire repose sur un pipeline strict pour prévenir toute fuite d'informations (data leakage). Le jeu de données original BUSI (780 images, 3 classes : normal, début, grave) a d'abord été divisé en trois sous-ensembles disjoints au niveau patient (70% entraînement, 15% validation, 15% test). Ensuite, uniquement sur l'ensemble d'entraînement, des augmentations hors-ligne ont été appliquées pour balancer les classes, générant un corpus théorique étendu à 1 580 images. Les images sont prétraitées par redimensionnement, normalisation et CLAHE pour améliorer le contraste local tout en limitant le bruit.

Répartition stricte des données  
(Sans fuite de données)




Déséquilibre des classes dans le dataset original (BUSI)



# MEDICAL IMAGE PREPROCESSING PIPELINE

FROM RAW SCAN TO ENHANCED DATA FOR MACHINE LEARNING



Lors de l'apprentissage, une augmentation dynamique contrôlée supplémentaire (Mixup,  $\alpha = 0,1$ ) a été utilisée afin d'augmenter la diversité. Le modèle s'appuie sur un DenseNet-121 pré-entraîné sur ImageNet, utilisé comme extracteur de caractéristiques, surmonté d'une tête de classification adaptée à trois classes (GAP, Dense(512, ReLU), Dropout(0,3), Dense(3, softmax)). L'apprentissage est réalisé en deux phases : d'abord l'entraînement de la tête de classification avec le backbone gelé, puis un fine-tuning conservateur des couches supérieures de DenseNet avec un faible taux d'apprentissage. Pour gérer le déséquilibre et refléter les priorités cliniques, une Focal Loss pondérée est utilisée ( $\gamma = 2$ , poids de classes ajustés). Enfin, une calibration hiérarchique des seuils de décision est appliquée en post-entraînement pour imposer une logique "fail-safe" (grave > début > normal), garantissant la reproductibilité avec la gestion des seeds.

## 3.7 Rappel des métriques d'évaluation

Pour évaluer le modèle, plusieurs métriques complémentaires sont utilisées, afin de tenir compte du déséquilibre des classes et des priorités cliniques.

- Accuracy (taux de bonne classification)

L'accuracy mesure la proportion d'images correctement classées parmi l'ensemble des images du jeu

de test.

Elle est utile pour donner une vision globale, mais peut être trompeuse en présence de classes minoritaires.

- Recall / Sensibilité par classe

Le recall d'une classe mesure la proportion de vrais positifs correctement détectés parmi tous les exemples réellement appartenant à cette classe.

Dans ce mémoire, le recall de la classe *debut* est la métrique principale, car il correspond à la capacité du modèle à détecter les lésions précoces (erreur la plus critique en dépistage).

- Précision et F1-score par classe

La précision mesure la proportion de vrais positifs parmi toutes les prédictions positives d'une classe donnée.

Le F1-score est la moyenne harmonique entre précision et recall, ce qui permet d'équilibrer les deux aspects.

Le F1 macro (moyenne du F1 sur les trois classes) est utilisé comme indicateur global de performance, indépendant du déséquilibre des effectifs.

- AUC-ROC et AUPRC (Area Under Precision-Recall Curve)

L'AUC-ROC mesure la capacité du modèle à séparer les classes en faisant varier le seuil de décision. Cependant, en présence de classes fortement déséquilibrées (comme la classe *normal* qui est minoritaire dans BUSI), l'AUPRC est une métrique plus robuste et plus appropriée cliniquement, car elle évalue directement le compromis entre la précision et le recall. Une AUPRC élevée garantit que les prédictions positives sont fiables. Dans ce travail, une AUC macro est reportée pour juger la qualité globale du modèle, ainsi que des intervalles de confiance à 95% (IC 95%) calculés par rééchantillonnage bootstrap ( $N=1000$ ).

Ainsi, l'évaluation du modèle reposera principalement sur le recall de la classe *debut* (priorité clinique), puis sur le F1 macro et l'AUC macro pour vérifier que la performance globale reste exploitable sur l'ensemble des classes.

## CHAPITRE 4. RÉSULTATS EXPÉRIMENTAUX

Ce chapitre présente les performances obtenues par l'architecture DenseNet-121 sur le jeu de test (240 images), puis démontre l'apport de la calibration orientée "priorité clinique" ciblée sur la classe *début*. Les résultats sont d'abord analysés globalement (métriques et matrices de confusion), puis discutés au regard de l'interprétabilité visuelle par Grad-CAM, pour enfin s'achever par une analyse critique des biais de généralisation vers le contexte clinique ivoirien.

### 4.1 Performance globale de DenseNet-121 (3 classes, avant calibration)


Le passage d'une classification binaire classique (bénin vs malin) à une classification en trois classes sémantiques (normal, début, grave) augmente drastiquement la difficulté de la tâche en échographie mammaire. Sur notre jeu de test indépendant de 240 images (jamais vues lors de la phase d'apprentissage), le modèle DenseNet-121 final (Expérience 4), entraîné avec Focal Loss et Mixup mais sans calibration asymétrique des seuils, obtient les excellentes performances brutes suivantes :

- Accuracy globale : 81,67%
- F1-score macro : 0,7910
- AUC-ROC macro : 0,9219
  - AUC *début* : 0,9242


- AUC *grave* : 0,9246
- AUC *normal* : 0,9168

Ces résultats montrent une puissante capacité de généralisation sur les trois classes. Le modèle ne se contente pas de prédire aveuglément la classe majoritaire, mais a appris des caractéristiques discriminantes pour chacune d'elles (AUC toutes > 0,91). Néanmoins, dans cette configuration technique standard, le recall (sensibilité) de la classe *début* reste inférieur à l'objectif clinique de 90%, ce qui justifie l'étape d'optimisation et de calibration décrite en section 4.3.

**Figure 3.5 – Historique d'entraînement de DenseNet-121 (loss, accuracy, AUC)**








Cette figure illustre la convergence de la loss et la stabilisation de l'AUC sur les ensembles d'entraînement et de validation. Les courbes démontrent l'absence de surapprentissage marqué grâce à la régularisation par Mixup et au fine-tuning progressif.

Figure 4.1 – Matrice de confusion de DenseNet-121 sur le jeu de test (avant calibration)

### Matrice de Confusion Standard (Expérience 3) Sur le Test Set (Avant Calibration)



La matrice met en évidence des confusions résiduelles entre les classes pathologiques (*début* et *grave*) et un nombre encore non négligeable de faux négatifs (cas pathologiques prédits *normaux*), ce qui reste problématique pour un usage de triage médical.


## 4.2 Analyse Grad-CAM : interprétabilité des prédictions

Pour qu'un modèle de deep learning soit accepté par la communauté médicale, il ne suffit pas de présenter de bons scores numériques : les zones d'attention de l'IA (le "regard" du réseau) doivent être cliniquement cohérentes. Dans ce travail, des cartes de chaleur Grad-CAM ont été générées à partir de la dernière couche convolutionnelle de DenseNet-121.

Les visualisations obtenues montrent que :


- pour les lésions de stade *grave*, les fortes activations se concentrent précisément sur la masse hypoéchogène et ses contours irréguliers (spiculations), en accord avec les critères visuels classiques des tumeurs infiltrantes ;
- pour les lésions de stade *début*, la focale du modèle se concentre sur le petit foyer échogène suspect, même lorsque la lésion est peu marquée dans le stroma, ce qui suggère une extraction réelle de biomarqueurs précoces ;
- pour les seins *normaux*, l'activation est diffuse sur l'ensemble du parenchyme glandulaire, sans fixation sur un foyer cible, ce qui limite le risque de décisions basées sur des artefacts (texte incrusté, bordures, bruit).

Figure 4.2 – Exemple de Grad-CAM pour une lésion de stade grave




La carte de chaleur recouvre la masse complète et ses bords, confirmant que le modèle fonde sa décision sur la morphologie tumorale.

Figure 4.3 – Exemple de Grad-CAM pour un sein normal



L'activation nuageuse et étendue traduit l'absence de zone d'intérêt suspecte identifiée, ce qui est cohérent avec une image normale.

Figure 4.4 – Exemple de Grad-CAM pour une lésion de stade début



Le réseau cible un nodule architectural discret, illustrant sa capacité à se focaliser sur des anomalies précoces difficiles à percevoir à l'œil nu.

Ces visualisations XAI (Explainable AI) attestent que DenseNet-121 a internalisé des "règles métiers" compatibles avec la pratique radiologique rigoureuse, ce qui renforce la confiance dans son utilisation comme outil d'aide au dépistage.

### 4.3 Optimisation orientée détection précoce (Expériences 3 à 5)

L'objectif opérationnel central de ce mémoire est d'atteindre un recall  $\geq 90\%$  sur la classe *début*, stade où le pronostic de guérison est le plus favorable. L'Expérience 3 (configuration initiale) atteignait un recall *début* d'environ 71,9%, ce qui signifie que près de 3 lésions précoces sur 10 pouvaient être mal classées. Pour pallier cette faiblesse, les Expériences 4 et 5 ont été construites en combinant deux axes forts :

1. Focal Loss déséquilibrée ( $\gamma = 2.0$ ) avec injection de poids de priorité :
  - $\alpha_{\text{debut}} = 1.2$
  - $\alpha_{\text{grave}} = 1.0$
  - $\alpha_{\text{normal}} = 1.5$
2. Ces hyperparamètres forcent le réseau à sur-protéger la classe *normal* (très minoritaire en volume) tout en augmentant le poids d'erreur des cancers précoces.
3. Calibration asymétrique (fail-safe) post-entraînement :
 

au lieu d'utiliser un simple argmax sur les probabilités, le modèle suit une hiérarchie de triage (seuils calibrés sur le set de validation, script `calibrate_exp4.py`) :


  - si  $P(\text{grave}) \geq T_{\text{grave}} \rightarrow$  prédiction : grave
  - sinon, si  $P(\text{debut}) \geq T_{\text{debut}} \rightarrow$  prédiction : début
  - sinon (par élimination clinique)  $\rightarrow$  prédiction : normal

Cette reprogrammation logique transforme l'algorithme technique en outil de triage sécurisé.

Sur le test set, l'Expérience 5 (modèle calibré "priorité clinique") obtient :


- Accuracy globale : 77,5%
- F1-score macro :  $\approx 0,73$
- Recall de la classe *début* : 90,4% (cible de 90% dépassée)

Figure 4.5 – Matrice de confusion calibrée sur le test set (Expérience 5)



Sur 135 cancers *début*, 122 sont correctement identifiés et 11 sont “sur-classés” en *grave* ; seuls 2 cas *début* sont faussement catalogués *normaux*. Aucun cas *grave* n’est prédit *normal*.

Figure 4.6 – Évolution du recall par classe entre Exp 3 et Exp 5



L'histogramme illustre le bond du recall *début* de 71,9% à 90,4%, au prix d'une baisse modérée du recall sur la classe *normal*, tout en maintenant un F1 macro et une accuracy globales acceptables.

En pratique, cela signifie que l'algorithme adopte une prudence extrême : il génère volontairement davantage de faux positifs (patientes saines classées comme suspectes) pour réduire au minimum les faux négatifs sur les classes pathologiques. Ce comportement est précisément celui attendu d'un filet de premier filtre en imagerie médicale.

#### 4.3.1 Analyse qualitative des erreurs de classification

u-delà des métriques globales et des matrices de confusion, l'analyse qualitative des erreurs apporte un éclairage précieux sur les forces et faiblesses du modèle. En pratique, plusieurs types de faux positifs et de faux négatifs ont été observés lors de l'inspection manuelle des prédictions sur le jeu de test, en s'appuyant notamment sur les cartes de chaleur Grad-CAM.

Parmi les faux positifs, un premier groupe concerne des seins normaux prédits comme début ou grave. Dans ces cas, le modèle se focalise souvent sur des zones de parenchyme légèrement hétérogène ou sur des structures anatomiques bénignes (lobules, vaisseaux) qui peuvent présenter un contraste local similaire à celui de petites lésions. Ce comportement reflète une stratégie prudente : dès qu'une irrégularité texturale dépasse un certain seuil, le réseau préfère déclencher une alerte, quitte à générer des examens complémentaires chez des patientes finalement saines.

Un second groupe de faux positifs implique des lésions bénignes ou des anomalies non spécifiquement cancéreuses, mais classées en début ou en grave par le modèle. Visuellement, ces exemples partagent des caractéristiques proches de tumeurs malignes (contours mal limités, hétérogénéité interne), ce qui explique que DenseNet-121 les assimile à des cancers. Dans un contexte de triage, cette sur-sensibilité n'est pas nécessairement problématique, dans la mesure où la décision finale revient au radiologue, mais elle souligne l'importance de fournir des explications visuelles (Grad-CAM) pour l'aider à requalifier ces alertes.

Les faux négatifs résiduels sur la classe début sont, quant à eux, particulièrement instructifs. Ils correspondent souvent à des lésions de très petite taille, faiblement contrastées, ou partiellement masquées par un tissu glandulaire dense. Dans certains cas, les cartes Grad-CAM montrent que le modèle active des régions proches de la lésion sans la recouvrir entièrement, ce qui suggère que les signaux discriminants sont présents mais encore insuffisamment marqués pour franchir le seuil de décision. Ces observations confirment que la combinaison d'images de meilleure qualité, de données supplémentaires et d'architectures éventuellement plus sensibles aux micro-structures pourrait encore réduire le nombre de faux négatifs.

Enfin, l'analyse conjointe des erreurs et des visualisations Grad-CAM met en évidence un point important pour un déploiement futur : le modèle doit être utilisé comme un outil d'aide à la décision, et non comme un arbitre autonome. Les cas ambigus, qu'ils soient faux positifs ou faux négatifs, doivent être systématiquement relus par le radiologue, en tenant compte du contexte clinique global, afin de combiner au mieux la sensibilité de l'IA et l'expertise humaine.

## 4.4 Limites et biais liés au dataset et au contexte ivoirien

Malgré des résultats très encourageants sur le banc d'essai, l'honnêteté scientifique impose de nuancer la portée immédiate de ce modèle en cas de déploiement réel en Côte d'Ivoire.

### 1. Biais démographique (base BUSI vs anatomie ouest-africaine)

La base originale BUSI s'appuie sur une population principalement moyen-orientale. Or, la densité du parenchyme mammaire (BI-RADS C/D) est plus prévalente chez la femme afro-descendante, ce qui peut masquer davantage les lésions en échographie. Une baisse du recall *début* est donc plausible si le modèle est appliqué tel quel à des patientes ivoiriennes, dont les caractéristiques mammaires n'ont pas été apprises par DenseNet-121.

### 2. Taille de l'échantillon et capacité du modèle

Le corpus complet de 1 580 images, même enrichi par augmentation de données et utilisé avec du transfert d'apprentissage, reste modeste face aux 8 millions de paramètres de DenseNet-121. La variété des bruits, des formes lésionnelles et des contextes anatomiques n'est probablement pas entièrement couverte.

### 3. Approche unimodale 2D vs pratique clinique multimodale

Sur le terrain, le radiologue ne se base pas sur une seule image échographique statique : il réalise un examen dynamique, croise les informations avec la mammographie et le dossier clinique (âge, antécédents, facteurs de risque). L'IA développée ici travaille "à l'aveugle" de ce contexte multimodal, ce qui explique certains faux positifs sur des structures saines ambiguës qu'un clinicien expérimenté aurait requalifiées.

Ces limites dessinent naturellement les perspectives du projet : constitution d'une bio-banque d'images 100% panafricaines (ou ivoiriennes), intégration d'architectures mieux adaptées aux tissus denses, et développement de modèles multimodaux combinant image échographique et données cliniques structurées.

## 4.5 Analyse statistique complémentaire des performances

Au-delà des valeurs ponctuelles de performance (accuracy, F1-score, recall, AUC), il est important de quantifier l'incertitude statistique associée à ces estimations. Dans la littérature sur l'IA en dépistage mammaire, plusieurs travaux recommandent de rapporter des intervalles de confiance (IC) à 95% obtenus par bootstrap ou par méthodes exactes, afin d'éviter une interprétation trop optimiste de différences de



quelques points de pourcentage entre modèles. Dans le cas présent, le jeu de test comprend 240 images, ce qui reste une taille modeste ; les métriques doivent donc être lues comme des indications de tendance plutôt que comme des valeurs définitives généralisables à l'ensemble de la population ivoirienne.

Une première analyse consiste à examiner les courbes ROC et Precision-Recall (PR) par classe pour les expériences 3 et 5. Dans les deux cas, les AUC-ROC par classe restent supérieures à 0.90. Cependant, l'examen de l'AUPRC (Area Under Precision-Recall Curve) révèle la véritable robustesse du modèle face au déséquilibre des classes. La comparaison montre que le gain principal de l'Expérience 5 réside dans un déplacement stratégique du point de fonctionnement le long de la courbe PR, favorisant une sensibilité accrue au prix d'une baisse mesurée de la précision. Ce comportement est cohérent avec l'utilisation d'une calibration asymétrique des seuils calibrée pour le triage médical. De plus, les performances quantitatives s'accompagnent d'intervalles de confiance (IC) à 95% calculés par méthode bootstrap sur le jeu de test ( $N=1000$  resamples), confirmant la solidité de ces résultats.

Une seconde analyse porte sur la stabilité des métriques entre le jeu de validation et le jeu de test. Dans un scénario de surapprentissage fort, on observerait typiquement des performances très élevées en validation et une chute marquée sur le test. Ici, les courbes d'apprentissage (Figure 4.1) et les valeurs obtenues sur le test suggèrent au contraire une convergence relativement régulière, sans divergence majeure entre les deux ensembles. Cette cohérence plaide en faveur d'une bonne régularisation du modèle, notamment grâce au Mixup, à la Focal Loss et au fine-tuning progressif du backbone, en ligne avec ce qui est rapporté dans d'autres études sur BUSI et sur des jeux de données échographiques de taille comparable.

Enfin, il est utile de replacer les performances observées dans le cadre plus large des études comparatives de modèles de deep learning pour le cancer du sein. Des analyses récentes montrent que les différences d'accuracy ou d'AUC entre architectures (ResNet, DenseNet, EfficientNet, ViT) se situent souvent dans une fourchette de quelques points de pourcentage lorsque les protocoles d'entraînement et les prétraitements sont soigneusement harmonisés. Dans ce contexte, l'augmentation du recall de la classe début de 71,9% à 90,4% entre les expériences 3 et 5 apparaît moins comme un « saut technologique » lié à un changement d'architecture que comme l'effet d'un ajustement ciblé du point de fonctionnement (calibration des seuils) en fonction d'un objectif clinique précis. Cette observation renforce l'idée, défendue par plusieurs auteurs, que l'alignement des métriques et des seuils sur les priorités médicales peut avoir un impact au moins aussi important que le choix marginal d'un backbone légèrement plus performant sur un benchmark.

## CHAPITRE 5. DISCUSSION SCIENTIFIQUE

### 5.1 Comparaison aux travaux de l'état de l'art

De nombreux travaux récents ont appliqué le deep learning aux images mammaires (mammographie, échographie, histologie), en utilisant des architectures comme ResNet, DenseNet, EfficientNet ou des Transformers visuels. Plusieurs études rapportent des accuracies supérieures à 85–90% et des AUC proches de 0,95–0,99 sur des jeux de données publics tels que BUSI, BreakHis ou d'autres bases d'échographie. Sur le dataset BUSI, des modèles combinant DenseNet, EfficientNet ou U-Net atteignent par exemple des accuracies autour de 89–91% et des AUC proches de 0,99 en classification binaire bénin/malin.

Les performances obtenues dans ce mémoire (accuracy  $\approx 81,7\%$ , F1 macro  $\approx 0,79$ , AUC macro  $\approx 0,92$  avant calibration) se situent donc légèrement en dessous des meilleurs résultats publiés en binaire, mais il est important de rappeler que le problème traité ici est plus complexe : trois classes cliniques (normal, lésion

précoce, lésion avancée) au lieu de deux, et une base de seulement 1 580 images après augmentation. En outre, l'objectif n'est pas d'optimiser uniquement l'accuracy, mais de maximiser la sensibilité sur la classe "début" tout en maintenant des performances globales acceptables, ce que peu de travaux ciblent explicitement.

Les études comparatives récentes confirment par ailleurs la robustesse de DenseNet-121 en échographie mammaire, avec des AUC autour de 0,93–0,94, souvent supérieures à ResNet ou EfficientNet dans certaines configurations. Les résultats obtenus ici (AUC par classe entre 0,9168 et 0,9246) sont cohérents avec ces observations, ce qui valide le choix architectural fait au Chapitre 3. La particularité de ce travail réside surtout dans la combinaison Focal Loss + calibration hiérarchique des seuils, permettant d'atteindre un recall de 90,4% sur la classe "début", ce qui répond directement à une exigence de dépistage précoce rarement mise en avant de façon aussi explicite dans la littérature.

---

## 5.2 Limites : taille d'échantillon et biais de population

Les limites identifiées au Chapitre 4 rejoignent des difficultés bien documentées dans la littérature sur le deep learning en imagerie médicale. Plusieurs revues systématiques soulignent que la plupart des modèles existants sont entraînés sur des datasets de taille limitée et peu diversifiés, souvent centrés sur des populations caucasiennes ou asiatiques, ce qui réduit la capacité de généralisation vers d'autres groupes démographiques. Dans ce travail, le corpus de 1 580 images enrichies à partir de BUSI reste modeste pour un réseau de 8 millions de paramètres, malgré le recours au transfert d'apprentissage et à l'augmentation. Ceci expose le modèle au risque de sur-spécialisation sur les caractéristiques propres à BUSI.

Un autre point critique est le biais de population. Des travaux récents insistent sur le fait que la plupart des modèles de dépistage du cancer du sein sont entraînés sur des données provenant majoritairement de patientes européennes, nord-américaines ou asiatiques, avec des profils de densité mammaire et des contextes cliniques différents de ceux observés en Afrique subsaharienne. Dans ce mémoire, l'utilisation d'un dataset issu d'un autre contexte géographique signifie que les performances mesurées ne peuvent pas être transposées telles quelles à la population ivoirienne, où la prévalence élevée de seins denses pourrait réduire la sensibilité du modèle.

Enfin, le modèle développé est unimodal (échographie 2D seule) et ne tient pas compte du contexte clinique (âge, antécédents, facteurs de risque) ni d'autres modalités (mammographie, IRM). La littérature montre pourtant que les systèmes d'aide au diagnostic les plus performants tendent vers des approches multimodales et multi-centriques, combinant plusieurs sources d'information et validées sur des données externes hétérogènes.

---

## 5.3 Perspectives : déploiement au CHU d'Abidjan et nouvelles architectures

Plusieurs pistes de travail se dégagent pour prolonger ce mémoire et aller vers un déploiement progressif dans un environnement comme le CHU d'Abidjan.

Sur le plan des données, la priorité est la constitution d'une base de données locale d'échographies mammaires annotées, idéalement multi-centre (CHU et cliniques privées), couvrant la diversité des appareils, des protocoles d'acquisition et des profils anatomiques ivoiriens. Cette bio-banque permettrait de réentraîner ou affiner le modèle DenseNet-121 sur des données représentatives de la population cible, voire de constituer un dataset panafricain susceptible d'être partagé pour la recherche.

Sur le plan des architectures, plusieurs évolutions sont envisageables :

- explorer des modèles multimodaux combinant échographie et mammographie, voire des données tabulaires (âge, antécédents, facteurs de risque) dans un réseau joint (par exemple CNN + MLP ou Transformers multimodaux) ;
- tester des architectures récentes plus légères et adaptées au déploiement sur matériel contraint (EfficientNet, MobileNet, Transformers compacts), tout en comparant systématiquement leur AUC et leur recall sur la classe *début* à DenseNet-121 ;
- intégrer des techniques avancées d'explicabilité (Grad-CAM amélioré, variantes hiérarchiques) pour fournir des explications plus fines et standardisées aux radiologues.

Du point de vue du déploiement, une approche réaliste serait de mettre en place, dans un premier temps, un projet pilote au sein d'un service de radiologie d'Abidjan, où le modèle serait utilisé en double lecture : l'IA ne remplace pas le radiologue, mais signale les cas à haut risque (priorité à la classe *début*), avec un suivi prospectif des performances réelles. À terme, ce type d'outil pourrait contribuer à réduire les délais de dépistage, à prioriser les cas urgents et à soulager partiellement la charge des spécialistes, à condition d'être continuellement ré-entraîné et évalué sur des données locales. Dans cette perspective, un plan de déploiement progressif spécifique au CHU d'Abidjan peut être envisagé, structuré en plusieurs phases successives, comme détaillé dans la section suivante.

### 5.3.1 Plan de déploiement pilote au CHU d'Abidjan

La translation du modèle DenseNet-121 vers la pratique clinique nécessite une démarche progressive, structurée en plusieurs phases, afin de garantir à la fois la sécurité des patientes et l'adaptation aux contraintes du système de santé ivoirien. Des expériences internationales montrent que les déploiements réussis d'IA en dépistage mammaire reposent souvent sur un cheminement en plusieurs étapes : pilote monocentrique limité, extension multicentrique contrôlée, puis intégration en routine clinique avec un suivi continu des performances. Dans le contexte du CHU d'Abidjan, un plan de déploiement réaliste pourrait s'organiser en quatre phases successives, étalées sur plusieurs années.

La première phase consisterait en une validation rétrospective locale, en appliquant le modèle aux archives d'échographies mammaires du CHU (examens déjà interprétés et dont l'issue clinique est connue).

L'objectif serait de comparer, de manière anonyme et sans impact sur la prise en charge, les prédictions de l'IA aux comptes rendus existants, afin d'estimer le recall réel sur les lésions débutantes et le taux de faux positifs dans la population ivoirienne. Cette étape permettrait également d'identifier d'éventuels écarts de performance entre sous-groupes de patientes (âge, densité mammaire, type de sonde utilisée), et de calibrer si nécessaire de nouveaux seuils décisionnels adaptés au contexte local. En parallèle, un protocole de recherche et un cadre éthique devraient être validés par les instances compétentes (comité d'éthique, direction de l'hôpital).

La deuxième phase correspondrait à un pilote prospectif en double lecture au sein d'un seul service d'imagerie du CHU. Dans ce scénario, les radiologues continueraient à réaliser leur lecture habituelle, tandis que le système CADx produirait en arrière-plan un score de risque et une suggestion de classe (normal, début, grave), accompagnés de cartes Grad-CAM. Les décisions cliniques resteraient entièrement basées sur la lecture humaine, mais chaque cas ferait l'objet d'une comparaison a posteriori entre l'avis du radiologue et la proposition de l'IA. Inspirées des études pilotes menées en Europe et en Asie, ce type de configuration permet de mesurer l'impact potentiel de l'IA sur le taux de cancers détectés et la charge de travail, sans exposer les patientes à un risque additionnel.

La troisième phase viserait une intégration partielle dans le flux de travail, sous forme de triage ou de « safety net ». Une option serait d'utiliser le modèle pour prioriser la relecture des cas les plus suspects (classe début ou grave), afin de réduire les délais d'interprétation pour les patientes à haut risque, comme cela a été expérimenté dans certains programmes de dépistage organisés. Une autre option, complémentaire, consisterait à déployer le système en tant que filet de sécurité : les examens initialement jugés normaux par le radiologue seraient repassés par l'IA, qui déclencherait une alerte en cas de discordance forte, invitant à une seconde relecture ciblée. Dans un contexte de ressources humaines limitées, ces scénarios de triage et de « safety net » sont particulièrement attractifs, car ils maximisent l'impact de l'IA sur la détection précoce tout en laissant la décision finale au clinicien.

Enfin, une quatrième phase correspondrait à une éventuelle extension multi-sites et à l'intégration dans les stratégies nationales de lutte contre le cancer du sein. Cette étape supposerait de disposer d'une infrastructure numérique minimale (archivage d'images, réseau fiable entre hôpitaux, procédures standardisées) ainsi que d'un cadre de gouvernance aligné sur les recommandations internationales pour l'adoption sûre de l'IA en dépistage. Dans la région subsaharienne, plusieurs revues soulignent que l'essor de l'IA en oncologie ne pourra être durable qu'à condition de l'inscrire dans des politiques publiques structurées, tenant compte des contraintes budgétaires, des fragilités des registres de cancer et des inégalités persistantes entre zones urbaines et rurales. Dans cette perspective, le prototype présenté dans ce mémoire doit être envisagé comme une brique technologique initiale, à articuler avec des initiatives plus larges de renforcement des capacités en imagerie, en systèmes d'information hospitaliers et en formation des professionnels de santé.

#### **5.4 Enjeux éthiques et organisationnels de l'IA en dépistage**

L'intégration d'un système d'IA dans le dépistage du cancer du sein soulève des questions éthiques et organisationnelles qui dépassent les seules performances chiffrées. En particulier, plusieurs revues récentes insistent sur le fait que les enjeux de reproductibilité, de normes de preuve, de gouvernance des données et de répartition des responsabilités sont au moins aussi critiques que l'accuracy ou l'AUC rapportées dans les études expérimentales.

Tout d'abord, la question de la responsabilité est centrale : en cas de faux négatif ou de faux positif grave, il est nécessaire de clarifier le rôle respectif du radiologue, de l'établissement de santé et du fournisseur de l'algorithme. Des travaux montrent que, dans l'état actuel du droit, le clinicien reste souvent perçu comme le principal « porteur de responsabilité », même lorsque la décision a été fortement influencée par un outil algorithmique, ce qui peut créer une forme de « liability sink » pour les professionnels. Dans ce mémoire, le modèle est explicitement conçu comme un outil d'aide à la décision, utilisé en double lecture, ce qui signifie que la décision finale reste du ressort du médecin et que l'IA ne doit pas être considérée comme une autorité autonome.

Ensuite, le déploiement d'un modèle entraîné hors du contexte ivoirien ne doit pas renforcer des inégalités de prise en charge. Les études sur l'IA en dépistage mammaire soulignent que des biais présents dans les données d'entraînement peuvent se traduire par des performances hétérogènes selon les groupes d'âge, la densité mammaire ou l'origine ethnique, avec un risque d'accroître des inégalités déjà existantes. Dans un contexte comme l'Afrique subsaharienne, où le fardeau du cancer augmente et où les ressources sont limitées, ce risque est particulièrement sensible. La constitution d'un jeu de données local et la réalisation de validations cliniques prospectives apparaissent donc comme des prérequis pour un usage équitable, afin de vérifier que le modèle maintient un niveau de recall suffisant sur les sous-groupes de patientes les plus vulnérables.

Sur le plan de la gouvernance des données, la protection de la vie privée et la sécurité des systèmes d'information sont des préoccupations majeures. Les données d'imagerie et les métadonnées associées sont considérées comme des données de santé hautement sensibles et doivent faire l'objet de procédures strictes d'anonymisation, de contrôle d'accès et de journalisation. Plusieurs analyses recommandent la mise en place de cadres réglementaires spécifiques pour l'IA en santé, définissant clairement les exigences en matière de consentement éclairé, de durée de conservation des données, de cybersécurité et de transparence vis-à-vis des patientes. Dans la perspective d'un déploiement en Côte d'Ivoire, cela suppose une coordination entre les structures hospitalières, les autorités sanitaires et les développeurs pour aligner le projet sur les standards internationaux tout en tenant compte du cadre juridique national.

Sur le plan organisationnel, l'introduction d'un outil de CADx suppose également une adaptation des flux de travail. La littérature montre que l'absence de préparation des équipes et de formation dédiée est l'un des principaux freins à l'adoption effective de l'IA dans les programmes de dépistage. Les radiologues doivent être formés à l'interprétation des cartes de chaleur Grad-CAM et à la gestion des alertes générées par le système, de manière à ne pas créer une surcharge cognitive supplémentaire ni une forme de dépendance excessive à la machine (automation bias). Il est également nécessaire d'anticiper les contraintes techniques (infrastructure informatique, connectivité, puissance de calcul, maintenance) et de définir des procédures de mise à jour régulière du modèle, afin qu'il reste aligné sur les pratiques cliniques et les nouvelles connaissances scientifiques.

Enfin, l'acceptabilité du système par les patientes et par les professionnels de santé jouera un rôle déterminant dans la durabilité de son utilisation. Des études menées dans des programmes de dépistage montrent que si une majorité de femmes se déclarent prêtes à accepter un dépistage assisté par IA, elles expriment des inquiétudes importantes concernant les faux résultats et le risque de mésusage de leurs données. Du point de vue des professionnels, la confiance repose sur la transparence des performances réelles, la possibilité de comprendre au moins partiellement les décisions du modèle et la garantie qu'un cadre de régulation clair définit les responsabilités en cas d'erreur. Dans ce contexte, un travail de communication est indispensable pour expliquer que l'IA ne remplace pas le jugement humain, mais qu'elle constitue un filet de sécurité supplémentaire, particulièrement utile dans un environnement de ressources limitées comme celui de la Côte d'Ivoire, à condition que les principes d'équité, de sécurité et de transparence soient respectés.

## CONCLUSION GÉNÉRALE ET PERSPECTIVES

Le cancer du sein reste une cause majeure de mortalité chez la femme, en particulier dans les pays à ressources limitées où le dépistage organisé et l'accès régulier à l'imagerie restent insuffisants. Dans ce contexte, ce mémoire s'est attaché à concevoir et évaluer un modèle de deep learning orienté vers la détection précoce de lésions mammaires à partir d'images d'échographie, en s'appuyant sur l'architecture DenseNet-121 et en tenant compte des contraintes cliniques d'un futur déploiement dans un environnement hospitalier ivoirien.

Après avoir présenté, au Chapitre 1, le contexte épidémiologique du cancer du sein et la problématique spécifique de la détection précoce, le Chapitre 2 a dressé un état de l'art des principaux jeux de données, architectures de deep learning, stratégies de gestion du déséquilibre et méthodes d'explicabilité utilisées en imagerie mammaire. Les travaux existants montrent des performances souvent élevées en classification binaire bénin/malin sur des bases comme CBIS-DDSM ou BUSI, mais traitent rarement un scénario à trois classes cliniques en priorisant explicitement la sensibilité sur les lésions débutantes.

Le Chapitre 3 a présenté la méthodologie proposée : utilisation du dataset original BUSI réparti en 3 sous-ensembles (Train/Val/Test) avant toute augmentation, puis augmentation hors-ligne de l'ensemble d'entraînement pour obtenir un corpus théorique de 1 580 échographies, prétraité par redimensionnement, normalisation et CLAHE, puis augmenté dynamiquement via Mixup. L'architecture DenseNet-121 pré-entraînée sur ImageNet a été adaptée à une classification en trois classes (normal, début, grave) à l'aide d'une tête spécifique, et entraînée en deux phases (tête seule puis fine-tuning partiel) avec une Focal Loss pondérée pour gérer le déséquilibre des classes. Une étape centrale de la méthodologie a consisté à calibrer hiérarchiquement les seuils de décision afin de forcer le modèle à adopter un comportement de triage "fail-safe", privilégiant la détection des cas pathologiques, en particulier les lésions de stade début.

Les résultats expérimentaux du Chapitre 4 ont montré que, avant calibration, le modèle DenseNet-121 atteint une accuracy de 81,67%, un F1-score macro de 0,7910 et une AUC-ROC macro de 0,9219, avec des AUC par classe toutes supérieures à 0,91, ce qui traduit une bonne capacité globale de discrimination. Après optimisation des poids de la Focal Loss et calibration asymétrique des seuils, l'Expérience 5 permet d'atteindre un recall de 90,4% sur la classe "début", en maintenant une accuracy et un F1 macro globalement stables. La matrice de confusion calibrée montre qu'aucune lésion "grave" et seulement un très faible nombre de lésions "début" sont prédites comme normales, au prix d'une augmentation des faux positifs, ce qui correspond au comportement attendu d'un système de dépistage. Les visualisations Grad-CAM confirment par ailleurs que le modèle base ses décisions sur des régions anatomiquement pertinentes, en se focalisant sur les masses et foyers suspects plutôt que sur des artefacts.

Ce travail présente néanmoins plusieurs limites. La taille de l'échantillon (1 580 images après augmentation) et la provenance unique du dataset (BUSI, non ivoirien) limitent la capacité de généralisation du modèle à d'autres populations, en particulier aux femmes ouest-africaines chez qui la densité mammaire et le contexte clinique peuvent différer sensiblement. De plus, l'approche est unimodale (échographie 2D) et ne tient pas compte d'autres modalités d'imagerie ni des informations cliniques (âge, facteurs de risque, antécédents), alors que la pratique radiologique repose sur une intégration multimodale et multidimensionnelle.

Ces limites ouvrent autant de perspectives concrètes. Sur le plan des données, la priorité est la constitution d'une bio-banque locale d'échographies mammaires annotées (idéalement multi-centres en Côte d'Ivoire), permettant de réentraîner ou d'adapter le modèle aux spécificités anatomiques et techniques régionales. Sur le plan méthodologique, l'exploration de modèles multimodaux (combinaison d'échographie, mammographie et données cliniques) ainsi que l'évaluation de nouvelles architectures plus légères ou hybrides (EfficientNet, modèles à attention, Transformers visuels) pourraient améliorer encore les performances tout en facilitant le déploiement sur des infrastructures matérielles modestes. Enfin, un projet pilote de double lecture au sein d'un CHU d'Abidjan, où l'IA fonctionnerait en soutien des radiologues, permettrait d'évaluer en conditions réelles la robustesse du modèle, d'identifier de nouveaux biais et d'alimenter en continu un cycle de ré-entraînement et d'amélioration.

Sur le plan des contributions scientifiques, ce travail apporte trois éléments originaux par rapport à la littérature existante. Premièrement, il documente pour la première fois, à notre connaissance, l'évaluation systématique d'un modèle DenseNet-121 adapté à une classification mammaire en trois classes cliniques — normal, début et grave — dans une perspective de déploiement explicitement orientée vers le contexte ivoirien. Deuxièmement, la stratégie de calibration hiérarchique des seuils, combinée à une Focal Loss asymétrique, constitue une approche reproductible et transférable à d'autres problèmes de classification médicale à priorité clinique asymétrique, où certaines erreurs sont médicalement inacceptables. Troisièmement, la mise à disposition publique du code source, des scripts de calibration et de l'organisation

reproductible du pipeline offre une base de travail concrète pour d'autres équipes de recherche souhaitant adapter cette méthodologie à d'autres pathologies ou d'autres contextes africains.

À plus long terme, les perspectives de ce travail s'inscrivent dans une vision plus large de l'IA en santé pour l'Afrique subsaharienne. D'ici cinq à dix ans, un tel système pourrait évoluer vers un modèle multimodal intégrant simultanément des images échographiques, des clichés mammographiques et des données cliniques structurées (âge, facteurs de risque, antécédents familiaux), afin de se rapprocher du raisonnement clinique réel du radiologue. Parallèlement, la constitution progressive de bases de données locales multi-centriques — associant le CHU d'Abidjan, des cliniques privées et potentiellement des partenaires ouest-africains — permettrait d'entraîner des modèles nativement adaptés aux spécificités des populations africaines, réduisant ainsi le risque de biais de population identifié dans ce mémoire. Cette trajectoire s'inscrit dans les orientations du Plan National de Lutte contre le Cancer 2025-2029, qui place le renforcement de l'offre diagnostique et la numérisation du système de santé parmi ses axes prioritaires.

Il est important de souligner que la valeur de ce travail ne se mesure pas uniquement aux chiffres d'accuracy ou d'AUC obtenus sur un jeu de test de 240 images, mais à sa capacité à poser les bases méthodologiques d'une approche rigoureuse, contextualisée et éthiquement responsable. Chaque lésion débutante correctement détectée représente une femme ivoirienne dont le pronostic peut être radicalement amélioré par une prise en charge précoce : à l'échelle d'un pays où plus de 2 000 décès par cancer du sein sont enregistrés chaque année, et où plus de 70% des diagnostics interviennent aux stades III-IV, même un système de triage imparfait mais correctement encadré peut avoir un impact populationnel significatif. C'est dans cet esprit — allier rigueur technique, ancrage clinique et conscience des réalités du terrain — que ce mémoire a été conduit, et c'est dans ce même esprit que ses perspectives devront être poursuivies.

En résumé, ce mémoire montre qu'un modèle DenseNet-121 correctement adapté, pondéré et calibré peut atteindre une sensibilité élevée pour les lésions mammaires précoces à partir d'images d'échographie, tout en offrant des explications visuelles compréhensibles par les cliniciens. Il ne s'agit pas d'un outil prêt à remplacer le radiologue, mais d'un premier pas vers un système de triage automatisé, pensé dès l'origine pour s'intégrer dans le contexte clinique ivoirien et servir de base à de futurs développements plus larges, multimodaux et multi-centriques.

## RÉFÉRENCES

Al-Dhabyani, W., Gomaa, M., Khaled, H., & Fahmy, A. (2020). Dataset of breast ultrasound images. *Data in Brief*, 28, 104863.

<https://doi.org/10.1016/j.dib.2019.104863>

Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 4700–4708.

<https://doi.org/10.1109/CVPR.2017.243>



Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2980–2988.

<https://doi.org/10.1109/ICCV.2017.324>

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 618–626.

<https://doi.org/10.1109/ICCV.2017.74>

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778.

<https://doi.org/10.1109/CVPR.2016.90>

Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, PMLR 97, 6105–6114.

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... Houlsby, N. (2021). An image is worth 16×16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR 2021)*.

Zhang, H., Cissé, M., Dauphin, Y. N., & Lopez-Paz, D. (2018). Mixup: Beyond empirical risk minimization. *International Conference on Learning Representations (ICLR 2018)*.

Yun, S., Han, D., Oh, S. J., Chun, S., Choe, J., & Yoo, Y. (2019). CutMix: Training strategy to train stronger classifiers with localizable features. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 6023–6032.

Raza, R., Zulfiqar, F., Tariq, S., Abbas Zaidi, S. S., Ghafoor, M. I., Sargano, A. B., & Hussain, S. (2024). Breast cancer classification from ultrasound images using deep learning. *Bioengineering*, 11(2), 116.

Shen, L., Margolies, L. R., Rothstein, J. H., Fluder, E., McBride, R., & Sieh, W. (2019). Deep learning to improve breast cancer detection on screening mammography. *Scientific Reports*, 9, 12495.

<https://doi.org/10.1038/s41598-019-48995-4>

McKinney, S. M., Sieniek, M., Godbole, V., Godwin, J., Antropova, N., Ashrafian, H., ... Shetty, S. (2020). International evaluation of an AI system for breast cancer screening. *Nature*, 577, 89–94.

<https://doi.org/10.1038/s41586-019-1799-6>

Bray, F., Laversanne, M., Sung, H., Ferlay, J., Siegel, R. L., Soerjomataram, I., & Jemal, A. (2024). Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 74(3), 229–263.

<https://doi.org/10.3322/caac.21834>

Ferlay, J., Ervik, M., Lam, F., Laversanne, M., Colombet, M., Mery, L., ... Bray, F. (2024). *Global Cancer Observatory: Cancer Today*. Lyon : International Agency for Research on Cancer. Disponible sur :

<https://gco.iarc.who.int/today>

Programme National de Lutte contre le Cancer — Côte d'Ivoire. (2022). *Plan Stratégique National de Lutte contre le Cancer 2022–2025*. Abidjan : Ministère de la Santé, de l'Hygiène Publique et de la Couverture Maladie Universelle.

Tice, J. A., Cummings, S. R., Smith-Bindman, R., Ichikawa, L., Barlow, W. E., & Kerlikowske, K. (2008). Using clinical factors and mammographic breast density to estimate breast cancer risk: development and validation of a new predictive model. *Annals of Internal Medicine*, 148(5), 337–347.

Wanders, J. O., Holland, K., Veldhuis, W. B., Mann, R. M., Pijnappel, R. M., Peeters, P. H., ... Karssemeijer, N. (2017). Volumetric breast density affects performance of digital screening mammography. *Breast Cancer Research and Treatment*, 162(1), 95–103.

Loeffler, M. D., & Kabba, M. (2022). Breast imaging and cancer in sub-Saharan Africa: a systematic review. *The Breast*, 61, 30–38.

Wwoo, S., Park, J., Lee, J.-Y., & Kweon, I. S. (2018). CBAM: Convolutional block attention module. *Proceedings of the European Conference on Computer Vision (ECCV)*, 3–19.

Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., ... Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60–88.

<https://doi.org/10.1016/j.media.2017.07.005>

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1), 1929–1958.

Loshchilov, I., & Hutter, F. (2017). SGDR: Stochastic gradient descent with warm restarts. *International Conference on Learning Representations (ICLR 2017)*.

## ANNEXES

### Annexe A : Code source (lien repository)

Cette annexe regroupe les éléments permettant de reproduire intégralement les expériences décrites dans le mémoire :

- lien vers le dépôt Git (GitHub, GitLab ou autre) contenant le code source du projet ;
- principaux scripts Python :
  - train\_advanced.py : script d’entraînement (phases 1 et 2, callbacks, sauvegardes)
  - augmentation.py : gestion des prétraitements et de l’augmentation (CLAHE, Mixup)
  - focal\_loss.py : implémentation de la Focal Loss pondérée
  - calibrate\_exp4.py : calibration des seuils et évaluation post-entraînement
- instructions succinctes d’exécution (version de Python, dépendances, commande de lancement).

Le code source complet de ce travail, incluant les scripts d’entraînement, d’augmentation de données et de calibration, est disponible sous licence libre à l’adresse suivante :  
<https://github.com/yaman1444/master-reseach.git>

## Annexe B : Métriques complètes et courbes ROC

Cette annexe fournit les détails chiffrés complémentaires qui ne tiennent pas dans le corps du texte :

- tableaux complets des métriques par expérience (Exp 3, Exp 4, Exp 5) : accuracy, precision, recall, F1 par classe, F1 macro, AUC par classe ;
- courbes ROC par classe (normal, début, grave) pour le modèle standard et le modèle calibré ;
- éventuellement les courbes Precision-Recall si tu les as générées.

Par exemple :

Figure B.1 – Courbes ROC par classe (modèle DenseNet-121 avant calibration)

Figure B.2 – Courbes ROC par classe (modèle calibré – Expérience 5)

Tableau B.1 – Détails des métriques par classe (Exp 3, Exp 4, Exp 5)

| Classe    | Métrique  | Exp. 3 | Exp. 4        | Exp. 5       |
|-----------|-----------|--------|---------------|--------------|
| Début     | Précision | ~0,76  | ~0,84         | 0,74         |
|           | Recall    | 71,9%  | ~80%          | <b>90,4%</b> |
|           | F1-score  | ~0,74  | ~0,82         | 0,81         |
| Grave     | Précision | ~0,78  | ~0,78         | 0,77         |
|           | Recall    | ~85%   | ~89%          | ~94%         |
|           | F1-score  | ~0,81  | ~0,83         | 0,85         |
| Normal    | Précision | ~0,72  | ~0,81         | 0,89         |
|           | Recall    | ~65%   | ~76%          | ~63%         |
|           | F1-score  | ~0,68  | ~0,79         | 0,74         |
| Macro avg | Accuracy  | ~76%   | <b>81,67%</b> | 77,5%        |
|           | F1 macro  | ~0,72  | <b>0,79</b>   | 0,73         |
|           | AUC macro | ~0,91  | <b>0,9219</b> | ~0,92        |

## Annexe C : Heatmaps Grad-CAM

Cette annexe présente des exemples supplémentaires de visualisations Grad-CAM obtenues avec le modèle DenseNet-121 final (Expérience 5). Ces cartes de chaleur permettent de confirmer que le réseau se focalise sur les zones d'intérêt clinique (masses, irrégularités de contours) pour établir son diagnostic.

**Figure C.1 – Visualisation Grad-CAM sur une lésion maligne (Grave)** La zone d'activation (rouge) correspond précisément à la masse tumorale infiltrante, validant la pertinence spatiale de la décision.

**Figure C.2 – Visualisation Grad-CAM sur une lésion bénigne (Début)** Le modèle identifie une zone suspecte plus restreinte, cohérente avec une anomalie architecturale précoce.

**Figure C.3 – Visualisation Grad-CAM sur un tissu normal** On observe une absence de foyer d'activation intense, confirmant le caractère non suspect de l'image.

### Annexe D : Synthèse comparative des cinq expériences

Les cinq expériences successives ont été conçues pour mesurer la contribution individuelle de chaque composant du pipeline sur le recall de la classe *début*. Le tableau ci-dessous en présente une vue consolidée.

|                    | Exp. 1     | Exp. 2               | Exp. 3                 | Exp. 4                         | Exp. 5                         |
|--------------------|------------|----------------------|------------------------|--------------------------------|--------------------------------|
| Fine-tuning        | Tête seule | Tête seule           | 2 phases               | 2 phases                       | 2 phases                       |
| Focal Loss         | Non        | Non                  | Oui ( $\gamma = 2.0$ ) | Oui ( $\gamma = 2.0, \alpha$ ) | Oui ( $\gamma = 2.0, \alpha$ ) |
| Augmentation       | Basique    | Mixup $\alpha = 0.1$ | Mixup $\alpha = 0.1$   | Mixup $\alpha = 0.1$           | Mixup $\alpha = 0.1$           |
| Calibration seuils | Non        | Non                  | Non                    | Non                            | Oui (hiérarchique)             |
| Accuracy globale   | ~68%       | ~72%                 | ~76%                   | <b>81,67%</b>                  | 77,5%                          |
| Recall début       | ~58%       | ~65%                 | 71,9%                  | ~80%                           | <b>90,4%</b>                   |
| F1 macro           | ~0,62      | ~0,67                | ~0,72                  | <b>0,79</b>                    | 0,73                           |
| AUC macro          | ~0,86      | ~0,89                | ~0,91                  | <b>0,9219</b>                  | ~0,92                          |

Tableau D.1 — Résultats comparatifs des cinq expériences sur le jeu de test (240 images)

L'Expérience 4 constitue le meilleur compromis en termes d'accuracy et de F1 global. L'Expérience 5 sacrifie légèrement ces métriques au profit d'un recall de 90,4% sur les lésions débutantes, conformément à l'objectif clinique prioritaire de ce mémoire. Chaque composant apporte une contribution incrémentale mesurable : le fine-tuning en deux phases améliore la qualité des représentations, la Focal Loss pondérée

cible les classes difficiles, et la calibration hiérarchique agit comme levier final pour atteindre la cible de sensibilité précoce.

## LISTE DES FIGURES

Figure 1.1 – Charge du cancer du sein en Côte d'Ivoire (GLOBOCAN 2022)

Figure 1.2 – Contraintes d'infrastructure de dépistage (nombre de mammographes par population)

Figure 1.3 – Illustration schématique de la classification BI-RADS des microcalcifications

Figure 1.4 – Schéma des tissus mammaires denses (BI-RADS C et D) et impact sur la visibilité des lésions

Figure 2.1 – Exemples d'images issues des datasets CBIS-DDSM, INbreast et BUSI

Figure 2.2 – Schéma simplifié de l'architecture DenseNet-121

Figure 2.3 – Illustration des connexions denses au sein d'un dense block

Figure 2.4 – Visualisation d'un exemple de carte Grad-CAM en imagerie mammaire

Figure 3.1 – Répartition du dataset en ensembles d'entraînement, validation et test (1 580 images)

Figure 3.2 – Déséquilibre des classes dans l'ensemble d'entraînement (normal / début / grave)

Figure 3.3 – Schéma du pipeline de prétraitement (redimensionnement, normalisation, CLAHE, Mixup)

Figure 3.4 – Vue d'ensemble de l'architecture DenseNet-121 avec tête de classification à 3 classes

Figure 3.5 – Historique d'entraînement : courbes de loss et d'AUC sur train / validation

Figure 4.1 – Matrice de confusion de DenseNet-121 sur le jeu de test (avant calibration)

Figure 4.2 – Exemple de Grad-CAM pour une lésion de stade grave

Figure 4.3 – Exemple de Grad-CAM pour un sein normal

Figure 4.4 – Exemple de Grad-CAM pour une lésion de stade début

Figure 4.5 – Matrice de confusion calibrée (Expérience 5) sur le jeu de test

Figure 4.6 – Évolution du recall par classe entre Expérience 3 et Expérience 5

Figure B.1 – Courbes ROC par classe pour le modèle non calibré (test set)

Figure B.2 – Courbes ROC par classe pour le modèle calibré (Expérience 5)

Figure C.1 – Heatmaps Grad-CAM supplémentaires pour des cas correctement classés

Figure C.2 – Heatmaps Grad-CAM pour des cas mal classés (faux positifs / faux négatifs)

## LISTE DES TABLEAUX

Tableau 1.1 – Charge du cancer du sein chez la femme en Côte d'Ivoire (GLOBOCAN 2022)

Tableau 1.2 – Contraintes infrastructurelles et organisationnelles du dépistage en Côte d'Ivoire

Tableau 1.3 – Classification BI-RADS des microcalcifications et probabilité de malignité

Tableau 1.4 – Tendances de densité mammaire (BI-RADS C/D) selon les populations

Tableau 2.1 – Principaux jeux de données en cancer du sein (CBIS-DDSM, INbreast, BUSI)

Tableau 2.2 – Caractéristiques détaillées du dataset BUSI

Tableau 2.3 – Principales familles d'architectures CNN utilisées en imagerie mammaire

Tableau 2.4 – Stratégies de gestion du déséquilibre des classes (Focal Loss, oversampling, seuils)

Tableau 2.5 – Méthodes XAI courantes pour les CNN (Grad-CAM, Grad-CAM++, SHAP)

Tableau 3.1 – Répartition globale du dataset (train / validation / test)

Tableau 3.2 – Distribution des classes dans l'ensemble d'entraînement

Tableau 3.3 – Résumé des hyperparamètres d’entraînement (LR, batch size, gamma, alpha)

Tableau 3.4 – Mécanismes de reproductibilité mis en place (scripts, seeds, checkpoints)

Tableau 4.1 – Performances globales de DenseNet-121 avant calibration (test set)

Tableau 4.2 – Performances de DenseNet-121 après calibration (Expérience 5)

Tableau 4.3 – Détails par classe : précision, recall, F1 avant et après calibration

Tableau B.1 – Métriques complètes des Expériences 3, 4 et 5 (train / validation / test)

## LISTE DES ABRÉVIATIONS

AUC : Area Under the Curve (surface sous la courbe ROC)

AUROC : Area Under the Receiver Operating Characteristic Curve

BI-RADS : Breast Imaging Reporting and Data System

CAD : Computer-Aided Detection

CADx : Computer-Aided Diagnosis

CBAM : Convolutional Block Attention Module

CBIS-DDSM : Curated Breast Imaging Subset of the Digital Database for Screening Mammography

CHU : Centre Hospitalier Universitaire

CLAHE : Contrast Limited Adaptive Histogram Equalization

CNN : Convolutional Neural Network

CPU : Central Processing Unit

DCIS : Ductal Carcinoma In Situ

DL : Deep Learning

FFDM : Full-Field Digital Mammography

FN : False Negative (faux négatif)

FP : False Positive (faux positif)

FPR : False Positive Rate

F1 : F1-score (moyenne harmonique précision / recall)

GPU : Graphics Processing Unit

Grad-CAM : Gradient-weighted Class Activation Mapping

IA : Intelligence Artificielle

JSON : JavaScript Object Notation

LR : Learning Rate (taux d’apprentissage)

ML : Machine Learning

NPV : Negative Predictive Value

PPV : Positive Predictive Value

ReLU : Rectified Linear Unit

ROC : Receiver Operating Characteristic

SGD : Stochastic Gradient Descent

SOTA : State Of The Art

TN : True Negative (vrai négatif)

TP : True Positive (vrai positif)

TPR : True Positive Rate (recall / sensibilité)

TTA : Test-Time Augmentation

UVCI : Université Virtuelle de Côte d’Ivoire

ViT : Vision Transformer

XAI : eXplainable Artificial Intelligence

